



ATC 工具使用指南

文档版本 12

发布日期 2025-05-20

版权所有 © 海思技术有限公司2025。保留一切权利。

非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部，并不得以任何形式传播。

商标声明



HISILICON、海思和其他海思商标均为海思技术有限公司的商标。

本文档提及的其他所有商标或注册商标，由各自的所有人拥有。

注意

您购买的产品、服务或特性等应受海思公司商业合同和条款的约束，本文档中描述的全部或部分产品、服务或特性可能不在您的购买或使用范围之内。除非合同另有约定，海思公司对本文档内容不做任何明示或默示的声明或保证。

由于产品版本升级或其他原因，本文档内容会不定期进行更新。除非另有约定，本文档仅作为使用指导，本文档中的所有陈述、信息和建议不构成任何明示或暗示的担保。

海思技术有限公司

地址：上海市青浦区虹桥港路2号101室 邮编：201721

网址：<https://www.hisilicon.com/cn/>

客户服务邮箱：support@hisilicon.com



前言

概述

本文介绍如何将开源框架的网络模型（如Caffe、Onnx等），通过ATC（Advanced Tensor Compiler）将其转换成图像分析引擎支持的离线模型，模型转换过程中可以实现算子调度的优化、权值数据重排、内存使用优化等，可以脱离设备完成模型的预处理。

产品版本

与本文档相对应的产品版本如下。

产品名称	产品版本
Hi3519D	V500
Hi3516D	V500
Hi3516C	V608
Hi3516C	V610

说明

本文未有特殊说明，Hi3516DV500与Hi3519DV500内容完全一致；Hi3516CV608与Hi3516CV610内容完全一致。

读者对象

本文档主要适用于以下工程师：

- 技术支持工程师
- 软件开发工程师

掌握以下经验和技能可以更好地理解本文档：

- 熟悉Linux基本命令。
- 对机器学习、图像分析方法有一定的了解。



符号约定

在本文中可能出现下列标志，它们所代表的含义如下。

符号	说明
 危险	表示如不避免则将会导致死亡或严重伤害的具有高等级风险的危害。
 警告	表示如不避免则可能导致死亡或严重伤害的具有中等级风险的危害。
 注意	表示如不避免则可能导致轻微或中度伤害的具有低等级风险的危害。
须知	用于传递设备或环境安全警示信息。如不避免则可能会导致设备损坏、数据丢失、设备性能降低或其它不可预知的结果。 “须知”不涉及人身伤害。
 说明	对正文中重点信息的补充说明。 “说明”不是安全警示信息，不涉及人身、设备及环境伤害信息。

修订记录

修订记录累积了每次文档更新的说明。最新版本的文档包含以前所有文档版本的更新内容。

版本	日期	修改描述
12	2025-05-20	第12次正式版本发布 “3.3.2.3 --fusion_switch_file” 涉及修改 新增 “3.3.2.13 --n_loop_enable”



版本	日期	修改描述
11	2025-03-19	第11次正式版本发布 “3.1.1 总体约束”、“3.2.4.1.2.5 色域转换配置说明”小节涉及修改 3.2.5.4~3.2.5.6小节，修改参数值约束 新增“3.2.6.8 --output_quantized”、“3.2.6.9 --all_batch_quant_together_enable” 新增“3.3.2.11 --group_conv_trans_depthwise_enable”、“3.3.2.12--group_conv_not_trans_depthwise_layer” 新增“3.3.3.8 --board_single_push_enable” 添加Permute、Clip、LRN的规格约束 新增“5.2.1.5 ArgMin”小节 5.1.1.8、5.1.1.33、5.2.1.17小节，修改规格约束 新增“5.2.2.8 Cmp”小节 5.2.2小节中的Ceil、Floor、Round移入5.2.1章节
10	2024-12-30	第10次正式版本发布 3.2.4.1.2.6、3.2.4.1.4、3.2.6.3小节涉及更新。 3.2.6.2、3.2.6.3小节涉及更新。 3.2.6小节中增加“--quant_mode”、“--concat_auto_fallback_to_fp16”章节。 3.2.7.1小节至3.2.7.4、3.2.7.7小节涉及更新。 4.3.3、4.3.8小节涉及更新。 5.2.2小节中“Neg”章节移至5.2.1小节中。新增“Round”。 3.2.6小节，新增concat_auto_fallback_to_fp16 3.2.7小节，--nms_threshold、--low_score_threshold、--min_width和--min_height涉及修改。 5.1.1小节中“Concat”、“Slice”涉及更新。 5.2.1小节中“Concat”、“Gather”、“Flatten”、“Transpose”涉及更新。 4.3.8小节涉及修改 5.2.1小节，添加Gather的其他约束，新增GroupNorm章节 5.2.2小节，新增Gather算子。5.2.2小节中Scatter涉及更新。 “CumSum”、“OneHot”涉及修改。
09	2024-09-15	第9次正式版本发布 3.3.2.10小节，涉及更新。 5.2.2小节中“MaxUnPool”章节涉及更新。



版本	日期	修改描述
08	2024-09-15	第8次正式版本发布 2.3小节，涉及更新 3.2.5小节中“--out_nodes”涉及更新 3.3.1小节中“--inout_mem_reuse_mode”、“--pb_share_config”涉及更新。新增“--workbuf_optimize_enable”。 3.3.2小节中“--batch_num”、“--fusion_switch_file”涉及更新 3.2.6.1、3.2.4.1.2.5、3.2.4.1.2.6、3.2.4.1.2.11、3.2.6.3、3.3.2.1小节涉及修改。 新增“3.3.2.10 --tilingw_fusion_piecenum”、“3.3.1.10 --workbuf_priority_first” 4.3.10小节涉及更新。 5.1.1小节中DetectionOutput、PassThrough、Permute、Reduction、SortVector、FilterVector涉及修改。 5.1.2小节中Constant、DecBBox、DecBBox、GridSampleXDec、Max、Mean、Min、Transpose、WinPartition、WinPartitionReverse涉及修改。 5.2.1.100小节中新增SortVector和FilterVector。 5.1.1.41小节，axis的规格描述涉及修改 6.2.1小节涉及修改。 LayerNorm、MatMul小节涉及修改
07	2024-06-20	第7次正式版本发布 3.3.2.9、5.1.1.8、5.2.1.15、5.2.1.57、5.2.1.99小节涉及修改。 新增"5.2.2.19 GridSample"小节
06	2024-05-20	第6次正式版本发布 3.6.2.3小节涉及修改 5.2.1.27小节，indices参数的规格涉及修改
05	2024-05-10	第5次正式版本发布 新增“3.3.2.9 --tilingw_fusion_enable”内容 5.2.1.27小节涉及修改
04	2024-04-28	第4次正式版本发布 3.2.4.1、3.3.1.6、4.3、5.1小节涉及修改 3.2.5.3~3.2.5.6小节，添加Hi3516CV610不支持约束 新增“4.3.10 Hi3516CV610检测网后处理流程”小节 5.1.1.40小节，规格涉及修改



版本	日期	修改描述
03	2024-03-31	第3次正式版本发布 “3.2.4.1.3 静态AIPP配置项” 小节涉及更新 3.3.1.6小节修改参数值 “5.1.1.8 Convolution”、“5.1.1.12 DepthwiseConv”、 “5.1.1.13 DetectionOutput”、“5.1.1.58 Pad”、 “5.1.1.59 Reciprocal”、“5.2.1.7 AveragePool”、 “5.2.1.15 Conv”、“5.2.1.48 MaxPool”和“5.2.1.55 PRelu” 小节涉及更新。
02	2024-03-15	第2次正式版本发布 添加Hi3516CV610的相关内容。
01	2024-01-30	第1次正式版本发布 3.1.1、3.3.2.8小节涉及更新。 3.2.4.1.1、3.2.4.1.2.5、3.2.4.1.2.10、3.3.2.1、4.3.7、4.3.8小节涉及更新。 新增3.2小节中 “--output_reorder” 。 新增3.3小节中 “--inout_mem_reuse_mode” 和"--inout_mem_reuse_name"。 “--hwts_preemption_enableus”、“--dynamic_image_size”、“--inout_mem_reuse_mode” 新增须知。 5.1小节中 “Bias”、“ArgMax”、“Reduction”、“Eltwise”、“Softmax”“InstanceNormalization”、“Bias”、“Concat”、“Convolution”、“DepthwiseConv”、“InnerProduct”、“Interp”、“Reorg”、“Tile”、“Conv”、“Reduction”、“Scale”、“Slice”、“DepthToSpace”、“Gelu”、“Split”、“InstanceNormalization”、“LRN”、“ShuffleChannel”、“Upsample” 涉及更新。 5.2小节中 “ArgMax”、“Conv”、“ConvTranspose”、“MatMul”、“Tile”、“Gemm”、“LogSoftmax” 涉及更新。



版本	日期	修改描述
00B05	2023-10-30	第5次临时版本发布 3.1.1、3.6、3.2.4.1.2.3小节涉及修改。 3.2.4.1.2.9、3.2.4.1.2.10、3.2.4.1.2.11小节补充约束。 5.1章节中“Softmax”、“Reshape”、“Interp”小节涉及修改。 5.2章节中“AveragePool”、“MaxPool”、“Scatter”、“ScatterND”、“Resize”、“Softmax”、“Gather”、ConvTranspose 小节涉及修改。 5.1.12 ArgMax 补充约束。 3.2.4.1小节”图 AIPP整体功能“涉及修改。 4.3.1小节涉及更新。 新增“4.4 Transformer网络硬化加速”小节 5.2章节中新增“WinPartition”、“WinPartitionReverse”、“Roll”、“LayerNorm”、“Gelu2”、“InverseSigmoid”、“GridSampleXDec”、“PosEncode”、“MulReduceSum”、“Erf”。
00B04	2023-09-15	第4次临时版本发布 新增“--weight_cmp_ratio” 新增“3.6 与NNIE参数差异”小节 2.1.1、3.1.1、3.2.4.1.1、3.2.4.1.2.7、3.6、5.1.1.4、5.1.1.8、5.2.1.15、5.2.1.63、5.2.2.48小节涉及修改 5.2.1.50~5.2.1.56小节补充约束
00B03	2023-06-30	第3次临时版本发布 3.2.4.1.1、3.2.4.1.2.2至3.2.4.1.2.5、3.2.4.1.2.11、3.2.4.1.2.12 涉及修改 新增3.2.4.10、3.3.1.5小节 3.3.1.2、3.3.2.1、3.3.2.3、4.3.1、4.3.6至4.3.9涉及修改 "5.1.1.2 ArgMax"、“5.1.1.8 Convolution”、“5.1.1.11 Deconvolution”、“5.1.1.12 DepthwiseConv”、“5.1.1.13 DetectionOutput”、“5.2.1.12 ConvTranspose”规格涉及修改 新增“5.2.1.23 GlobalAveragePool”、“5.2.1.44 ReduceMax”、“5.2.1.45 ReduceMean”和“5.2.2.31 Neg” “6.2.1 Conv/Pool/DepthwiseConv”说明



版本	日期	修改描述
00B0 2	2023-05-1 0	第2次临时版本发布 3.2.1.2、3.2.2.3、3.2.3.1、3.2.3.3、3.2.4.1.2小节涉及更新。 3.2.4.1、3.2.4.2、3.2.4.1.3、3.2.5.2、3.3.1.1小节涉及更新。 3.2.4.11小节增加图。新增3.2.4.1.2.12小节“通道转换配置说明”。 5.1.1.8、5.1.1.11、5.1.1.49、5.1.1.51、5.2.1.11、5.2.1.12、 5.2.1.13、5.2.1.44、5.2.1.46、5.2.2.30小节涉及更新。
00B0 1	2023-03-1 0	第1次临时版本发布



目 录

前言.....	i
1 简介.....	1
1.1 工具功能架构.....	1
1.2 工具运行流程.....	1
2 使用入门.....	3
2.1 准备动作.....	3
2.1.1 获取 ATC 工具.....	3
2.1.2 设置环境变量.....	3
2.2 转换样例.....	3
2.3 输出文件说明.....	5
3 参数说明.....	7
3.1 概览.....	7
3.1.1 总体约束.....	7
3.1.2 参数配置方式.....	8
3.1.3 参数概览.....	9
3.2 基础功能.....	9
3.2.1 总体选项.....	9
3.2.1.1 --help.....	9
3.2.1.2 --version.....	9
3.2.1.3 --mode.....	10
3.2.2 ATC 输入选项.....	10
3.2.2.1 --model.....	10
3.2.2.2 --weight.....	11
3.2.2.3 --om.....	11
3.2.2.4 --framework.....	11
3.2.2.5 --custom_ops_lib.....	12
3.2.3 ATC 输出选项.....	12
3.2.3.1 --output.....	12
3.2.3.2 --check_report.....	13
3.2.3.3 --json.....	13
3.2.4 模型输入选项.....	14
3.2.4.1 --insert_op_conf.....	14



3.2.4.1.1 AIPP 规格约束.....	16
3.2.4.1.2 AIPP 选项.....	18
3.2.4.1.2.1 aipp_mode.....	18
3.2.4.1.2.2 related_input_rank.....	18
3.2.4.1.2.3 input_format 配置说明.....	19
3.2.4.1.2.4 model_format 配置说明.....	19
3.2.4.1.2.5 色域转换配置说明.....	20
3.2.4.1.2.6 减均值乘系数配置说明.....	23
3.2.4.1.2.7 原始图像宽高.....	24
3.2.4.1.2.8 最大图像宽高.....	25
3.2.4.1.2.9 crop 配置说明.....	25
3.2.4.1.2.10 resize 配置说明.....	26
3.2.4.1.2.11 padding 配置说明.....	27
3.2.4.1.3 静态 AIPP 配置项.....	28
3.2.4.1.4 动态 AIPP 配置项.....	29
3.2.4.2 --input_csc_enable.....	30
3.2.4.3 --input_channel_order_enable.....	30
3.2.4.4 --input_preprocess_enable.....	30
3.2.4.5 --input_resize_enable.....	31
3.2.4.6 --input_padding_enable.....	31
3.2.4.7 --input_crop_enable.....	31
3.2.4.8 --input_padding_info.....	32
3.2.4.9 --image_data_bits.....	32
3.2.4.10 --bit_compact_layer.....	33
3.2.4.11 --input_type.....	33
3.2.4.12 --input_shape.....	33
3.2.4.13 --input_format.....	34
3.2.5 模型输出选项.....	34
3.2.5.1 --output_type.....	34
3.2.5.2 --out_nodes.....	35
3.2.5.3 --image_report_name.....	35
3.2.5.4 --image_report_bit.....	36
3.2.5.5 --image_report_type.....	36
3.2.5.6 --output_rgb_order.....	37
3.2.5.7 --output_reorder.....	37
3.2.6 量化选项.....	38
3.2.6.1 --gfpq_param_file.....	38
3.2.6.2 --image_list.....	39
3.2.6.3 --compile_mode.....	41
3.2.6.4 --weight_quant_per_channel.....	42
3.2.6.5 --quant_mode.....	42
3.2.6.6 --high_precision_layer.....	42



3.2.6.7 --concat_auto_fallback_to_fp16.....	43
3.2.6.8 --output_quantized.....	43
3.2.6.9 --all_batch_quant_together_enable.....	43
3.2.7 RPN 硬化层选项.....	44
3.2.7.1 --nms_threshold.....	44
3.2.7.2 --low_score_threshold.....	44
3.2.7.3 --min_width.....	45
3.2.7.4 --min_height.....	45
3.2.7.5 --image_width.....	45
3.2.7.6 --image_height.....	46
3.2.7.7 --generate_anchors_file.....	46
3.2.7.8 --detection_out_accuracy.....	47
3.2.7.9 --use_class_id.....	47
3.2.8 Recurrent 网络选项.....	48
3.2.8.1 --recurrent_max_total_t.....	48
3.2.8.2 --recurrent_tmax.....	48
3.2.9 目标解决方案选项.....	49
3.2.9.1 --soc_version.....	49
3.3 高级功能.....	49
3.3.1 功能配置选项.....	49
3.3.1.1 --max_roi_frame_cnt.....	49
3.3.1.2 --online_model_type.....	50
3.3.1.3 --dynamic_image_size.....	50
3.3.1.4 --hwts_preemption_enable.....	51
3.3.1.5 --hwts_jump_option.....	52
3.3.1.6 --inout_mem_reuse_mode.....	52
3.3.1.7 --inout_mem_reuse_name.....	53
3.3.1.8 --pb_share_config.....	53
3.3.1.9 --workbuf_optimize_enable.....	54
3.3.1.10 --workbuf_priority_first.....	55
3.3.2 模型调优选项.....	55
3.3.2.1 --batch_num.....	55
3.3.2.2 --internal_stride.....	56
3.3.2.3 --fusion_switch_file.....	57
3.3.2.4 --net_optimize_enable.....	58
3.3.2.5 --layer_fusion_enable.....	58
3.3.2.6 --layer_m2m_enable.....	59
3.3.2.7 --layer_m2m_no_event_enable.....	59
3.3.2.8 --weight_cmp_ratio.....	60
3.3.2.9 --tilingw_fusion_enable.....	60
3.3.2.10 --tilingw_fusion_piecenum.....	60
3.3.2.11 --group_conv_trans_depthwise_enable.....	61



3.3.2.12 --group_conv_not_trans_depthwise_layer.....	61
3.3.2.13 --n_loop_enable.....	61
3.3.3 调试选项.....	62
3.3.3.1 --save_original_model.....	62
3.3.3.2 --dump_mode.....	62
3.3.3.3 --dump_data.....	63
3.3.3.4 --is_precheck.....	63
3.3.3.5 --log_level.....	64
3.3.3.6 --forward_quantization_option.....	64
3.3.3.7 --cutoff_layer.....	65
3.3.3.8 --board_single_push_enable.....	65
3.4 仅文件方式支持的参数.....	65
3.4.1 模型输入选项.....	65
3.4.1.1 image_type.....	65
3.4.1.2 norm_type.....	67
3.4.1.3 data_scale.....	67
3.4.1.4 mean_file.....	67
3.4.1.5 RGB_order.....	68
3.4.1.6 input_rgb_order.....	69
3.4.2 ATC 输入选项.....	69
3.4.2.1 prototxt_file.....	69
3.4.2.2 caffemodel_file.....	69
3.5 已废弃参数.....	70
3.6 与 NNIE 参数差异.....	70
4 定制网络修改.....	73
4.1 简介.....	73
4.2 Recurrent 网络 prototxt 示例.....	73
4.2.1 prototxt 针对 RNN 层书写规范.....	74
4.2.1.1 通常场景 (expose_hidden=false, 2 输入, 1 输出)	74
4.2.1.2 隐藏参数显式输入输出 (expose_hidden=true, 3 输入, 2 输出)	74
4.2.1.3 具有额外的固定输入 (expose_hidden=false, 3 输入, 1 输出)	75
4.2.1.4 既有固定输入, 又有显式的隐藏参数 (expose_hidden=true, 4 输入, 2 输出)	76
4.2.2 prototxt 针对 LSTM 层书写规范.....	76
4.2.2.1 通常场景 (expose_hidden=false, 2 输入, 1 输出)	77
4.2.2.2 隐藏参数显式输入输出 (expose_hidden=true, 4 输入, 3 输出)	77
4.2.2.3 具有额外的固定输入 (expose_hidden=false, 3 输入, 1 输出)	78
4.2.2.4 既有固定输入, 又有显式的隐藏参数 (expose_hidden=true, 5 输入, 3 输出)	79
4.2.3 prototxt 针对 GRU 层书写规范.....	79
4.2.3.1 通常场景 (expose_hidden=false, 2 输入, 1 输出)	80
4.2.3.2 隐藏参数显式输入输出 (expose_hidden=true, 3 输入, 2 输出)	80
4.2.3.3 具有额外的固定输入 (expose_hidden=false, 3 输入, 1 输出)	81
4.2.3.4 既有固定输入, 又有显式的隐藏参数 (expose_hidden=true, 4 输入, 2 输出)	82



4.2.4 Recurrent 网络约束.....	82
4.3 检测网硬化加速.....	83
4.3.1 DecBBox、Sort、Nms、Filter 层功能说明.....	83
4.3.2 硬化层参数配置.....	83
4.3.3 Faster RCNN 网络.....	86
4.3.4 RFCN 网络.....	88
4.3.5 SSD 网络.....	89
4.3.6 YOLOV1 网络.....	91
4.3.7 YOLOV2 网络.....	93
4.3.8 YOLOV3/V4/V5/V7 网络.....	95
4.3.9 YOLOV8 网络.....	96
4.3.10 Hi3516CV610 检测网后处理流程.....	98
4.4 Transformer 网络硬化加速.....	98
4.4.1 SwinT 网络.....	98
4.4.2 MOTR 网络.....	100
5 算子规格说明.....	102
5.1 Caffe 框架算子规格.....	102
5.1.1 图像分析引擎.....	102
5.1.1.1 AbsVal.....	102
5.1.1.2 ArgMax.....	102
5.1.1.3 BatchNorm.....	103
5.1.1.4 Bias.....	103
5.1.1.5 BNLL.....	103
5.1.1.6 Clip.....	104
5.1.1.7 Concat.....	104
5.1.1.8 Convolution.....	104
5.1.1.9 CReLU.....	106
5.1.1.10 Crop.....	106
5.1.1.11 Deconvolution.....	106
5.1.1.12 DepthwiseConv.....	107
5.1.1.13 DetectionOutput.....	109
5.1.1.14 Eltwise.....	110
5.1.1.15 ELU.....	110
5.1.1.16 Exp.....	111
5.1.1.17 Extract.....	111
5.1.1.18 Flatten.....	111
5.1.1.19 GRU.....	111
5.1.1.20 Hswish.....	112
5.1.1.21 InnerProduct.....	112
5.1.1.22 Input.....	112
5.1.1.23 Interp.....	113
5.1.1.24 Log.....	113



5.1.1.25 LRN.....	113
5.1.1.26 LSTM.....	114
5.1.1.27 MatMul.....	114
5.1.1.28 Mish.....	114
5.1.1.29 MVN.....	114
5.1.1.30 Nop.....	115
5.1.1.31 Normalize.....	115
5.1.1.32 PassThrough.....	115
5.1.1.33 Permute.....	115
5.1.1.34 Pooling.....	116
5.1.1.35 Power.....	117
5.1.1.36 PReLU.....	117
5.1.1.37 PSROIPooling.....	118
5.1.1.38 Reduction.....	118
5.1.1.39 ReLU/ReLU6/RReLU.....	118
5.1.1.40 Reorg.....	119
5.1.1.41 Reshape.....	119
5.1.1.42 Reverse.....	119
5.1.1.43 RNN.....	120
5.1.1.44 ROIPooling.....	120
5.1.1.45 Scale.....	121
5.1.1.46 ShuffleChannel.....	121
5.1.1.47 Sigmoid.....	121
5.1.1.48 Slice.....	121
5.1.1.49 Silence.....	122
5.1.1.50 Softmax.....	122
5.1.1.51 Split.....	122
5.1.1.52 SPP.....	122
5.1.1.53 Swish.....	123
5.1.1.54 TanH.....	123
5.1.1.55 Threshold.....	123
5.1.1.56 Tile.....	123
5.1.1.57 Upsample.....	123
5.1.1.58 SortVector.....	124
5.1.1.59 FilterVector.....	124
5.2 Onnx 框架算子规格.....	125
5.2.1 图像分析引擎.....	125
5.2.1.1 Abs.....	125
5.2.1.2 Acos.....	125
5.2.1.3 Add.....	126
5.2.1.4 ArgMax.....	126
5.2.1.5 ArgMin.....	127



5.2.1.6 Asin.....	127
5.2.1.7 Atan.....	128
5.2.1.8 AveragePool.....	128
5.2.1.9 BatchNormalization.....	129
5.2.1.10 Celu.....	130
5.2.1.11 Ceil.....	130
5.2.1.12 Clip.....	130
5.2.1.13 Compress.....	131
5.2.1.14 Concat.....	131
5.2.1.15 Constant.....	132
5.2.1.16 ConstantOfShape.....	133
5.2.1.17 Conv.....	133
5.2.1.18 ConvTranspose.....	135
5.2.1.19 Cos.....	136
5.2.1.20 DecBBBox.....	136
5.2.1.21 DepthToSpace.....	138
5.2.1.22 Div.....	138
5.2.1.23 Dropout.....	139
5.2.1.24 Elu.....	139
5.2.1.25 Exp.....	139
5.2.1.26 Erf.....	139
5.2.1.27 Filter.....	140
5.2.1.28 Floor.....	140
5.2.1.29 Flatten.....	140
5.2.1.30 Gather.....	141
5.2.1.31 Gemm.....	141
5.2.1.32 GlobalAveragePool.....	142
5.2.1.33 GlobalMaxPool.....	142
5.2.1.34 GRU.....	142
5.2.1.35 Gelu.....	144
5.2.1.36 GridSampleXDec.....	144
5.2.1.37 HardSigmoid.....	145
5.2.1.38 Identity.....	145
5.2.1.39 If.....	145
5.2.1.40 InverseSigmoid.....	145
5.2.1.41 InstanceNormalization.....	146
5.2.1.42 LRN.....	146
5.2.1.43 LeakyRelu.....	147
5.2.1.44 Log.....	147
5.2.1.45 LogSoftmax.....	147
5.2.1.46 Loop.....	148
5.2.1.47 LSTM.....	148



5.2.1.48 LayerNorm.....	149
5.2.1.49 MatMul.....	150
5.2.1.50 Max.....	150
5.2.1.51 MaxPool.....	151
5.2.1.52 Mean.....	152
5.2.1.53 Min.....	152
5.2.1.54 Mul.....	152
5.2.1.55 MeanVarianceNormalization.....	153
5.2.1.56 MulReduceSum.....	153
5.2.1.57 Neg.....	154
5.2.1.58 NMS.....	154
5.2.1.59 PRelu.....	154
5.2.1.60 Pow.....	155
5.2.1.61 PosEncode.....	155
5.2.1.62 Pad.....	156
5.2.1.63 Reciprocal.....	156
5.2.1.64 ReduceL1.....	156
5.2.1.65 ReduceMax.....	157
5.2.1.66 ReduceMean.....	157
5.2.1.67 ReduceMin.....	158
5.2.1.68 ReduceSumSquare.....	158
5.2.1.69 ReduceSum/version<=12.....	159
5.2.1.70 ReduceSum/version13.....	159
5.2.1.71 Relu.....	160
5.2.1.72 Reshape.....	160
5.2.1.73 Resize.....	160
5.2.1.74 RNN.....	161
5.2.1.75 RoiAlign.....	162
5.2.1.76 Round.....	163
5.2.1.77 Roll.....	164
5.2.1.78 Scan.....	164
5.2.1.79 Selu.....	164
5.2.1.80 Shape.....	165
5.2.1.81 Sigmoid.....	165
5.2.1.82 Sign.....	165
5.2.1.83 Sin.....	165
5.2.1.84 Size.....	166
5.2.1.85 Slice.....	166
5.2.1.86 Softplus.....	167
5.2.1.87 Softsign.....	167
5.2.1.88 SpaceToDepth.....	167
5.2.1.89 Split.....	168



5.2.1.90 Squeeze.....	168
5.2.1.91 Sub.....	168
5.2.1.92 Sum.....	169
5.2.1.93 Softmax.....	169
5.2.1.94 Sort.....	169
5.2.1.95 Tanh.....	170
5.2.1.96 ThresholdedRelu.....	170
5.2.1.97 Tile.....	170
5.2.1.98 Transpose.....	171
5.2.1.99 Upsample.....	171
5.2.1.100 Unsqueeze.....	172
5.2.1.101 WinPartition.....	172
5.2.1.102 WinPartitionReverse.....	172
5.2.1.103 TopK.....	173
5.2.1.104 SortVector.....	174
5.2.1.105 FilterVector.....	174
5.2.1.106 GroupNorm.....	175
5.2.2 CPU.....	175
5.2.2.1 Acosh.....	176
5.2.2.2 And.....	176
5.2.2.3 Asinh.....	176
5.2.2.4 Atanh.....	176
5.2.2.5 BitShift.....	177
5.2.2.6 Cosh.....	177
5.2.2.7 CumSum.....	177
5.2.2.8 Cmp.....	177
5.2.2.9 Equal.....	178
5.2.2.10 Det.....	178
5.2.2.11 Div.....	178
5.2.2.12 Expand.....	179
5.2.2.13 GatherElements.....	179
5.2.2.14 GlobalLpPool.....	179
5.2.2.15 Greater.....	179
5.2.2.16 GreaterOrEqual.....	180
5.2.2.17 GridSample.....	180
5.2.2.18 HardMax.....	180
5.2.2.19 Less.....	181
5.2.2.20 LessOrEqual.....	181
5.2.2.21 LpNormalization.....	181
5.2.2.22 MaxUnPool.....	181
5.2.2.23 Mod.....	182
5.2.2.24 NonMaxSuppression.....	182



5.2.2.25 NonZero.....	183
5.2.2.26 Not.....	183
5.2.2.27 OneHot.....	183
5.2.2.28 Or.....	184
5.2.2.29 Range.....	184
5.2.2.30 Resize.....	184
5.2.2.31 ReduceL2.....	185
5.2.2.32 ReduceLogSum.....	185
5.2.2.33 ReduceLogSumExp.....	186
5.2.2.34 ReduceProd.....	186
5.2.2.35 Scatter.....	186
5.2.2.36 ScatterND.....	187
5.2.2.37 Selu.....	187
5.2.2.38 Shrink.....	188
5.2.2.39 Sinh.....	188
5.2.2.40 Sqrt.....	188
5.2.2.41 Transpose.....	188
5.2.2.42 Xor.....	188
5.2.2.43 Where.....	189
5.2.2.44 Gather.....	189
5.3 Roi/Psroi Pooling 算子输入格式.....	189
5.3.1 ATC 工具的输入格式.....	190
5.3.2 板端的输入格式.....	191
5.4 Recurrent (LSTM/GRU/RNN) 算子板端输入输出格式.....	191
5.4.1 板端的输入格式.....	192
5.4.2 板端的输出格式.....	194
6 性能优化推荐设置.....	195
6.1 网络连接.....	195
6.1.1 兄弟节点的数据类型.....	195
6.1.2 兄弟节点的补边.....	196
6.1.3 Conv 级联 Pool.....	196
6.2 算子属性.....	196
6.2.1 Conv/Pool/DepthwiseConv.....	197
6.2.2 Deconv.....	197
6.2.3 输入输出 shape.....	198
6.2.4 变形类算子.....	198
6.2.5 双目运算类算子.....	198



插图目录

图 1-1 ATC 工具功能架构.....	1
图 1-2 运行流程.....	2
图 3-1 AIPP 整体功能.....	16
图 3-2 crop,padding,resize 顺序图.....	18
图 3-3 不支持 batch 结构图.....	56
图 4-1 Faster RCNN Proposal 层硬化结构图.....	87
图 4-2 RFCN Proposal 层硬化结构图.....	89
图 4-3 SSD DetectionOutput 层硬化结构图.....	90
图 4-4 YOLOV1 DetectionOutput 层硬化结构图.....	92
图 4-5 YOLOV2 DetectionOutput 层硬化结构图.....	94
图 4-6 YOLOV3/V4/V5/V7 DecBBBox/DetectionOutput 层硬化结构图.....	95
图 4-7 YOLOV8 DecBBBox/Sort/Nms/Filter 层硬化结构图.....	97
图 4-8 Hi3516CV610 检测网后处理流程图.....	98
图 4-9 Roll 算子对应原生 onnx 网络结构.....	99
图 4-10 WinPartition 算子对应原生 onnx 网络结构.....	99
图 4-11 WinPartitionReverse 算子对应原生 onnx 网络结构.....	99
图 4-12 InverseSigmoid 对应原生 onnx 网络结构.....	100
图 4-13 GridSampleXDec 算子对应原生 onnx 网络结构.....	100
图 4-14 PosEncode 对应原生 onnx 网络结构.....	101
图 4-15 MulReduceSum 对应原生 onnx 网络结构.....	101
图 5-1 两种输入格式的 prototxt 写法.....	190
图 5-2 两种输入格式的量化数据排布.....	190
图 5-3 首层 Roi/Psroi Pooling 网络结构图.....	191
图 5-4 Recurrent 网络片段结构图.....	193
图 6-1 兄弟节点的数据类型设置.....	195
图 6-2 兄弟节点的补边设置.....	196
图 6-3 Conv 级联 Pool 推荐设置.....	196



表格目录


表 4-1 硬化层参数配置限制.....	84
表 4-2 Faster RCNN RFCN SSD 硬化层参数配置.....	84
表 4-3 YOLOV1/V2/V3 硬化层参数配置.....	85

1 简介

1.1 工具功能架构

ATC工具功能架构如图1-1所示。从图1-1中可以看出，用户可以将开源框架网络模型通过ATC工具转换成适配图像分析引擎的离线模型，也可以将转换后的离线模型转成json文件，方便文件查看。用户也可以直接将开源框架网络模型文件通过ATC工具转成json文件。


图 1-1 ATC 工具功能架构



1.2 工具运行流程

使用ATC工具进行模型转换的总体流程如图1-2所示。

图 1-2 运行流程



详细流程说明如下：

- 使用ATC工具之前，请先在开发环境安装ATC，获取相关路径下的ATC工具，详细说明请参见“[获取ATC工具](#)”中的环境准备。
- 准备要进行转换的模型，并上传到开发环境，详细说明请参见“[转换样例](#)”。
- 使用ATC工具进行模型转换，在配置相关参数时，根据实际情况选择是否进行“[量化选项](#)”。图像预处理是图像分析引擎提供的硬件图像预处理模块，包括色域转换，图像归一化（减均值/乘系数）功能。



2 使用入门

2.1 准备动作

2.1.1 获取 ATC 工具

独立安装CANN包，详情请参见《驱动和开发环境安装指南》"2.3.4 软件包安装"。

本手册以ATC独立安装CANN包为例进行说明。

2.1.2 设置环境变量

须知

- 使用export方式设置环境变量后，环境变量只在当前窗口有效。如果用户之前在.bashrc文件中设置过ATC安装路径的环境变量，则在执行上述命令之前，需要先手动删除原来设置的ATC安装路径环境变量。
- 如果用户之前在.bashrc文件中设置过之前版本ATC安装路径的环境变量，则在执行atc命令之前，需要先手动删除原来设置的ATC安装路径环境变量，然后设置如下环境变量。设置完成后，切换到新窗口执行atc模型转换命令。

必选环境变量（如下环境变量中\${install_path}以软件包使用默认安装路径为例进行说明）

```
export PATH=${install_path}/Ascend/ascend-toolkit/{software version}/atc/bin:$PATH
export LD_LIBRARY_PATH=${install_path}/Ascend/ascend-toolkit/{software version}/atc/
third_party_lib:$LD_LIBRARY_PATH
```

或者执行如下命令配置环境变量。

```
source ${install_path}/Ascend/ascend-toolkit/{software version}/x86_64-linux/script/setenv.sh
```

2.2 转换样例

**须知**

使用高版本ATC工具转换的模型，在低版本环境上使用可能会出现不兼容问题，建议使用匹配的版本重新进行模型转换。

开源框架的 Caffe 网络模型转换成离线模型

步骤1 以ATC运行用户登录开发环境，并将模型转换过程中用到的模型文件 (*.prototxt)、权重文件 (*.caffemodel) 等上传到开发环境任意路径，例如上传到\$HOME/test/目录下。

步骤2 执行如下命令生成离线模型。（如下命令中使用的目录以及文件均为样例，请以实际为准）

```
atc --model=$HOME/test/xxx.prototxt --weight=$HOME/test/xxx.caffemodel --framework=0 --output=$HOME/test/out/xxx --image_list="data:$HOME/test/xxx_image_list.txt" --insert_op_conf="$HOME/test/image_preprocess.txt"
```

关于参数的详细解释以及使用方法请参见“[参数说明](#)”。

步骤3 若提示如下信息，则说明模型转换成功。

```
end binary code generating
```

成功执行命令后，在output参数指定的路径下，可查看离线模型（如：xxx.om）。

说明

如果用户使用Faster RCNN、YOLOV3、YOLOV2、SSD等Caffe框架网络模型进行模型转换，由于此类网络中包含了一些原始Caffe框架中没有定义的算子结构，如ROI Pooling、Normalize、PSROI Pooling和Upsample等。为了使图像分析引擎能支持这些网络，需要对原始的Caffe框架网络模型进行扩展，降低开发者开发自定义算子/开发后处理代码的工作量，详细扩展方法请参见“[检测网硬化加速](#)”。

----结束

开源框架的 Onnx 网络模型转换成离线模型

步骤1 以ATC运行用户登录开发环境，并将模型转换过程中使用到的模型文件 (*.onnx) 等上传到开发环境任意路径，例如\$HOME/test/目录下。

步骤2 执行如下命令生成离线模型。（如下命令中使用的目录以及文件均为样例，请以实际为准）

```
atc --model=$HOME/test/xxx.onnx --framework=5 --output=$HOME/test/out/xxx.om --image_list="data:$HOME/test/xxx_image_list.txt"
```

关于参数的详细解释以及使用方法请参见“[参数说明](#)”。

步骤3 若提示如下信息，则说明模型转换成功。

```
end binary code generating
```

成功执行命令后，在output参数指定的路径下，可查看离线模型（如：xxx.om）。

----结束

2.3 输出文件说明

- *.om: 转换后的模型文件，文件名通过**--output**配置。
- atc_perf.csv: 预估模型在板端运算时实际计算量。
- calibration_param.txt: 模型使用的量化参数。
- cnn_net_tree_parser.dot: 原始模型解析后的算子信息。
- cnn_net_tree_adapt.dot: 网络适配后的算子信息。
- cnn_net_tree.dot: 网络优化后的算子信息。
- cnn_net_tree_after_tiling_seg_0.dot: 网络深度融合后的算子信息。

说明

请通过dot命令把*.dot 文件转为pdf文件方便查看，如：dot -Tpdf cnn_net_tree.dot -o cnn_net_tree.pdf。

安装dot命令：apt install graphviz

- mapper_debug.log: 转换模型的调试日志。
- mapper_error.log: 转换模型的错误日志。
- layer.json: 输出原始模型的算子信息，见命令行参数**--json**。
- shape.json: 输出原始模型每个算子的shape信息，见命令行参数**--json**。
- om.json: 输出转换后的模型信息，见命令行参数**--json**。
 - 模型信息包括但不限于：
 - tmp_buf_size: 板端运行模型时NPU算子需要的临时缓存。
 - aicpu_buf_size: 板端运行模型时CPU算子需要的缓存。
 - dump_buf_size: 板端运行模型时，dump算子数据时需要的缓存。
 - model_param_size: om模型的参数大小。
 - atc_version: 转换模型时用的ATC版本号。
 - batch_num: 支持的动态batch数，见命令行参数**--batch_num**。
 - 算子信息包括但不限于：
 - name: 算子名。
 - type: 算子类型。
 - device_type: 算子类型是CPU或NPU。
 - input_desc: 算子输入信息。
 - output_desc: 算子输出信息。
 - data_flow: 算子输入、计算、输出的数据类型。



须知

以下文件包含网络结构等敏感信息，若用户不需要保留这些数据，请及时删除：
.om/.dot/*.json/mapper_debug.log



3 参数说明

3.1 概览

3.1.1 总体约束

在进行模型转换前，请务必查看如下约束要求：

- 如果要Faster RCNN等网络模型转成适配图像分析引擎的离线模型，则务必参见“[定制网络修改](#)”先修改prototxt模型文件。
- 支持原始框架类型为Caffe、Onnx的模型转换，输入数据类型为FP32、FP16、INT16、UINT16、INT8、UINT8。
- 当原始框架类型为Caffe时，模型文件（.prototxt）和权重文件（.caffemodel）的层名、层类型必须保持名称一致（包括大小写）。
- 不支持动态shape的输入，例如：NCHW输入为[?,3,?,?]多个维度可任意指定数值。模型转换时需指定固定数值。
- 输入数据默认最大支持四维，有特殊说明的算子，以具体规格说明为准。
- 模型中的所有层算子除const算子外，输入和输出需要满足每个维度不为零。
- 只支持“[算子规格说明](#)”中的算子，并需满足算子限制条件。不支持的算子需用户在板端使用CPU实现，把网络切分编译多个om，然后调用板端ACL API串通网络。
- 当模型输入是4维或2维，且第0维>1时，ATC识别第0维为batch，为节省work buffer，把第0维改为1。
- 模型中所有输入输出的名字和算子层的名字都需要小于255个字符。
- 以下参数仅Hi3516CV610 AIISP场景支持，非AIISP模型请勿配置：

--alu_coef_pipe_name	--backward_jump	--combine_tiling_info_enable
--dlut_enable	--dynamic_ub_reuse	--event_table_opt
--gplp_method	--image_fake_raw_type	--max_val
--min_val	--multi_model_share_aipp	--once_jump



--once_jump_cnt	--out_nodes_order_2nd	--pingpong_jump
--pingpong_jump_cnt	--pitch_align_opt	--tile_number
--ub_alloc_opt	--w4_cube_eltwise_merge_enable	--active2pwl
--aidrc_compress_layer	--aipp_data_merge_enable	--deconv_multiple
--dlut_input	--dlut_table	--fusion_buffer_info
--fusion_end_nodes	--fusion_strategy	--fusion_subnet_info
--input_crop_info	--input_csc_input_bias_info	--input_csc_matrix_info
--input_csc_output_bias_info	--input_dcmp_enable	--input_dcmp_nodes
--input_gamma_enable	--input_gamma_lut_table	--input_max_shape_info
--input_padding_mode	--input_resize_mode	--input_resize_ratio
--input_resize_shape_info	--inst_opt_enable	--inter_layer_event_opt_enable
--isp_gain_clip_data_bits	--isp_gain_input_enable	--isp_gain_input_node_name
--isp_gain_param_num	--load_buffer_num	--mutil_model_enable
--nodes_order	--op_binary_file	--output_cmp_enable
--output_cmp_nodes	--output_crop_enable	--output_crop_info
--output_degama_enable	--output_degama_lut_table	--output_shape
--packed_report_name	--packed_report_repeat_num	--post_processing_high_precision
--profile_map_channel_num	--profile_map_conv_node_name	--pwl_file
--reorder_nodes_disable	--src_img_shape	--store_buffer_num
--tiling_cube_l0c_priority_enable	--two_stage_enable	--alu_op_opt
--op_binary_stage_num		

3.1.2 参数配置方式

ATC 支持2种配置方式，支持同样的参数。

- 文件参数方式：
atc cfg_file

示例：atc test.cfg

- 文件参数格式：



```
[param1] value1  
[param2] value2  
...
```

文件参数格式示例：

```
[model] test.prototxt  
[weight] test.caffemodel  
[image_list] image_list.txt  
[insert_op_conf] image_preprocess.txt
```

- 命令行参数方式：

```
atc param1=value1 param2=value2 ...
```

示例：

```
--model=$HOME/test/resnet50.prototxt --weight=$HOME/test/resnet50.caffemodel --  
image_list=image_list.txt --insert_op_conf=image_preprocess.txt
```

3.1.3 参数概览

通过atc --help命令查询出所有支持的参数。

3.2 基础功能

以下介绍部分常用参数选项，更多选项用法请输入--help。

3.2.1 总体选项

3.2.1.1 --help

功能说明：显示帮助信息。

关联参数：无

参数取值：无

推荐配置及收益：无

示例：atc --help

依赖约束：无

3.2.1.2 --version

功能说明：显示ATC版本信息。

关联参数：无

参数取值：无

推荐配置及收益：无

示例：atc --version

依赖约束：无



3.2.1.3 --mode

功能说明：运行模式。

关联参数：若--mode取值为1或3，则需要与 **--om**、**--json**参数配合使用。如果将原始模型文件转换成带shape信息的json文件，则还需要与 **--dump_mode**参数配合使用。

参数取值：

- 参数值
 - 0：生成离线模型。
 - 1：离线模型或原始模型文件转json，方便查看模型中的参数信息。
 - 3：仅做预检，检查模型文件的内容是否合法。
- 参数值约束：配置为1或3时不会转换离线模型。
- 参数默认值：0

推荐配置及收益：无

示例：

```
--mode=0或--mode 0
```

📖 说明

使用atc命令进行模型转换时，命令有两种方式，用户根据实际情况进行选择，本章节以选择第一种方式为例进行说明：

1. **atc param1=value1 param2=value2 ...**（value值前面不能有空格，否则会导致截断，param取的value值为空）
2. **atc param1 value1 param2 value2 ...**

依赖约束：无

3.2.2 ATC 输入选项

3.2.2.1 --model

功能说明：原始模型文件路径与文件名。

关联参数：当原始模型为Caffe框架时，需要和**--weight**参数配合使用。

参数取值：

- 参数值：模型文件路径与文件名。
- 参数值格式：路径和文件名，支持大小写字母（a-z, A-Z）、数字（0-9）、下划线（_）、中划线（-）、句点（.）、中文字符。

推荐配置及收益：无

示例：

```
--model=$HOME/test/resnet50.prototxt --weight=$HOME/test/resnet50.caffemodel
```

依赖约束：无



3.2.2.2 --weight

功能说明：

- 权重文件路径与文件名。
- 当原始模型是Caffe时需要指定。

关联参数：当原始模型为Caffe框架时，需要和**--model**参数配合使用。

参数取值：

- 参数值：权重文件路径与文件名。
- 参数值格式：路径和文件名，支持大小写字母（a-z, A-Z）、数字（0-9）、下划线（_）、中划线（-）、句点（.）、中文字符。

推荐配置及收益：无

示例：

```
--model=$HOME/test/resnet50.prototxt --weight=$HOME/test/resnet50.caffemodel
```

依赖约束：无

3.2.2.3 --om

功能说明：需要转换为json格式的离线模型（.om）、原始模型文件（.prototxt、.onnx）。

关联参数：若**--mode=1**，则该参数必填，并且需要与**--json**参数配合使用。

参数取值：

- 参数值：离线模型（.om）、原始模型文件（.prototxt、.onnx）。
- 参数值格式：路径和文件名，支持大小写字母（a-z, A-Z）、数字（0-9）、下划线（_）、中划线（-）、句点（.）、中文字符。

推荐配置及收益：无

示例：

- 离线模型转换为json
`--mode=1 --om=$HOME/test/module/out/caffe_resnet50.om --json=$HOME/test/module/out/result.json`
- 原始模型文件转换为json
`--mode=1 --om=$HOME/module/resnet50.prototxt --json=$HOME/module/out/result.json --framework=0`

依赖约束：无

3.2.2.4 --framework

功能说明：原始框架类型。

关联参数：无

参数取值：

- 参数值：
 - 0: Caffe



- 5: ONNX
- 6: ABSTRACT (使用构图接口)
- 参数值约束: 当 **--mode** 为 1 时, 该参数可选, 可以指定 Caffe、Onnx、原始模型转成 json, 不指定时默认为离线模型转 json, 如果指定时需要保证 --om 模型和 --framework 类型对应一致, 例如:

```
--mode=1 --framework=0 --om=$HOME/test/resnet18.prototxt --mode=1 --framework=5 --om=$HOME/test/resnet101.onnx
```

推荐配置及收益: 无

示例:

```
--mode=0 --framework=0 --model=$HOME/test/resnet50.prototxt --weight=$HOME/test/resnet50.caffemodel
```

依赖约束: 无

3.2.2.5 --custom_ops_lib

📖 说明

Hi3516CV610 不支持自定义算子。

功能说明: 自定义算子库文件路径与文件名。如果没有配置 --custom_ops_lib, 默认从环境变量 LD_LIBRARY_PATH 中加载名为 libsvp_custom.so 的自定义算子库。如果配置了 --custom_ops_lib, 则优先加载 --custom_ops_lib。当转换的模型包含自定义算子, 而环境变量 LD_LIBRARY_PATH 没有包含 libsvp_custom.so 时, 必须配置 --custom_ops_lib 指定自定义算子库, 否则转换模型失败。

参数取值:

- 参数值: 自定义算子库文件路径与文件名。绝对路径或相对 ATC 执行的路径。
- 参数值格式: 路径和文件名, 支持大小写字母 (a-z, A-Z)、数字 (0-9)、下划线 (_)、中划线 (-)、句点 (.)、中文字符。

推荐配置及收益: 无

示例:

```
--custom_ops_lib=$HOME/test/libsvp_custom.so
```

依赖约束: 无

3.2.3 ATC 输出选项

3.2.3.1 --output

功能说明: 如果是开源框架的网络模型, 存放转换后的离线模型的路径以及文件名, 例如: \$HOME/test/out/caffe_resnet18 或 \$HOME/test/out/tf_resnet18, 转换后的模型文件名以指定的文件名为准, 自动以 .om 后缀结尾, 例如: caffe_resnet18.om。

关联参数: 无

参数取值:

- 参数值: 如果是开源框架的网络模型: 存放转换后的离线模型的路径以及文件名。



- 参数默认值：如果未指定路径或文件名，或以"/"结束，则默认生成inst.om。
- 参数值格式：路径和文件名：支持大小写字母（a-z, A-Z）、数字（0-9）、下划线（_）、中划线（-）、句点（.）、中文字符。

推荐配置及收益：无

示例：

```
--output=$HOME/test/out/caffe_resnet18
```

依赖约束：无

3.2.3.2 --check_report

功能说明：预检结果保存文件路径和文件名。

关联参数：

--mode：当--mode=3仅做预检时，用于生成check_result.json预检结果文件。

参数取值：

- 参数值：预检结果保存文件路径和文件名。
- 参数默认值：无
- 参数值格式：路径和文件名：支持大小写字母（a-z, A-Z）、数字（0-9）、下划线（_）、中划线（-）、句点（.）、中文字符。

推荐配置及收益：无

示例：

```
--check_report=$HOME/test/out/check_result.json
```

依赖约束：无

3.2.3.3 --json

功能说明：离线模型、原始模型文件、转换为json格式文件的路径和文件名。

关联参数：

- 离线模型转换为json
该参数需要与--mode=1、--om参数配合使用。
- 原始模型文件转换为json
该参数需要与--mode=1、--om参数、--framework配合使用，caffe还需配合--weight使用。

参数取值：

- 参数值：json格式文件的路径和文件名。
- 参数值格式：路径和文件名：支持大小写字母（a-z, A-Z）、数字（0-9）、下划线（_）、中划线（-）、句点（.）、中文字符。

推荐配置及收益：无

示例：



- 离线模型转换为包含模型信息和算子信息的json
`--mode=1 --om=$HOME/test/module/out/caffe_resnet50.om --json=$HOME/test/module/out/om.json`
- 原始模型文件转换为包含层信息的json
`--mode=1 --om=$HOME/module/resnet50.prototxt --json=$HOME/module/out/layer.json --framework=0`
- 原始模型文件转换为包含形状信息的json
`--mode=1 --om=$HOME/module/resnet50.prototxt --weight=$HOME/module/resnet50.caffemodel --json=$HOME/module/out/shape.json --framework=0 --dump_mode=1`

依赖约束：无

3.2.4 模型输入选项

3.2.4.1 --insert_op_conf

功能说明：插入图像预处理的配置。配置了图像预处理的Data层表示输入数据格式为图像，没有配置的为Feature Map。

关联参数：无

参数取值：

- 参数值：插入图像预处理的配置文件路径与文件名。
- 参数值格式：路径和文件名，支持大小写字母（a-z，A-Z）、数字（0-9）、下划线（_）、中划线（-）、句点（.）、中文字符。

推荐配置及收益：无



须知


1. 图像预处理(AIPP:AI Preprocessing)当前支持图像裁剪(crop)、图像边缘填充(padding)、图像缩放(resize)、色域转换、通道数据交换、减均值、乘系数;对于Hi3519DV500芯片,如果图像缩放模式选择为最近邻(nearest),图像预处理按图像裁剪、图像边缘填充、图像缩放、色域转换、通道数据交换、减均值、乘系数顺序执行;如果选择图像缩放模式为线性缩放,图像预处理按图像裁剪、图像边缘填充、色域转换、通道数据交换、减均值、乘系数,图像缩放顺序执行。对于Hi3516CV610芯片,图像预处理按图像裁剪、图像边缘填充、色域转换、通道数据交换、减均值、乘系数,图像缩放顺序执行。
2. 请按原始模型的图像预处理、板端运行时输入的数据格式配置。
3. 模板中参数取值都为默认值,实际使用时,如果配置文件中某些参数未配置,则模型转换时自动设置成该模板中相应参数的默认值。
4. input_format属性为必选属性,其余属性均为可选配置,如果未配置,则模型转换时自动设置成该模板中相应参数的默认值。
5. 模型转换时开启或没有AIPP,在进行推理业务时,输入图片数据都要求为NCHW排布。
6. 图像输入种类。
 - 若图像输入为YUV400,要求输入channel为1;
 - 若图像输入为UVSP、VUSP,要求输入channel为2;
 - 若图像输入为YUV420SP、YVU420SP、YUV422SP、YVU422SP、YUV444SP、YVU444SP、BGR_PLANAR、RGB_PLANAR、RGB_PACKAGE、BGR_PACKAGE,要求输入channel为3;
 - 其他输入格式要求输入channel为4。
7. 在使能AIPP功能时,您只能选择静态AIPP或动态AIPP方式来处理图片,不能同时配置静态AIPP和动态AIPP两种方式,使能AIPP时可以通过aipp_mode参数控制。动态AIPP的参数每次推理需要计算,计算需要耗时,所以动态AIPP的性能比静态AIPP性能要差。
8. 当开启preproc为动态时,需与静态preproc结果一致时,生成离线模型时动态insert_op_conf文件需将静态对应的preproc参数一块配置。

将配置好的insert_op.conf文件上传到ATC工具所在服务器任意目录,例如上传到/home/test/,使用示例如下:

```
--insert_op_conf=/home/test/insert_op.conf
```

依赖约束: 无

图 3-1 AIPP 整体功能



3.2.4.1.1 AIPP 规格约束


- 对于Hi3519DV500，Resize模式不同，AIPP的流程顺序也不同。
 - 当Resize的模式是nearest时候，流程顺序是Crop、Pad、Resize、色域转换、通道转换、减均值归一化；
 - 当Resize的模式是bilinear时候，流程顺序是Crop、Pad、色域转换、通道转换、减均值归一化、Resize。
- 对于Hi3516CV610，AIPP流程顺序统一为：Crop、Pad、色域转换、通道转换、减均值归一化、Resize。
- Crop、Pad、Resize三个操作会改变图像尺寸，经过AIPP处理之后的图片的宽和高，应该与模型文件--input_shape中的宽和高相等。
- 在处理RAW_RGGB、RAW_GRBG、RAW_GBRG、RAW_BGGR图像的时候，Crop和Pad是对原始图像即channel为1的图像进行处理，Resize则是对变成4通道后的数据即channel为4的数据进行处理。假设原始图像的大小为1*1*224*224，Crop的加载坐标以及大小参数分别为[3, 3, 110, 110]，Pad的上下左右补边参数分别是[2, 2, 2, 2]，经过Crop和Pad之后，图像变为1*1*114*114；在进入Resize前，图像会变为4通道：1*4*57*57；因此Resize的input需要填为1*4*57*57，此外Resize的output需要与--input_shape相等。
- Crop、Pad、Resize静态模式不支持动态分辨率
 - Crop
 - 抠图起始位置用load_start_pos_w和load_start_pos_h表示，抠图大小用crop_size_w和crop_size_h表示。
 - 抠图起始位置约束



- 要求load_start_pos_w * bitNum为8的倍数，其中bitNum代表图像像素的位宽。
 - 要求 load_start_pos_w < src_image_size_w, load_start_pos_h < src_image_size_h。
 - 对于YUV420SP、YVU420SP、YUV422SP、YVU422SP的图像，要求取值是偶数。
- 抠图大小约束
 - 要求load_start_pos_w + crop_size_w <= src_image_size_w, load_start_pos_h + crop_size_h <= src_image_size_h
 - 对于YUV420SP、YVU420SP、YUV422SP、YVU422SP以及RAW_RGGB、RAW_GRGB、RAW_GBRG、RAW_BGGR的图像，要求取值是偶数。
- Pad
 - 上下左右补边分别用top_padding, bottom_padding, left_padding, right_padding
 - 要求top_padding, bottom_padding, left_padding, right_padding范围都在[0, 15]
 - 对于RAW_RGGB、RAW_GRGB、RAW_GBRG、RAW_BGGR的图像，要求 (top_padding+ bottom_padding) 的结果为偶数， (left_padding + right_padding) 为偶数
 - Pad模式包括const_zero、duplicate、reflection、symmetric。对于const_zero模式，当使能Resize的nearest模式，且垂直方向为下采样的时候，即高方向缩放倍数（输出/输入）小于1的时候，top_padding和bottom_padding只能设置为0。对于Hi3516CV610芯片，只支持const_zero和duplicate模式。
 - 对于YUV420SP、YVU420SP、YUV422SP、YVU422SP，静态aipp场景，pad要求取值是偶数；动态aipp场景，当resize关闭或者模式为nearest模式的时候，pad要求取值是偶数
- Resize
 - 静态模式
 - 支持nearest resize, 宽、高缩放倍数（输出/输入）分别支持 0.25、0.5、1、2。
 - 对于Hi3519DV500芯片，bilinear resize支持cube和vector两种模式，区别为不同硬件实现，对于Hi3516CV610芯片，bilinear resize不区分模式。
 - 对于Hi3519DV500芯片，支持bilinear resize (cube) : 缩放倍数能用5.5定点数表示，则优先走cube，以获得通常情况下较优的性能。H方向缩放倍数为Hin/Hout，W方向缩放倍数为Win/Wout。5.5定点数，为整数部分使用5位和小数部分使用5位的定点数，该数的整数部分小于32，小数部分乘32后结果为整数。
注：在align_corners模式下，缩放倍数计算公式为(Win-1)/(Wout-1)或(Hin-1)/(Hout-1)。
 - 对于Hi3519DV500芯片，支持bilinear resize (vector) : 如果不能使用cube的话，则使用vector。

- 对于Hi3519DV500芯片，为了支持更高精度，用户可配置使用 bilinear resize (vector)。
- 动态模式
 - 支持nearest resize, 宽、高缩放倍数（输出/输入）分别支持 0.25、0.5、1、2。
 - 支持bilinear resize (vector)。
 - 输入、输出的分辨率最大值4096。

图 3-2 crop,padding,resize 顺序图



3.2.4.1.2 AIPP 选项

3.2.4.1.2.1 aipp_mode

功能说明：AIPP模式，必须配置。

关联参数：无

参数取值：

- 参数值：dynamic,static
dynamic: 动态AIPP
static: 静态AIPP
- 参数类型：String

示例：

```
aipp_mode: static
```

依赖约束：无

3.2.4.1.2.2 related_input_rank

功能说明：标识对模型的第几个输入做图像预处理，从0开始，默认为0。

关联参数：无

参数取值：

- 参数值：0,1.....
- 参数默认值：0
- 参数类型：整型
- 参数数值约束：>=0

示例：



related_input_rank: 0

依赖约束：无

3.2.4.1.2.3 input_format 配置说明

功能说明：板端运行时输入的图像格式或Feature Map，必须配置。

关联参数：无

参数取值：

- 参数值：YUV420SP、YVU420SP、YUV422SP、YVU422SP、YUV444SP、YVU444SP、YUV400、BGR_PLANAR、RGB_PLANAR、RGB_PACKAGE、BGR_PACKAGE、XRGB_PLANAR、ARGB_PLANAR、XBGR_PLANAR、ABGR_PLANAR、RGBX_PLANAR、RGBA_PLANAR、BGRX_PLANAR、BGRA_PLANAR、XRGB_PACKAGE、ARGB_PACKAGE、XBGR_PACKAGE、ABGR_PACKAGE、RGBX_PACKAGE、RGBA_PACKAGE、BGRX_PACKAGE、BGRA_PACKAGE、RAW_RGGB、RAW_GRGB、RAW_GBRG、RAW_BGGR、UVSP、VUSP、FM。
- 参数类型：enum
- 参数值约束
 - 1.图像输入时shape必须为4d。
 - 2.图像输入与输入channel的对应关系如下：
若图像输入为YUV420SP、YVU420SP、YUV422SP、YVU422SP、YUV444SP、YVU444SP、BGR_PLANAR、RGB_PLANAR、RGB_PACKAGE、BGR_PACKAGE，要求输入channel为3
若图像输入为YUV400，要求输入channel为1；
若图像输入为UVSP、VUSP，要求输入channel为2；
若图像输入为XRGB_PLANAR、ARGB_PLANAR、XBGR_PLANAR、ABGR_PLANAR、RGBX_PLANAR、RGBA_PLANAR、BGRX_PLANAR、BGRA_PLANAR、XRGB_PACKAGE、ARGB_PACKAGE、XBGR_PACKAGE、ABGR_PACKAGE、RGBX_PACKAGE、RGBA_PACKAGE、BGRX_PACKAGE、BGRA_PACKAGE、RAW_RGGB、RAW_GRGB、RAW_GBRG、RAW_BGGR，要求输入channel为4。
若图像输入为BGR_PLANAR且图像输入channel为1，则会强制将图像输入类型更改为YUV400。
 - 3.FM表示Feature Map。
 - 4.channel在aipp功能后的channel数目。

示例：

input_format: BGR_PLANAR

依赖约束：无

3.2.4.1.2.4 model_format 配置说明

功能说明：模型运行时的色域格式。

关联参数：[input_format](#)

参数取值：



- 参数值：RGB、BGR、ARGB、ABGR、RGBA、BGRA、XRGB、XBGR、RGBX、BGRX、RGGB、GRBG、GBRG、BGGR
- 参数类型：enum
- 参数值约束：需要与input_format相匹配
YUV420SP、YVU420SP、YUV422SP、YVU422SP、YUV444SP、YVU444SP、UVSP、VUSP、BGR_PLANAR、RGB_PLANAR、RGB_PACKAGE、BGR_PACKAGE可取值范围为RGB、BGR;
XRGB_PLANAR、ARGB_PLANAR、XBGR_PLANAR、ABGR_PLANAR、RGBX_PLANAR、RGBA_PLANAR、BGRX_PLANAR、BGRA_PLANAR、XRGB_PACKAGE、ARGB_PACKAGE、XBGR_PACKAGE、ABGR_PACKAGE、RGBX_PACKAGE、RGBA_PACKAGE、BGRX_PACKAGE、BGRA_PACKAGE可取值范围为XRGB、XBGR、RGBX、BGRX;
RAW_RGGB、RAW_GRBG、RAW_GBRG、RAW_BGGR可取值范围为RGGB、GRBG、GBRG、BGGR;
YUV400忽略此配置;
图像格式为灰度图(GRAY)时，不需配置;
Feature Map忽略此配置。

示例：

```
model_format: BGR
```

依赖约束：无

3.2.4.1.2.5 色域转换配置说明

功能说明：用于将输入的图片格式，转换为模型需要的图片格式，静态aipp可选配置，动态aipp无须配置，Feature Map不支持此功能。

关联参数：无

相关参数：

- csc_switch
功能说明：色域转换开关，静态AIPP配置。
参数类型：bool
取值范围：true/false，true表示开启色域转换，false表示关闭;
示例：

```
csc_switch: false
```
- matrix_r0c0, matrix_r0c1, matrix_r0c2, matrix_r1c0, matrix_r1c1, matrix_r1c2, matrix_r2c0, matrix_r2c1, matrix_r2c2
功能说明：3*3 CSC矩阵元素
参数类型：int16
取值范围：[-32677, 32676]
示例：

```
matrix_r0c0: 1192  
matrix_r0c1: 2166  
matrix_r0c2: 0  
matrix_r1c0: 1192  
matrix_r1c1: -218  
matrix_r1c2: -547  
matrix_r2c0: 1192
```



```
matrix_r2c1: 0
matrix_r2c2: 1836
```

- output_bias_0, output_bias_1, output_bias_2

功能说明：RGB转YUV时的输出偏移。

参数类型：uint8

取值范围：[0, 255]

示例：

```
output_bias_0: 16
output_bias_1: 128
output_bias_2: 128
```

- input_bias_0, input_bias_1, input_bias_2

功能说明：YUV转RGB时的输入偏移。

参数类型：uint8

取值范围：[0, 255]

示例：

```
input_bias_0: 16
input_bias_1: 128
input_bias_2: 128
```

计算规则：

YUV转BGR：

```
| B | | matrix_r0c0 matrix_r0c1 matrix_r0c2 | | Y - input_bias_r0 | | output_bias_0 |
| G | = ( | matrix_r1c0 matrix_r1c1 matrix_r1c2 | | U - input_bias_r1 | ) >> 10 + | output_bias_1 |
| R | | matrix_r2c0 matrix_r2c1 matrix_r2c2 | | V - input_bias_r2 | | output_bias_2 |
```

根据不同的彩色视频数字化标准又可以将视频格式分为BT-601标准清晰度视频格式（定义于SDTV标准中）和BT-709 高清晰度视频格式（定义于HDTV标准中）。针对模型输入的图片或视频，当前给出标清和高清之间的色域转换矩阵。

- 601 yuv标清转rgb高清系数

```
matrix_r0c0: 1192
matrix_r0c1: 0
matrix_r0c2: 1634
matrix_r1c0: 1192
matrix_r1c1: -400
matrix_r1c2: -833
matrix_r2c0: 1192
matrix_r2c1: 2066
matrix_r2c2: 0
input_bias_0: 16
input_bias_1: 128
input_bias_2: 128
output_bias_0: 0
output_bias_1: 0
output_bias_2: 0
```

- 601 yuv标清转rgb标清矩阵系数

```
matrix_r0c0: 1024
matrix_r0c1: 0
matrix_r0c2: 1404
matrix_r1c0: 1024
matrix_r1c1: -344
matrix_r1c2: -716
matrix_r2c0: 1024
matrix_r2c1: 1775
matrix_r2c2: 0
input_bias_0: 16
input_bias_1: 128
input_bias_2: 128
output_bias_0: 16
```



output_bias_1: 16
output_bias_2: 16

- 601 yuv高清转rgb标清矩阵系数

matrix_r0c0: 880
matrix_r0c1: 0
matrix_r0c2: 1233
matrix_r1c0: 880
matrix_r1c1: -302
matrix_r1c2: -629
matrix_r2c0: 880
matrix_r2c1: 1599
matrix_r2c2: 0
input_bias_0: 0
input_bias_1: 128
input_bias_2: 128
output_bias_0: 16
output_bias_1: 16
output_bias_2: 16

- 601 yuv高清转rgb高清矩阵系数

matrix_r0c0: 1024
matrix_r0c1: 0
matrix_r0c2: 1436
matrix_r1c0: 1024
matrix_r1c1: -352
matrix_r1c2: -731
matrix_r2c0: 1024
matrix_r2c1: 1815
matrix_r2c2: 0
input_bias_0: 0
input_bias_1: 128
input_bias_2: 128
output_bias_0: 0
output_bias_1: 0
output_bias_2: 0

- 709 yuv标清转rgb高清矩阵系数

matrix_r0c0: 1192
matrix_r0c1: 0
matrix_r0c2: 1836
matrix_r1c0: 1192
matrix_r1c1: -218
matrix_r1c2: -547
matrix_r2c0: 1192
matrix_r2c1: 2166
matrix_r2c2: 0
input_bias_0: 16
input_bias_1: 128
input_bias_2: 128
output_bias_0: 0
output_bias_1: 0
output_bias_2: 0

- 709 yuv高清转rgb高清矩阵系数

matrix_r0c0: 1024
matrix_r0c1: 0
matrix_r0c2: 1613
matrix_r1c0: 1024
matrix_r1c1: -192
matrix_r1c2: -479
matrix_r2c0: 1024
matrix_r2c1: 1900
matrix_r2c2: 0
input_bias_0: 0
input_bias_1: 128
input_bias_2: 128
output_bias_0: 0
output_bias_1: 0
output_bias_2: 0



- 709 yuv标清转rgb标清矩阵系数

```
matrix_r0c0: 1024
matrix_r0c1: 0
matrix_r0c2: 1578
matrix_r1c0: 1024
matrix_r1c1: -187
matrix_r1c2: -470
matrix_r2c0: 1024
matrix_r2c1: 1861
matrix_r2c2: 0
input_bias_0: 16
input_bias_1: 128
input_bias_2: 128
output_bias_0: 16
output_bias_1: 16
output_bias_2: 16
```

- 709 yuv高清转rgb标清矩阵系数

```
matrix_r0c0: 880
matrix_r0c1: 0
matrix_r0c2: 1385
matrix_r1c0: 880
matrix_r1c1: -164
matrix_r1c2: -413
matrix_r2c0: 880
matrix_r2c1: 1634
matrix_r2c2: 0
input_bias_0: 0
input_bias_1: 128
input_bias_2: 128
output_bias_0: 16
output_bias_1: 16
output_bias_2: 16
```

依赖约束：对于Hi3516CV610芯片，只有yuv格式输入支持csc配置；其它格式配置后不生效。

3.2.4.1.2.6 减均值乘系数配置说明

功能说明：减均值、乘系数；均值和系数的通道顺序为按model_format做完通道数据交换后的顺序。由于量化模块需感知均值和系数，因而动态AIPP在量化场景下，也需要配置，配置为在线时典型均值和系数值（注：如果配置的值，和动态AIPP在线传入的值差异较大，可能导致量化误差）。

计算规则： $\text{pixel_out_chx}(i) = [\text{clip}(\text{pixel_in_chx}(i), \text{min_chn_i}) - \text{mean_chn_i}] * \text{var_reci_chn}$

关联参数：无

相关参数：

- mean_chn_0, mean_chn_1, mean_chn_2, mean_chn_3

功能说明：每个通道的均值，可选。

参数类型：float32

取值范围：[-65504.0, 65504.0]

示例：

```
mean_chn_0: 0
mean_chn_1: 0
mean_chn_2: 0
mean_chn_3: 0
```

- var_reci_chn_0, var_reci_chn_1, var_reci_chn_2, var_reci_chn_3

功能说明：每个通道的方差的倒数，可选。



参数类型: float32

取值范围: [0, 65504]

示例:

```
var_recn_chn_0: 1.0
var_recn_chn_1: 1.0
var_recn_chn_2: 1.0
var_recn_chn_3: 1.0
```

- min_chn_0, min_chn_1, min_chn_2, min_chn_3

功能说明: 每个通道的最小值。

参数类型: float32

取值范围: [-65504.0, 65504.0]

示例:

```
min_chn_0: 0
min_chn_1: 0
min_chn_2: 0
min_chn_3: 0
```

依赖约束: 当input_format参数为FM时, 只使用第一组通道系数; 当输入大于4维时, 可只配置一组通道系数。Hi3516CV610不支持逐通道配置最小值, 只会对所有通道统一使用min_chn_0作为最小值。

3.2.4.1.2.7 原始图像宽高

功能说明: 原始图像的宽度、高度; 静态aipp可选配置, 动态aipp无须配置。

关联参数: 无

参数取值:

- 相关参数值:

src_image_size_w: 原始图像的宽度。

src_image_size_h: 原始图像的高度。

- 参数类型: int32

- 参数值约束:

宽度取值范围为[2,4096]; 高度取值范围为[1,4096], 对于YUV420SP_U8类型的图像, 要求原始图像的宽和高取值是偶数。

请根据实际图片的宽、高配置src_image_size_w和src_image_size_h; 只有crop, resize, padding功能没有开启的场景, src_image_size_w和src_image_size_h才能不配置, 该场景下会取网络模型输入定义的w和h。

在处理RAW_RGGB、RAW_GRGB、RAW_GBRG、RAW_BGGR图像的时候, aipp的原始图像输入的通道数为1, src_img_size_w, src_img_size_h须按照通道数为1的图像进行设置的。进行aipp处理之后, 数据会变成4通道, aipp处理的结果须与--input_shape一致, 因此--input_shape须按照通道数为4的数据进行配置。例如src_image_size_w为256, src_image_size_h为128, crop, resize, padding功能没有开启, 则--input_shape的shape配置为1,4,64,128。RAW输入的其他处理规则请见[AIPP规格约束](#)。

示例:

```
src_image_size_w: 16
src_image_size_h: 16
```

依赖约束: 无



3.2.4.1.2.8 最大图像宽高

功能说明：输入图像的最大宽度、高度；静态aipp无须配置，动态aipp必须配置。

关联参数：无

参数取值：

- 相关参数值：
max_src_image_size_w: 最大输入图像的宽度。
max_src_image_size_h: 最大输入图像的高度。
- 参数类型：int32
- 参数值约束：
宽度取值范围为[2,4096]；高度取值范围为[1,4096]，对于YUV420SP_U8类型的图像，要求原始图像的宽和高取值是偶数。

示例：

```
max_src_image_size_w: 16  
max_src_image_size_h: 16
```

依赖约束：无

3.2.4.1.2.9 crop 配置说明

功能说明：AIPP处理时是否支持抠图，静态aipp可选配置，动态aipp无须配置。

关联参数：无

相关参数：

- crop
功能说明：crop转换开关，静态AIPP配置。
参数类型：bool
取值范围：true/false，true表示开启crop，false表示关闭；
示例：

```
crop: false
```
- load_start_pos_w, load_start_pos_h
功能说明：抠图起始位置水平、垂直方向坐标，抠图大小为网络输入定义的w和h。
参数类型：int32
取值范围：[0,4095]；load_start_pos_w<src_image_size_w，
load_start_pos_h<src_image_size_h；
示例：

```
load_start_pos_w: 0  
load_start_pos_h: 0
```
- crop_size_w, crop_size_h
功能说明：抠图后的图像size。
参数类型：int32
取值范围：[0,4096]；load_start_pos_w + crop_size_w <= src_image_size_w、
load_start_pos_h + crop_size_h <= src_image_size_h；



示例：

```
crop_size_w: 16
crop_size_h: 16
```

依赖约束：仅支持shape维度为4

3.2.4.1.2.10 resize 配置说明

功能说明：AIPP处理时是否支持缩放，静态aipp可选配置，动态aipp无须配置。

关联参数：无

相关参数：

- **resize**

功能说明：resize转换开关，静态AIPP配置。

参数类型：bool

取值范围：true/false，true表示开启resize，false表示关闭。

示例：

```
resize: false
```

- **resize_mode**

功能说明：缩放的方式，静态AIPP配置。

参数类型：enum

取值范围：

对于Hi3519DV500芯片，取值范围为：nearest, linear_vector, linear_cube。其中linear_vector和linear_cube都是双线性插值，区别在于linear_vector使用vector逻辑单元进行处理，而linear_cube使用cube逻辑单元进行处理。

备注：若linear不满足使用cube逻辑单元的条件，但是强制配置为linear_cube，会回退为linear_vector。linear_cube条件请参考前文描述。

对于Hi3516CV610，取值范围为：nearest, linear。

示例：

```
resize_mode: nearest
```

- **resize_input_w, resize_input_h, resize_output_w, resize_output_h**

功能说明：缩放后和缩放前图像的宽度和高度。

参数类型：int32

取值范围：resize_output_h: [16,4096]; resize_output_w: [16,1920];
resize_output_w/resize_input_w ∈ [1/16,16]、resize_output_h/resize_input_h ∈ [1/16,16];

示例：

```
resize_input_w: 16
resize_input_h: 16
resize_output_w: 32
resize_output_h: 32
```

- **coordinate_trans_mode**

功能说明：坐标轴转换的方式。

参数类型：enum

参数默认值：align_corners

取值范围：静态AIPP，resize_mode为linear_vector, linear_cube支持half_pixel, pytorch_half_pixel, asymmetric, align_corners；动态AIPP支持asymmetric,



align_corners。其中asymmetric模式与opencv的双线性插值对应，pytorch_half_pixel模式与pytorch的resize对应。

示例：

```
coordinate_trans_mode : align_corners
```

依赖约束：仅支持shape维度为4

3.2.4.1.2.11 padding 配置说明

功能说明：AIPP处理时是否支持padding，静态aipp可选配置，动态aipp无须配置。

关联参数：无

相关参数：

- padding

功能说明：padding转换开关，静态AIPP配置。

参数类型：bool

取值范围：true/false，true表示开启padding，false表示关闭。

示例：

```
padding: false
```

- padding_mode

功能说明：padding的方式，静态AIPP配置。

参数类型：enum

取值范围：

- const_zero：常量填充。
- duplicate：复制填充。(对于Hi3516CV610芯片，当input_format为RGB_PACKAGE、BGR_PACKAGE、RAW_RGGB、RAW_GRBG、RAW_GBRG、RAW_BGGR、UVSP、VUSP时不支持)
- reflection：镜像填充（Hi3516CV610芯片不支持）。
- symmetric：对称填充（Hi3516CV610芯片不支持）。

示例：

```
padding_mode: const_zero
```

- left_padding_size, right_padding_size, top_padding_size, bottom_padding_size

功能说明：H和W的填充值，静态AIPP配置，上下左右四个值不能缺省。

参数类型：int32

取值范围：[0,15]。（对于Hi3516CV610芯片，当input_format为RGB_PACKAGE、BGR_PACKAGE时，left_padding_size和right_padding_size的取值范围为[0,5]）

示例：

```
left_padding_size: 0
right_padding_size: 0
top_padding_size: 0
bottom_padding_size: 0
```

参数值约束：

padding模式为reflection时，H和W的填充值需小于填充前的H和W；padding模式为symmetric时，H和W的填充值需不大于填充前的H和W；

依赖约束：仅支持shape维度为4。



3.2.4.1.3 静态 AIPP 配置项

图像预处理的配置以aipp_op开始，标识这是AIPP算子的配置。

```
aipp_op {
  aipp_mode: static
  related_input_rank: 0
  input_format: BGR_PLANAR
  model_format: BGR

  src_image_size_w: 16
  src_image_size_h: 16

  # crop参数设置
  crop: false
  load_start_pos_w: 0
  load_start_pos_h: 0
  crop_size_w: 16
  crop_size_h: 16

  # resize参数设置
  resize: false
  resize_mode: nearest
  resize_input_w: 16
  resize_input_h: 16
  resize_output_w: 32
  resize_output_h: 32

  # padding参数设置
  padding: false
  padding_mode: const_zero
  left_padding_size: 0
  right_padding_size: 0
  top_padding_size: 0
  bottom_padding_size: 0
  # 色域转换开关，静态AIPP配置
  csc_switch: false
  matrix_r0c0: 298
  matrix_r0c1: 516
  matrix_r0c2: 0
  matrix_r1c0: 298
  matrix_r1c1: -100
  matrix_r1c2: -208
  matrix_r2c0: 298
  matrix_r2c1: 0
  matrix_r2c2: 409
  output_bias_0: 16
  output_bias_1: 128
  output_bias_2: 128
  input_bias_0: 16
  input_bias_1: 128
  input_bias_2: 128

  # 减均值、乘系数设置
  mean_chn_0: 0
  mean_chn_1: 0
  mean_chn_2: 0
  mean_chn_3: 0
  var_reci_chn_0: 1.0
  var_reci_chn_1: 1.0
  var_reci_chn_2: 1.0
  var_reci_chn_3: 1.0
  min_chn_0: 0
  min_chn_1: 0
  min_chn_2: 0
  min_chn_3: 0
}
```



示例:

下面以插入图像预处理算子为例进行说明，静态配置文件内容示例如下（文件名为举例为：*insert_op.cfg*）。

```
aipp_op {
#第一个输入
    related_input_rank:0
    aipp_mode:static
    input_format:YUV420SP
    model_format:RGB
    # 以pytorch的预处理为例，如torchvision.transforms.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229,
0.224, 0.225]),
    # 即  $y = (x/255 - \text{mean})/\text{std} = (x - 255*\text{mean}) * 1/(255*\text{std})$ 
    # 所以  $\text{mean\_chn\_x} = 255*\text{mean}$ ,  $\text{var\_reci\_chn\_x} = 1/(255*\text{std})$ 
    mean_chn_0:123.675
    mean_chn_1:116.28
    mean_chn_2:103.53
    var_reci_chn_0:0.01712475
    var_reci_chn_1:0.017507002
    var_reci_chn_2:0.01742919

# 第二个输入
    related_input_rank:1
    input_format:RGB_PLANAR
    model_format:BGR
    # 以Caffe 的ImageData层预处理为例:
    #transform_param {
    #    scale: 0.0078125
    #    mean_value: 104.0
    #    mean_value: 117.0
    #    mean_value: 123.0
    #}
    # 即  $y = (x - \text{mean\_value}) * \text{scale}$ ,
    # 所以  $\text{mean\_chn\_x} = \text{mean\_value}$ ,  $\text{var\_reci\_chn\_x} = \text{scale}$ 
    mean_chn_0:104
    mean_chn_1:117
    mean_chn_2:126
    var_reci_chn_0:0.0078125
    var_reci_chn_1:0.0078125
    var_reci_chn_2:0.0078125
}
```

3.2.4.1.4 动态 AIPP 配置项

```
# 图像预处理的配置以aipp_op开始，标识这是AIPP算子的配置。
aipp_op {
    aipp_mode: dynamic
    related_input_rank: 0
    input_format : BGR_PLANAR
    model_format : BGR
    max_src_image_size_w:16
    max_src_image_size_h:16
    #说明: 可通过命令行--input_csc_enable=OFF,--input_channel_order_enable=OFF,--input_crop_enable=OFF,--
input_preprocess_enable=OFF, --input_resize_enable=OFF, --input_padding_enable=OFF关闭动态AIPP功能;
    当padding为动态时, 可通过命令行设置--input_padding_info=layername: top_padding_size,
    bottom_padding_size, left_padding_size, right_padding_size设置其最大padding_info信息, 否则为默认值[6,
    6, 6, 6]。
}
```

备注：若使用在线均值方差功能，量化时由于需要感知均值方差，需送入均值方差处理后的数据作为量化输入。

示例:

下面以插入图像预处理算子为例进行说明，动态配置文件内容示例如下（文件名举例为：*insert_op.cfg*）。



```
aipp_op {  
#第一个输入  
    related_input_rank:0  
    aipp_mode:dynamic  
    input_format:YUV420SP  
    model_format:RGB  
    max_src_image_size_w:16  
    max_src_image_size_h:16  
#第二个输入  
    related_input_rank:1  
    aipp_mode:dynamic  
    input_format:YUV420SP  
    model_format:RGB  
    max_src_image_size_w:16  
    max_src_image_size_h:16  
}
```

3.2.4.2 --input_csc_enable

功能说明：动态AIPP会开启所有的AIPP功能，如果在线色域转换不需使用，可以通过该选项进行关闭

关联参数：--insert_op_conf

参数取值：

- 参数值：OFF
- 参数值约束：只能为OFF

推荐配置及收益：无

示例：

```
--input_csc_enable=OFF
```

依赖约束：无

3.2.4.3 --input_channel_order_enable

功能说明：动态AIPP会开启所有的AIPP功能，如果在线通道转换不需使用，可以通过该选项进行关闭

关联参数：--insert_op_conf

参数取值：

- 参数值：OFF
- 参数值约束：只能为OFF

推荐配置及收益：无

示例：

```
--input_channel_order_enable=OFF
```

依赖约束：无

3.2.4.4 --input_preprocess_enable

功能说明：动态AIPP会开启所有的AIPP功能，如果在线均方差不需使用，可以通过该选项进行关闭



关联参数: **--insert_op_conf**

参数取值:

- 参数值: OFF
- 参数值约束: 只能为OFF

推荐配置及收益: 无

示例:

```
--input_preprocess_enable=OFF
```

依赖约束: 无

3.2.4.5 --input_resize_enable

功能说明: 动态AIPP会开启所有的AIPP功能, 如果在线resize不需使用, 可以通过该选项进行关闭

关联参数: **--insert_op_conf**

参数取值:

- 参数值: OFF
- 参数值约束: 只能为OFF

推荐配置及收益: 无

示例:

```
--input_resize_enable=OFF
```

依赖约束: 无

3.2.4.6 --input_padding_enable

功能说明: 动态AIPP会开启所有的AIPP功能, 如果在线补边不需使用, 可以通过该选项进行关闭

关联参数: **--insert_op_conf**

参数取值:

- 参数值: OFF
- 参数值约束: 只能为OFF

推荐配置及收益: 无

示例:

```
--input_padding_enable=OFF
```

依赖约束: 无

3.2.4.7 --input_crop_enable

功能说明: 动态AIPP会开启所有的AIPP功能, 如果在线裁剪不需使用, 可以通过该选项进行关闭

关联参数: **--insert_op_conf**



参数取值：

- 参数值：OFF
- 参数值约束：只能为OFF

推荐配置及收益：无

示例：

```
--input_crop_enable=OFF
```

依赖约束：无

3.2.4.8 --input_padding_info

功能说明：指定动态AIPP Padding的最大可能补边数。

关联参数：--insert_op_conf

参数取值：

- 参数值：格式为
op_name:top_padding_size,bottom_padding_size,left_padding_size,right_paddi
ng_size
- 参数值约束：padding的范围为[0,15]
- 参数默认值：默认[6,6,6,6]

推荐配置及收益：无

示例：

```
--input_padding_info="data0:2,2,2,2"
```

依赖约束：无

3.2.4.9 --image_data_bits

功能说明：指定输入RAW图像格式的数据位宽。

关联参数：--insert_op_conf 配置Data层输入为RAW图像格式，即input_format为RAW_RGGB、RAW_GRBG、RAW_GBRG、RAW_BGGR，此配置才生效。

参数取值：

- 参数值：
 - Hi3519DV500: {8,10,12,14,16}
 - Hi3516CV610: {8}
- 参数值约束：所有RAW图像格式输入共用1个配置。
- 参数默认值：8。

推荐配置及收益：无

示例：

```
--image_data_bits=8
```

依赖约束：无



3.2.4.10 --bit_compact_layer

功能说明：指定输入YUV400图像格式的是否为4bit紧密排布。

关联参数：[--insert_op_conf](#) 配置Data层输入为YUV400图像格式，即input_format为YUV400，此配置才生效。

参数取值：

- 参数值：字符串。网络模型中的节点（node_name）名称
- 参数默认值：不使能。

推荐配置及收益：无

示例：

```
--bit_compact_layer="data0;data1"
```

依赖约束：Hi3516CV610不支持。

3.2.4.11 --input_type

功能说明：指定网络Data层的输入数据类型，只用于Feature map 输入的Data层，不能用于图片输入的Data层。

关联参数：[--insert_op_conf](#)未配置Data层输入为图片格式，即输入为Feature map 时，才可以指定输入数据类型。

参数取值：

- 参数值：格式为op_name:data_type
 - op_name：指定算子的层名，必须为Data层。
 - data_type：支持数据类型FP16, FP32, INT16, INT8, S16, S8, U16, U8, UINT16, UINT8。
- 参数值约束：指定多个输入数据类型时，使用英文分号隔开，用双引号括住。如：--input_type="data0:INT8;data1:FP16"。
- 参数默认值：Feature map未指定数据类型时，默认FP32。

推荐配置及收益：无

示例：

```
--input_type="data0:INT8;data1:FP16"
```

依赖约束：无

3.2.4.12 --input_shape

功能说明：指定模型输入数据的shape。

关联参数：[--dynamic_image_size](#)

参数取值：

- 参数值：
模型输入的shape信息，例如：
"input_name1:n1,c1,h1,w1;input_name2:n2,c2,h2,w2"。指定的节点必须放在双



引号中，节点中间使用英文分号分隔。input_name必须是转换前的网络模型中的节点名称。

当某个输入需要支持动态分辨率时，需要将其h、w设置为-1。

- 参数值约束：

设置为固定取值，例如，取值为“1，2，3...” ，用于将输入数据某个维度不固定的原始模型转换为固定维度的离线模型。

推荐配置及收益：无

示例：

```
--input_shape="input_name1:n1,c1,h1,w1;input_name2:n2,c2,h2,w2"
```

依赖约束：input_shape需要与image_list的量化校准文件数据匹配。

3.2.4.13 --input_format

功能说明：输入数据格式。

关联参数：无

参数取值：

- 参数值：只支持NCHW。
- 参数默认值：默认为NCHW。
- 参数值约束：无

推荐配置及收益：无

示例：

```
--input_format=NCHW
```

依赖约束：无

3.2.5 模型输出选项

3.2.5.1 --output_type

功能说明：指定网络输出数据类型或指定输出节点的输出类型。

关联参数：

若指定某个输出节点的输出类型，则需要和--out_nodes参数配合使用。

参数取值：

- 参数值：支持两种格式。

格式1：data_type, 表示指定所有输出节点的输出数据类型。

格式2：op_name:output_index:data_type, 表示指定某个输出节点的某个输出的输出数据类型。

- op_name：指定算子的层名，必须为--out_nodes指定的输出层。
- output_index：指定输出层的第几个输出。
- data_type：支持数据类型FP16, FP32, INT16, INT8, S16, S8, U16, U8, UINT16, UINT8。



- 参数默认值：FP32

推荐配置及收益：无

示例：

- 指定网络输出类型
`--output_type=FP32`
- 指定某个输出节点的输出类型
`output_type="conv1:0:FP32" --out_nodes="conv1:0"`

依赖约束：AICPU算子只支持输出FP32。

3.2.5.2 --out_nodes

功能说明：指定输出节点。当用户想要查看网络中间某层算子的输出时，则需要指定输出此算子。模型的最后一层默认输出，不需要指定。

关联参数：无

参数取值：

- 参数值：
 - 网络模型中的节点（node_name）名称。
 - 指定的输出节点必须放在双引号中，节点中间使用英文分号分隔。node_name必须是模型转换前的网络模型中的节点名称，冒号后的数字表示第几个输出，例如node_name1:0，表示节点名称为node_name1的第1个输出。
- 参数值约束：
 - 如果模型转换过程中该算子被离线计算融合掉，则该算子不能作为输出节点，配置不生效。
 - 没有实际运算而被优化删除的算子，不能作为输出节点，配置不生效。如Cast, Dropout算子。
 - 配置的输出节点的顺序与最后输出的顺序无关。
 - 即使最后一层的节点没有被指定，也一定会被输出。
 - 支持最大输入节点和输出节点加起来不能超过32个。

推荐配置及收益：无

示例：

参数值取网络模型中的节点（node_name）名称。

```
--out_nodes="node_name1:0;node_name1:1;node_name2:0"
```

依赖约束：无

3.2.5.3 --image_report_name

功能说明：指定网络某个输出为图像格式。

关联参数：[--out_nodes](#)，[--image_report_bit](#)，[--image_report_type](#)。

参数取值：指定网络输出算子的层名，必须为--out_nodes指定的输出层。

参数值约束：不能配置为data层或preprocessMerge的算子层。



推荐配置及收益：无

示例：

指定conv1输出，且为12bit的RGGB图像格式

```
--out_nodes=conv1:0 --image_report_name=conv1 --image_report_bit=12 --image_report_type=RGGB
```

3.2.5.4 --image_report_bit

功能说明：指定输出RAW图像格式的数据位宽。

关联参数：**--image_report_type** 配置为RGGB、GRBG、GBRG、BGGR时此配置才生效。

参数取值：

- 参数值：8, 10, 12, 14, 16
- 参数默认值：8

推荐配置及收益：无

依赖约束：Hi3516CV610不支持参数值为10或者14。

示例：

指定conv1输出，且为12bit的RGGB图像格式

```
--out_nodes=conv1:0 --image_report_name=conv1 --image_report_bit=12 --image_report_type=RGGB
```

3.2.5.5 --image_report_type

功能说明：图像格式输出的类型

关联参数：**--out_nodes**, **--image_report_name**, **--image_report_bit**, **--output_rgb_order**, **RGB_order**

参数取值：

- 参数值：RGGB、GRBG、GBRG、BGGR、UVSP、VUSP、YUV400、BGR_PLANAR、RGB_PLANAR、RGB_PACKAGE、BGR_PACKAGE、XRGB_PLANAR、XBGR_PLANAR、RGBX_PLANAR、BGRX_PLANAR、XRGB_PACKAGE、XBGR_PACKAGE、RGBX_PACKAGE、BGRX_PACKAGE
- 参数默认值：RGGB
- 参数值约束：
 - 1.图像输出时shape必须为4d。
 - 2.若图像输出为YUV400，要求输出channel为1；
若图像输出为UVSP，VUSP，要求输出channel为2；
若图像输出为 BGR_PLANAR，RGB_PLANAR，RGB_PACKAGE，BGR_PACKAGE，要求输出channel为3；
其他输出格式要求输出channel为4。
 - 3.参数值必须与RGB_order或--output_rgb_order相匹配，详见RGB_order和--output_rgb_order。
Hi3516CV610仅支持RGGB、GRBG、GBRG、BGGR。

推荐配置及收益：无

示例：



指定conv1输出，且为12bit的RGGB图像格式

```
--out_nodes=conv1:0 --image_report_name=conv1 --image_report_bit=12 --image_report_type=RGGB --output_rgb_order=RGGB
```

3.2.5.6 --output_rgb_order

功能说明：模型输出数据做通道转换前的通道顺序。

关联参数：[--image_report_type](#)

参数取值：

- 参数值：字符串。取值范围{RGB、BGR、XRGB、RGBX、XBGR、BGRX、RGGB、GRBG、GBRG、BGGR}
- 参数默认值：RGB

参数值约束：

- 配置值需和image_report_type的类型匹配：
UVSP、VUSP、BGR_PLANAR、RGB_PLANAR、RGB_PACKAGE、BGR_PACKAGE可取值范围为RGB、BGR；
XRGB_PLANAR、XBGR_PLANAR、RGBX_PLANAR、BGRX_PLANAR、XRGB_PACKAGE、XBGR_PACKAGE、RGBX_PACKAGE、BGRX_PACKAGE可取值范围为XRGB、XBGR、RGBX、BGRX
RAW_RGGB、RAW_GRBG、RAW_GBRG、RAW_BGGR可取值范围为RGGB、GRBG、GBRG、BGGR
YUV400忽略此配置。
- 多个输出时，共用一个配置。
- 不能与[RGB_order](#)同时配置。
- Hi3516CV610仅支持RGGB、GRBG、GBRG、BGGR。

推荐配置及收益：无

示例：

```
[output_rgb_order] RGB
```

依赖约束：image_report_type配置时才生效。

3.2.5.7 --output_reorder

功能说明：转换后的模型输出节点顺序和原始模型是否保持一致。

关联参数：无

参数取值：

- 参数值：[0,1]
 - 0：转换后的模型输出节点与原始模式保持一致。
 - 1：转换后的模型输出节点重新排列，与原始模式可能不一致。
- 参数默认值：1

示例：

```
--output_reorder=1
```



依赖约束：无

3.2.6 量化选项

3.2.6.1 --gfpq_param_file

功能说明：GFPQ(Grouped Floating Point Quantization)分组量化参数配置文件。AMCT校准或retrain输出此文件，如quant_param_record.txt。ATC转换模型校准时输出此文件，如calibration_param.txt。

关联参数：

--model：当输入模型为定点模型时，必须配置此参数。定点模型即AMCT校准后输出权重参数为定点的模型。

参数取值：参数值：protobuf格式的文件路径，支持txt和bin格式。

文件格式定义：Proto定义

```
syntax = "proto2";
package calibration;
enum DataType {
    S4 = 0;
    U4 = 1;
    S8 = 2;
    U8 = 3;
    S16 = 4;
    U16 = 5;
    F16 = 6;
    S32 = 7;
    U32 = 8;
    F32 = 9;
}

message FactorParam
{
    required DataType data_type = 1 [default = S8];
    repeated float scale = 2;
    repeated float offset = 3;
    optional bytes params = 4;
}

message QuantParam
{
    repeated FactorParam input = 1;
    optional FactorParam weight = 2;
}

message LayerParam
{
    required string name = 1;
    optional DataType calc_data_type = 2 [default = S8];
    required QuantParam quant_param = 3;
}

message CalibrationParam
{
    optional uint32 version = 1 [default = 65536];
    repeated LayerParam layer = 2;
}
```



示例：

```
version: 65536
layer {
  name: "conv1"
  calc_data_type: S8
  quant_param {
    input {
      data_type: S8
      scale: 12.75
      offset: -77
    }
    weight {
      data_type: S8
      scale: 127
    }
  }
}
```

推荐配置及收益：

- 配置量化参数后，ATC不需要再校准，节省转换模型的时间。
- 使用AMCT重训或校准后的quant_param_record.txt，精度更好。

示例：

```
--gfpq_param_file=quant_param_record.txt
```

依赖约束：Hi3516CV610不支持VEC层配置高精度。

3.2.6.2 --image_list

功能说明：转换模型生成量化参数时用的校准数据。支持Feature map文本和二进制格式文件和图片格式文件。

关联参数：

- **--model**：当输入模型为定点模型时，不需要配置此参数。
- **--gfpq_param_file**：配置了所有层的量化参数时，不需要配置此参数。已配置量化参数的层，不校准，只使用image_list做forward。
- **--dump_data**：需要导出校准数据时，必须配置此参数。
- **--input_type**：校准数据使用二进制文件时，需要文件的数据类型和--input_type匹配，如果没有配置，默认FP32。
- **--insert_op_conf**：配置了图像预处理的Data层使用图片文件格式，没有则使用Feature map格式。

参数取值：

- 参数值：输入的层名和校准数据的文件路径。
- 参数值格式：多输入时，使用半角分号“;”隔开，用双引号括住。示例：
--image_list="name1:file1;name2:file2"
此外，多输入时，也可以使用多个image_list分别输入。示例：
--image_list="name1:file1"
--image_list="name2:file2"
- 文件格式：



- --insert_op_conf没有配置图像预处理时，即输入为Feature map。
 - 文本文件：

文件内容为浮点文本数据，数据间以空格或逗号分隔，一行的数据个数为输入形状channel × height × width。一行表示一个batch。示例：

输入形状 3×2×2，4个batch。即一行12个数据，共4行。

feature_map.txt:

```
1 2 3 4 5 6 7 8 9 10 11 12
0.46 0.05 -0.01 -0.20 -7 -0.6114 -0.12 0.87 0.553 -0.67 -0.027 0.164082
-0.367 0.373 0.99 -0.0820 0.04 -0.454 -0.311 0.52 -0.033 -0.3 0.731473 0.09
-0.012 0.928 -0.903 0.374 0.7 0.4 -0.48 -0.490 0.473455 -0.146 -0.83 -0.637
```
 - 二进制文件：

文件内容为数据值的二进制，文件名必须以“.bin”为后缀。数据类型需要和--input_type匹配。
- --insert_op_conf配置图像预处理，即输入为图片时，文件内容为图片文件路径，一行一个图片文件路径，一行表示一个batch。图片大小不限，ATC根据输入的height × width缩放。

图片文件路径支持以下三种。

- i. 绝对路径；
- ii. 相对--image_list的路径；
- iii. 相对ATC执行的路径。

示例：testcase/image_list.txt，3个batch配置3个图片文件。

```
/home/xxx/testcase/images/test_1.jpg
images/test_2.png
testcase/images/test_3.bmp
```

--insert_op_conf图像预处理配置的input_format为YUV420SP、YVU420SP、YUV422SP、YVU422SP、YUV400、YUV444SP、YVU444SP、BGR_PLANAR、RGB_PLANAR、RGB_PACKAGE、BGR_PACKAGE、XRGB_PLANAR、ARGB_PLANAR、XBGR_PLANAR、ABGR_PLANAR、RGBX_PLANAR、RGBA_PLANAR、BGRX_PLANAR、BGRA_PLANAR、XRGB_PACKAGE、ARGB_PACKAGE、XBGR_PACKAGE、ABGR_PACKAGE、RGBX_PACKAGE、RGBA_PACKAGE、BGRX_PACKAGE、BGRA_PACKAGE时，使用图片路径文本格式，支持图片后缀bmp、jpeg、jpg、jpe、jp2、png。

--insert_op_conf图像预处理配置的input_format为RAW_RGGB、RAW_GRGB、RAW_GBRG、RAW_BGGR时，使用浮点文本格式，数据排列格式为RAW图像通道拆分前的顺序。

示例：输入4×2×2的RAW_RGGB，通道拆分前的顺序：

```
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16
```

通道拆分后的数据：

```
1 3 9 11 2 4 10 12 5 7 13 15 6 8 14 16
```

即：

```
Channel_0:1 3 9 11
Channel_1:2 4 10 12
Channel_2:5 7 13 15
Channel_3:6 8 14 16
```

通过image_type配置输入数据类型时，image_type为0，18，19，20，21，24，25时输入文件内容为浮点文本数据，其他情况下输入文件内容为图片文件路径。



推荐配置及收益：校准时需要的图片是典型场景图片，建议从网络模型的测试场景随机选择3~5张作为参考图片进行量化，选择的图像要尽量覆盖模型的各个场景（图像要包含分类或检测的目标，如分类网的目标是苹果、梨、桃子，则参考图像至少要包含苹果、梨、桃子。比如检测人、车的模型，参考图像中必须有人、车，不能仅使用人或者无人无车的图像进行量化）。图片影响校准生成量化参数，选择典型场景的图片计算出来的量化参数对典型场景的量化误差越小。所以请不要选择偏僻场景、过度曝光、纯黑、纯白的图片，请选择识别率高，色彩均匀的典型场景图片。

示例：

```
--image_list=" data1:feature_map.txt;data2:images.txt"
```

依赖约束：无

3.2.6.3 --compile_mode

功能说明：编译模式，量化后的数据bit位宽，参数值0和1不影响权重量化的bit位宽，权重固定是8bit量化。参数值3和4将权重量化成4bit，以用于整网的性能测试，实际使用时需要4bit重训。

关联参数：

--gfpq_param_file：优先使用配置的量化参数。未配置量化参数时，compile_mode才生效。

参数取值：

- 参数值
 - 0：A8W8，使用8bit量化数据和权重。
 - 1：A16W8，使用16bit量化数据，使用8bit量化权重。
 - 2：预留值。
 - 3：A4W4，使用4bit量化数据和权重，该参数值用于测试整网A4W4的性能。Hi3519DV500不支持配置该值。
 - 4：A8W4，使用8bit量化数据，使用4bit量化权重，该参数值用于测试整网A8W4的性能。Hi3519DV500不支持配置该值。
 - 5：数据和权重量化使用8bit，且仅对CUBE算子进行量化，非CUBE算子使用fp16格式。
 - 6：数据量化使用16bit，权重量化使用8bit，且仅对CUBE算子进行量化，非CUBE算子使用fp16格式。

CUBE算子：

Conv,ConvTranspose,DepthwiseConv,InnerProduct,Gemm,MatMul,Pooling系列算子。

- 参数值约束：无
- 参数默认值：0

推荐配置及收益：

- 配置为0时，带宽小，板端缓存小，耗时少，精度损失大。
- 配置为1时，带宽大，板端缓存大，耗时大，精度损失小。
- 配置为5时，带宽、板端缓存、耗时比模式0大，比模式1和6小；精度损失比模式0小，与模式1相比则和网络结构相关，若网络中含有大量的非CUBE算子，则此模式可能精度损失更小。



- 配置为6时，带宽大，板端缓存大，耗时大，精度损失很小。

示例：

```
--compile_mode=0
```

依赖约束：无

3.2.6.4 --weight_quant_per_channel

功能说明：权重是否每个卷积单独量化，对应一组量化参数。只有Convolution和Deconvolution 支持。

关联参数：

--gfpq_param_file：优先使用配置的量化参数。未配置量化参数时, --weight_quant_per_channel才生效。

参数取值：

- 参数值
 - 0：去使能。
 - 1：使能。
- 参数默认值：1

推荐配置及收益：配置为1时，权重量化粒度细，精度更好。

示例：

```
--weight_quant_per_channel=1
```

依赖约束：无

3.2.6.5 --quant_mode

功能说明：量化算法模式

- 参数取值：
 - 0：使用默认量化算法，linear_quant
 - 1：数据和权重使用不同的量化算法，其中数据使用ifmr算法进行量化，权重使用arq算法进行量化
- 参数值约束：无
- 参数默认值：0

示例：

```
--quant_mode=0
```

依赖约束：无

3.2.6.6 --high_precision_layer

功能说明：高精度层配置。如果配置的层是CUBE算子，该算子会进行量化，数据量化使用16bit，权重量化使用8bit，如果是非CUBE算子，则使用fp16格式。

CUBE算子：

Conv,ConvTranspose,DepthwiseConv,InnerProduct,Gemm,MatMul,Pooling系列算子。



- 参数取值：字符串。网络模型中的节点（node_name）名称的集合。
- 推荐配置及收益：无
- 示例：其中opName0、opName1、opName2为需要配置的节点在网络模型中的名称

```
--high_precision_layer=opName0;opName1;opName2
```

3.2.6.7 --concat_auto_fallback_to_fp16

功能说明：当concat多路输入的数值范围差距较大时，进行量化可能会增大量化误差，此时将concat的量化类型自动回退成fp16，防止量化误差增大。

关联参数：无

参数取值：

- 参数值：
 - 0：去使能
 - 1：使能
- 参数默认值：1

推荐配置及收益：配置为1时，可避免因concat多路输入数值范围差距大引起的量化误差。

示例：

```
--concat_auto_fallback_to_fp16=1
```

依赖约束：Hi3519DV500不支持

3.2.6.8 --output_quantized

功能说明：当--output_type配置为S8、U8、S16或者U16的时候是否做量化。

关联参数：[--gfpq_param_file](#)：配置量化参数时，--output_quantized不生效。

参数取值：

- 参数值：
 - 0：去使能
 - 1：使能
- 参数默认值：0

示例：

```
--output_quantized=1
```

依赖约束：Hi3516CV610不支持

3.2.6.9 --all_batch_quant_together_enable

功能说明：量化时，是否所有batch一起进行量化参数计算。

参数取值：

- 参数值：



- 0: 去使能
- 1: 使能
- 参数默认值: 0

示例:

```
--all_batch_quant_together_enable=1
```

3.2.7 RPN 硬化层选项

3.2.7.1 --nms_threshold

功能说明: Nms层阈值, 只用于ATC量化校准时的RPN硬化层, 板端推理时不使用此值。仅Hi3519DV500 YOLOV3/V4/V5/V7支持配置多个nms_threshold阈值, 且最大支持80类阈值配置, 当配置多个阈值时, 启动多类别多阈值功能。

关联参数: 无

参数取值:

- 参数值: [0,1)
- 参数默认值: 0.75

推荐配置及收益: 无

示例:

```
--nms_threshold=0.75  
6个类别: --nms_threshold=0.1,0.2,0.3,0.4,0.5,0.6
```

依赖约束: 无

3.2.7.2 --low_score_threshold

功能说明: Filter层最低分数阈值, 只用于ATC量化校准时的RPN硬化层, 板端推理时不使用此值。仅Hi3519DV500 YOLOV3/V4/V5/V7支持配置多个low_score_threshold阈值, 且最大支持80类阈值配置, 当配置多个阈值时, 启动多类别多阈值功能。

关联参数: 无

参数取值:

- 参数值: [0,1)
- 参数默认值: 0.5

推荐配置及收益: 无

示例:

```
--low_score_threshold=0.5  
6个类别: --low_score_threshold=0.5,0.5,0.5,0.5,0.5,0.5
```

依赖约束: 无



3.2.7.3 --min_width

功能说明：Filter层最低宽度阈值。仅19DV500 YOLOV3/V4/V5/V7支持配置多个min_width阈值，且最大支持80类阈值配置，当配置多个阈值时，启动多类别多阈值功能。

关联参数：无

参数取值：

- 参数值：[1,4096]
- 参数默认值：1

推荐配置及收益：无

示例：

```
--min_width=1  
6个类别: --min_width=1,1,1,1,1,1
```

依赖约束：无

3.2.7.4 --min_height

功能说明：Filter层最低高度阈值。仅Hi3519DV500 YOLOV3/V4/V5/V7支持配置多个min_height阈值，且最大支持80类阈值配置，当配置多个阈值时，启动多类别多阈值功能。

关联参数：无

参数取值：

- 参数值：[1,4096]
- 参数默认值：1

推荐配置及收益：无

示例：

```
--min_height=1  
6个类别: --min_height=1,1,1,1,1,1
```

依赖约束：无

3.2.7.5 --image_width

功能说明：

网络包含RPN硬化层，输入为Feature map，不是图片时，需指定原图的宽。

关联参数：无

参数值：[1,4096]

推荐配置及收益：无

示例：

```
--image_width=224
```

依赖约束：无



3.2.7.6 --image_height

功能说明：网络包含RPN硬化层，输入为Feature map，不是图片时，需指定原图的高。

关联参数：无

参数值：[1,4096]

推荐配置及收益：无

示例：

```
--image_height=224
```

依赖约束：无

3.2.7.7 --generate_anchors_file

功能说明：锚点坐标文件。使用硬化层的Faster RCNN、RFCN、SSD网络必须配置。

关联参数：无

参数取值：

- 参数值：anchors文件路径与文件名。
- 参数值格式：路径和文件名：支持大小写字母（a-z, A-Z）、数字（0-9）、下划线（_）、中划线（-）、句点（.）、中文字符。
- 文件内容的格式：

- Faster RCNN和RFCN锚点坐标文件每行内容为“xmin, ymin, xmax, ymax”，如下：

```
-84.000000 -40.000000 99.000000 55.000000
-176.000000 -88.000000 191.000000 103.000000
-360.000000 -184.000000 375.000000 199.000000
-56.000000 -56.000000 71.000000 71.000000
.....
```

请参考samples/2_object_detection/rfcfn/rfcfn_resnet50/caffe_model/anchors.txt

生成anchors.txt的方法，例如Caffe框架在py-faster-rcnn/rpn/proposal_layer.py保存anchors，如下图：

```
93 # Enumerate all shifted anchors:
94 #
95 # add A anchors (1, A, 4) to
96 # cell K shifts (K, 1, 4) to get
97 # shift anchors (K, A, 4)
98 # reshape to (K*A, 4) shifted anchors
99 A = self._num_anchors
100 K = shifts.shape[0]
101 anchors = self._anchors.reshape((1, A, 4)) + \
102         shifts.reshape((1, K, 4)).transpose((1, 0, 2))
103 anchors = anchors.reshape((K * A, 4))
104
105 np.savetxt("anchors.txt", anchors, fmt="%0.6f")
106
```

- SSD锚点坐标文件每行内容为“xmin, ymin, xmax, ymax, var0, var1, var2, var3”，如下：

```
-11.000000 -11.000000 19.000000 19.000000 0.099854 0.099854 0.199951 0.199951
-17.000000 -17.000000 25.000000 25.000000 0.099854 0.099854 0.199951 0.199951
```



```
-17.000000 -6.000000 25.000000 14.000000 0.099854 0.099854 0.199951 0.199951
-6.000000 -17.000000 14.000000 25.000000 0.099854 0.099854 0.199951 0.199951
.....
```

请参考samples/2_object_detection/ssd/caffe_model/anchors.txt

生成anchors.txt方法：例如Caffe框架下保存mbox_priorbox层的输出，再生成anchors，示例python代码如下：

```
import numpy as np
data = np.loadtxt("mbox_priorbox_output0_2_34928_caffe.float")
image_width=300
image_height=300
anchors_num = int(data.size / 8)
data = data.reshape(int(data.size / 4), -1)
boxes = data[ : anchors_num]
boxes[:,0,2] = boxes[:,0,2] * image_width
boxes[:,1,3] = boxes[:,1,3] * image_height
variance = data[ anchors_num : ]
anchors = np.hstack((boxes, variance))
np.savetxt("anchors.txt", anchors, fmt="%0.6f")
```

推荐配置及收益：无

示例：

```
--generate_anchors_file=anchors.txt
```

依赖约束：无

3.2.7.8 --detection_out_accuracy

功能说明：RPN层是否输出高精度。

关联参数：无

参数取值：

- 参数值：[0,1]
 - 0: 低精度，使用FP16。
 - 1: 高精度，使用FP32。
- 参数默认值：0。

推荐配置及收益：无

示例：

```
--detection_out_accuracy=0
```

依赖约束：无

3.2.7.9 --use_class_id

功能说明：RPN层输出是否包括class id。

关联参数：无

参数取值：

- 参数值：[0,1]



- 0: 不包括class id。
- 1: 包括class id。
- 参数默认值: 1。

推荐配置及收益: 当前版本只支持配1

示例:

```
--use_class_id=1
```

依赖约束: 无

3.2.8 Recurrent 网络选项

3.2.8.1 --recurrent_max_total_t

功能说明: Recurrent网络 (包含LSTM/RNN/GRU层) 每一句话的最大帧数, 用于板端运行时分配输入内存。

关联参数: 无

参数取值:

- 参数值: [1, 1024]
- 参数默认值: 1024

推荐配置及收益: 按板端实际部署运行时每一句话的最大帧数配置, 配置越大, 分配的输入内存越大。

示例:

```
--recurrent_max_total_t=1024
```

依赖约束: 必须大于等于每一句话的最大帧数, 否则输入数据不完整, 计算错误。

3.2.8.2 --recurrent_tmax

功能说明: Recurrent网络 (包含LSTM/RNN/GRU层) 执行期间, 将基于continuous对输入的每一句话进行子句切分, 一句话会被切分为若干子句以实现并行处理。该参数表示由切分所产生的若干子句中, 子句的最大帧数, 用于板端运行时分配临时缓存。假设某Recurrent层第二个输入continuous的数据为 [0, 1, 0], 这意味着帧数为3的句子将被切分为帧数为2和1的两个子句, 子句的最大帧数为2, 故该参数取2。

关联参数: 无

参数取值:

- 参数值: [1, 1024]
- 参数默认值: 1024

推荐配置及收益: 按板端实际部署运行时每一句话基于continuous做子句切分后, 子句的最大帧数配置, 若难以明确子句的最大帧数, 则配置为每一句话的最大帧数即可, 配置越大占用临时缓存越大。

示例:

```
--recurrent_tmax=1024
```



依赖约束：必须大于等于每一句话进行子句切分后的子句最大帧数，否则计算错误。

3.2.9 目标解决方案选项

3.2.9.1 --soc_version

功能说明：模型转换时指定解决方案版本。

关联参数：无

参数取值：

- 参数值：Hi3516DV500, Hi3519DV500, Hi3516CV608, Hi3516CV610
- 参数默认值：
 - Hi3516DV500/Hi3519DV500: Hi3516DV500
 - Hi3516CV608/Hi3516CV610: 无，且参数为必传值。
- 用户根据具体板端解决方案，选择对应的取值。

推荐配置及收益：无

示例：

```
--soc_version=Hi3516DV500
```

依赖约束：无

3.3 高级功能

以下介绍部分常用参数选项，更多选项用法请输入--help。

3.3.1 功能配置选项

3.3.1.1 --max_roi_frame_cnt

功能说明：包含ROIPOOLING/PSROI/ROIALIGN网络的RPN阶段输出的候选框最大数目。

关联参数：无

参数取值：

- 参数值：[1,2048]
- 参数默认值：300

推荐配置及收益：无

示例：

```
--max_roi_frame_cnt=300
```

依赖约束：无



3.3.1.2 --online_model_type

功能说明：转换生成模型的类型，用于板端执行profiling或dump数据。

关联参数：

--layer_fusion_enable：深度融合的层板端不支持dump，而指令仿真支持，即*.om转json文件里，属性is_dump_available为0的层不支持dump。

--net_optimize_enable：层间融合的数据不支持dump，即*.om转json文件里，_datadump_original_op_names描述融合的层。例如Convolution融合了BatchNorm，只能dump 融合之后的数据。

参数取值：

- 参数值：[0,7]。
 - 0: 没有调试相关的内容，没有网络结构和算子信息。
 - 1: 调试带层信息。
 - 2: 调试带层开始和结束标记，板端profiling 用。
 - 3: 调试带层信息、层开始和结束标记。
 - 4: 调试带层TRAP指令，板端dump数据用。
 - 5: 调试带层信息、层TRAP指令。
 - 6: 调试带层开始和结束标记、层TRAP指令。
 - 7: 调试带层信息、层开始和结束标记、TRAP指令。

- 参数默认值：2

推荐配置及收益：

- Release 配置 0。
- Debug for profile配置2。
- Debug for dump and compare配置4。

示例：

```
--online_model_type=2
```

依赖约束：无

3.3.1.3 --dynamic_image_size

功能说明：设置输入的动态分辨率档位，在板端运行时可选择其中的一个作为输入的大小。

关联参数：

--input_shape：当某个输入采用动态分辨率时，需要配置该选项，且将宽、高配置成-1。

参数取值：

- 参数值：

模型输入的动态分辨率信息，例如："h1,w1;h2,w2"。指定的分辨率必须放在双引号中，分辨率中间使用英文分号分隔。
- 参数值约束：



可支持设置【2, 100】组分辨率。第一组分辨率必须为最大的分辨率。

每组分辨率宽、高的取值范围为[1, 16384]。

推荐配置及收益：配置的动态分辨率越多时，生成的OM也会越大，请根据实际需要设置。

示例：

```
--dynamic_image_size="h1,w1,h2,w2"  
--input_shape="input1:1,3,-1,-1"
```

表示input1使用动态分辨率，且动态分辨率有两组，分别为【h1, w1】、【h2, w2】。

在运行时，可以指定采用【h1, w1】或【h2, w2】进行推理。若未指定，则使用第一档分辨率【h1,w1】进行推理。

依赖约束：

- --insert_op_conf 配置 aipp_mode 为 static 且使能Crop或Pad或Resize时，不支持动态分辨率。
- 模型本身不支持其他分辨率时，不支持动态分辨率。如模型包含FC层。

须知

开启动态分辨率时，网络及算子的性能同静态相比可能会有所下降：

- 带有权重的算子，比如Convolution、Deconvolution、DepthwiseConv、InnerProduct算子，性能可能会下降。
- 整网由于层间深度融合、层间数据共享策略的变化，相比静态模式，性能可能会下降。

3.3.1.4 --hwts_preemption_enable

功能说明：网络前向推理的时候，是否允许被优先级更高的任务抢占。

关联参数：无

参数取值：

- 参数值：[0,1]
 - 0：关闭优先级抢占。
 - 1：使能优先级抢占。
- 参数默认值：0。

推荐配置及收益：按板端实际部署运行时的场景配置，如果模型需要使能优先级抢占和优先级提升，则必须配置为1；若配置为0，通过板端ACL接口 `svp_acl_md1_config_handle *svp_acl_md1_create_config_handle()` 创建handle之后，对handle设置的优先级抢占和优先级提升无效。

示例：

```
--hwts_preemption_enable=1
```

依赖约束：无

**须知**

- 有AICPU算子的模型，workbuf中有32KB用于保存切换任务的上下文。
- 使能任务抢占后，也需要32KB用于保存切换任务的上下文，如果模型有AICPU算子，则workbuf没有变化，如果没有AICPU算子，则workbuf增大32KB。

3.3.1.5 --hwts_jump_option

功能说明：网络向前推理的时候，aicpu执行时，aicore是否处于忙等状态。

关联参数：无

参数取值：

- 参数值：[0,1]
 - 0: busy jump, aicpu执行时，aicore处于忙等状态，workbuf可共享。
 - 1: release jump, aicpu执行时，aicore释放，workbuf不可共享。
- 参数默认值：0

示例：

```
--hwts_jump_option=0
```

依赖约束：无

3.3.1.6 --inout_mem_reuse_mode

功能说明：网络在推理的时候，需要的内存主要有：输入内存、输出内存、workbuf（用来保存推理时的中间数据）。如果输入、输出内存中的数据后续不再需要使用，则在推理时可以将中间数据保存在输入、输出内存中，从而减少workbuf的大小。本字段用来描述输入、输出内存可被复用时的各种模式。

关联参数：[--inout_mem_reuse_name](#)。

参数取值：

- 参数值：[0, 6]
 - 0: 输入内存不连续，输出内存不连续。此模式下，可以使用inout_mem_reuse_name来指定哪些输入、输出内存可以被复用。
 - 1: 输入内存连续，输出内存不连续。此模式下，所有输入地址连续，且可以被复用，输入内存需要按照index顺序排布；可以使用[--inout_mem_reuse_name](#)指定哪些输出内存可以被复用。
 - 2: 输入内存不连续，输出内存连续。此模式下，所有输出地址连续，且可以被复用，输出内存需要按照index顺序排布；可以使用[--inout_mem_reuse_name](#)指定哪些输入内存可以被复用。
 - 3: 输入内存连续，输出内存连续。此模式下，所有输入地址连续，且可以被复用，输入内存需要按照index顺序排布，输出内存按照index顺序排布；所有输出地址连续，且可以被复用。
 - 4: 输入、输出内存连续。此模式下，所有输入、输出地址连续，且可以被复用，输入内存需要按照index顺序排布，输出内存需要按照index顺序排布，并且需要按照输入/输出顺序排布。
 - 5: 输入、输出、tmpbuf内存连续。此模式下，所有输入、输出和tmpbuf地址连续，且可以被复用，输入内存需要按照index顺序排布，输出内存需要按



照index顺序排布，并且需要按照输入/输出/workbuf顺序排布。依赖约束：Hi3519DV500不支持。

- 6：输出、tmpbuf内存连续。此模式下，所有输出和tmpbuf地址连续，且可以被复用，输出内存需要按照index顺序排布，并且需要按照输出/workbuf顺序排布。依赖约束：Hi3519DV500不支持。

- 参数默认值：0

示例：

```
--inout_mem_reuse_mode=0
```

须知

- 若指定了输入或者输出内存连续，则在分配输入、输出内存时，需要保证连续，否则在推理时会出现错误。
- 当输入输出多batch时，只能通过**--inout_mem_reuse_name**来指定可被复用的输入，此时输入仅第一个batch内存可被复用。输出不能被复用。
- 使能复用模式后，还会根据网络的实际情况分析实际推理时是否可以被复用。因此，该模式不能保证一定可以减少workbuf。如果最终未使能复用，在使用接口 `svp_acl_mdl_get_reuse_buffer_type` 从OM中获取复用标记时，会显示为0。
- 开启动态分辨率后，所有档位使用相同的复用结果。即某一档位下，若某个输入或者输出被复用了，则其它档位下也会被设置成复用。
- 使用时，板端的内存申请需要按照相应的规则申请，具体可参考《应用开发指南》"WorkBuf内存复用"章节。

3.3.1.7 --inout_mem_reuse_name

功能说明：用来指定网络推理时，哪些输入、输出内存可以被复用。详见 `inout_mem_reuse_mode`。

关联参数：**--inout_mem_reuse_mode**。

参数取值：输入名称、输出名称。多个名称之间用;隔离。默认值为空。

示例：

```
--inout_mem_reuse_name="data1;out1"
```

假设某个网络的输入为data1，data2；输出为out1，out2。则上述示例表示data1对应的内存可以被复用，out1对应的内存可以被复用。

3.3.1.8 --pb_share_config

功能说明：设置模型转换时，PB缓存复用相关的配置

关联参数：无

参数取值：

- 参数值：
PB缓存复用相关的配置，指定复用的PB大小，单位为KB，例如："30"。



如果模型中仅存在一种PB复用场景，则只需要传递一个参数即可，此时编译出的OM中仅包含指定的一种PB复用场景。

- 参数值约束：

目前Hi3516CV610芯片，仅支持复用0KB，30KB，100KB三种场景，且仅支持存在一种PB复用场景。

示例：

```
--pb_share_config="30"
```

依赖约束：Hi3519DV500不支持。

须知

PB内存复用不仅需要ATC "--pb_share_config"配置,同时需要不同组件配合才能生效，不同组件生效场景如下：

- 板端：依赖板端Ko配置的更改，如果需启用PB复用，需更改《MPP媒体处理软件V.xx开发参考》“系统控制”章节中module param -> profile参数，然后重新插入KO才能够生效。
- 指令仿真/性能仿真：通过接口svp_acl_init的json参数配置，配置格式为：

```
{
  "pb_reuse": {
    "pb_buf_size": "30720"
  }
}
```

其中30KB复用场景 "pb_buf_size" 配置为30720，100KB复用场景 "pb_buf_size" 配置为102400。

- 功能仿真无需特殊配置，只需要ATC "--pb_share_config"配置即可。

3.3.1.9 --workbuf_optimize_enable

功能说明：设置模型转换时，是否开启workbuf优化。workbuf大小和模型结构有关，因此开启该优化有可能减小workbuf的大小，也有可能不减小。

关联参数：无

参数取值：

- 参数值：[0,1]
 - 0：去使能。
 - 1：使能。
- 参数默认值：1

推荐配置及收益：推荐配置1，可能降低workbuf的大小。

示例：

```
--workbuf_optimize_enable=1
```

依赖约束：仅支持Hi3516CV610。



3.3.1.10 --workbuf_priority_first

功能说明：在模型转换时，是否开启workbuf优先策略。ATC默认按“性能优先”的策略进行模型转换，当开启该参数后，ATC按“workbuf优先”的策略进行模型转换，编译出workbuf最小的OM。

关联参数：无

参数取值：

- 参数值：[0,1]
 - 0：去使能。
 - 1：使能。
- 参数默认值：0

推荐配置及收益：当需要优化work buffer时，推荐配置1。

示例：

```
--workbuf_priority_first=1
```

依赖约束：仅支持Hi3516CV610。

3.3.2 模型调优选项

3.3.2.1 --batch_num

功能说明：

- 支持batch处理的层单次处理的数据份数。影响性能和临时缓存大小。例如InnerProduct层支持batch处理，当batch_num配置为0或1时，则分配1份输入和输出所需的内存，单次处理1份数据。
- 当batch_num配置为256时，则分配256份的输入和输出所需的内存，单次处理256份数据。

关联参数：无


参数取值：

- 参数值：[0, 256]。
 - 0和1：表示single（单张）模式。Batch层一次处理一张图片，临时缓存为一张图片分配。
 - 大于1：表示batch（多张）模式。Batch层一次处理batch张图片，临时缓存为batch张图片分配。
- 参数默认值：Hi3519DV500：网络包含AICPU层时，或网络不包含batch层时，默认为1。其他情况默认为16。batch层：如InnerProduct。Hi3516CV610：默认为1
- 参数值约束：

网络包含Recurrent层且Recurrent层连接非FC层时，网络包含ROI Pooling/PSROI Pooling层、RPN硬化层、IF/LOOP/SCAN、Winpartition-WinpartitionReverse循环等这类控制层时，不支持batch，强制设置batch_num为1。

网络包含如下结构时，不支持batch，强制设置batch_num为1：

图 3-3 不支持 batch 结构图



其中batch op是指：FC算子、CPU算子。

推荐配置及收益：对于batch层，batch模式比single模式性能好，占用内存也会更多。batch层包括InnerProduct、LSTM、RNN、GRU。

示例：

```
--batch_num=256
```

依赖约束：无

3.3.2.2 --internal_stride

功能说明：DDR读写对齐字节数。

关联参数：无

参数取值：

- 参数值：{16,32,64,128,256}
- 参数默认值：16

推荐配置及收益：

- DDR类型为DDR4时，读写32字节对齐性能最好，建议配置为32。
- 每个width占用的内存对齐到internal_stride，当width*sizeof(data_type)不能整除internal_stride时，internal_stride越大越占用内存，读写内存越多也越耗时间，所以并不是internal_stride越大越好。

示例：

```
--internal_stride=16
```

依赖约束：无



3.3.2.3 --fusion_switch_file

功能说明：融合规则开关配置文件路径以及文件名。

关联参数：`--fusion_switch_file`是控制指定某个图优化开关，`--net_optimize_enable`是控制所有图优化开关。

- 当配置`--net_optimize_enable=0`时，`--fusion_switch_file`不生效。
- 当配置`--net_optimize_enable=1`时，`--fusion_switch_file`生效。

参数取值：

- 参数值：支持配置以下2种方式，
 - 文件路径以及文件名。
 - 融合规则字符串。（仅Hi3519DV500支持）
- 参数值格式：
 - 路径和文件名：支持大小写字母（a-z, A-Z）、数字（0-9）、下划线（_）、中划线（-）、句点（.）、中文字符。
 - 融合规则字符串：格式"`item1:on;item2:off`"，融合规则+英文冒号+"on"或"off"，融合规则之间使用英文分号分隔。例如：
"`BatchNormMergeToConvWeight:off;BatchNormMergeToConvActive:off`"
- 参数值约束：如果用户想使用经过AMCT量化后的模型，进行精度比对，则该参数必填。通过配置该文件，关闭融合功能。

推荐配置及收益：无

示例：支持如下融合规则。

- BatchNormMergeToConvWeight: BatchNorm层融合到前一层Conv/Deconv/FC的权重。
- BatchNormMergeToConvActive: BatchNorm层融合到前一层Conv/Deconv/FC的输出参数。
- ScaleMergeToConvWeight: Scale层融合到前一层Conv/Deconv/FC的权重。
- ScaleMergeToConvActive: Scale层融合到前一层Conv/Deconv/FC的输出参数。
- BiasMergeToConv: Bias层融合到前一层Conv/Deconv/FC的权重。
- ReluMerge: Relu层融合到前一层输出参数。
- PReluMerge: PRelu层融合到前一层输出参数。
- AbsMerge: Abs层融合到前一层输出参数。
- BatchNormTransfromToDepthwiseConv: BatchNorm层转换为DepthwiseConv层。性能大幅提升，精度略微降低。
- EltwiseMergeToCube: Eltwise层融合到Cube层，Cube层包括Conv/Deconv/DepthwiseConv/Pool。性能提升，量化参数有溢出风险。
- PoolMergeToConv: MaxPooling层、AvePooling层、GlobalMaxPooling层、GlobalAvePooling融合到Conv层。
- SwishMergeToConv: Swish/Gelu层融合到Conv层
- SigmoidMergeToConv: Sigmoid层融合到Conv层
- GemmTransformToFc: Flatten/Reshape+Gemm转成FC层
- TransformerFusion: 开启开源swin/vit等transformer网络结构优化，转换为picovison对应结构



配置文件样例如下，冒号前面为融合规则名，后面字段表示融合规则是否开启（文件名举例为 *fusion_switch.txt*）：

```
BatchNormMergeToConvWeight:on
BatchNormMergeToConvActive:off
ScaleMergeToConvWeight:on
ScaleMergeToConvActive:off
BiasMergeToConv:on
ReluMerge:on
PReluMerge:on
AbsMerge:on
BatchNormTransfromToDepthwiseConv:on
PoolMergeToConv:on
EltwiseMergeToCube:on
SwishMergeToConv:on
SigmoidMergeToConv:on
GemmTransformToFc:on
```

将配置好的 *fusion_switch.txt* 文件上传到ATC工具所在服务器任意目录，例如上传到 */home/test/*，使用示例如下：

```
--fusion_switch_file=/home/test/fusion_switch.txt
```

19DV500支持不指定*fusion_switch.txt*文件路径，直接配置融合规则，使用示例如下：

```
--
fusion_switch_file=BatchNormMergeToConvWeight:off;BatchNormMergeToConvActive:off;ScaleMergeToConvWeight:off;ScaleMergeToConvActive:off
```

依赖约束：无

3.3.2.4 --net_optimize_enable

功能说明：所有融合规则的使能开关。

关联参数：**--fusion_switch_file**是控制指定某个融合规则的开关，**--net_optimize_enable**是控制所有融合规则的开关。

- 当配置**--net_optimize_enable=0**时，关闭所有融合规则，**--fusion_switch_file**不生效。
- 当配置**--net_optimize_enable=1**时，使能所有融合规则，如果配置了**--fusion_switch_file**，以配置的融合规则文件为准。

参数取值：

- 参数值：[0,1]
 - 0：去使能。
 - 1：使能。
- 参数默认值：1

推荐配置及收益：融合可以减少算子，提升性能，推荐配置1。

示例：

```
--net_optimize_enable=1
```

依赖约束：无

3.3.2.5 --layer_fusion_enable

功能说明：层间深度融合的使能开关。层间深度融合是指多层之间融合在一起，切小块循环计算，数据在内部RAM传递，不读写DDR。



关联参数：无

参数取值：

- 参数值：[0,1]
 - 0：去使能。
 - 1：使能。
- 参数默认值：1

推荐配置及收益：层间深度融合可以减少DDR读写，提升性能，推荐配置1。

示例：

```
--layer_fusion_enable=1
```

依赖约束：无

3.3.2.6 --layer_m2m_enable

功能说明：层间数据共享的使能开关。层间数据共享是指两层之间，上一层的输出数据在内部RAM共享给下一层作为输入数据，不读写DDR。

关联参数：无

参数取值：

- 参数值：[0,1]
 - 0：去使能。
 - 1：使能。
- 参数默认值：1

推荐配置及收益：层间数据共享可以减少DDR读写，提升性能，推荐配置1。

示例：

```
--layer_m2m_enable=1
```

依赖约束：无

3.3.2.7 --layer_m2m_no_event_enable

功能说明：使能层间数据共享时，层间事件的使能开关。有事件时，必须等上一层全部计算完再开始下一层的计算。没有事件时，不依赖上一层的计算可以先开始，不用等上一层计算完。

关联参数：该参数需要与--layer_m2m_enable一起使用。

参数取值：

- 参数值：[0,1]
 - 0：去使能。
 - 1：使能。
- 参数默认值：1

推荐配置及收益：关闭层间事件同步，可以减少等待，提升性能，推荐配置1。

示例：



```
--layer_m2m_no_event_enable=1
```

依赖约束：无

3.3.2.8 --weight_cmp_ratio

功能说明：待压缩权重的长度占权重总长度的比例。例如权重总长为1000，weight_cmp_ratio为0.4时，则取400长度的权重进行压缩，假设压缩后长度为300，则最终权重的长度为 $(1000-400)+300=900$ 。

关联参数：无

参数取值：

- 参数值：[0,1]
- 参数默认值：0

推荐配置及收益：通常，在极致省带宽场景下推荐配置为1，在性能提升场景下，推荐配置为[0.4, 0.5]之间。对于权重稀疏性较差的网络，可能导致压缩后权重略微变大，具体是否开压缩以及压缩比例需根据具体网络实测后确定。该编译选项适用于网络中fc层较多且权重较大的场景，例如resnet、densenet网络。

示例：

```
--weight_cmp_ratio=0.435
```

依赖约束：Hi3516CV610不支持。

3.3.2.9 --tilingw_fusion_enable

功能说明：层间深度融合进阶切块（tilingw depth fusion）的使能开关。层间深度融合是指多层之间融合在一起，切小块循环计算，数据在内部RAM传递，不读写DDR。

关联参数：该参数需要与--layer_fusion_enable一起使用。

参数取值：

- 参数值：[0,1]
 - 0：去使能。
 - 1：使能。
- 参数默认值：1

推荐配置及收益：层间深度融合可以减少DDR读写，提升性能，推荐配置1。

示例：

```
--tilingw_fusion_enable=1
```

依赖约束：仅支持Hi3516CV610。

3.3.2.10 --tilingw_fusion_piecenum

功能说明：配置层间深度融合进阶切块（tilingw depth fusion）的宽维度的切块数量。当网络的分辨率比较大导致work buffer较大时，可以尝试增大该参数值，例如改成3，能够对网络切得更碎融合更深，以减小work buffer，降低模型推理占用的内存。若编译过程中提示有关于cache miss的warn警告时，可能由于切块很碎导致深度融合子网过长，存在cache miss，导致性能的下降、带宽的增加，此时应按实际需求决策以性能优先还是work buffer优先来选择合适的参数。



关联参数：该参数需要与`--tilingw_fusion_enable`一起使用。

参数取值：

- 参数值：[2, 5]
- 参数默认值：2

推荐配置及收益：当需要优化work buffer时，可以尝试改成3或者4。网络workbuf的收益与模型结构强相关，因此具体收益以实测为准。

示例：

```
--tilingw_fusion_piecenum=3
```

依赖约束：仅支持Hi3516CV610。

3.3.2.11 --group_conv_trans_depthwise_enable

功能说明：是否使能group conv转换为depthwise conv。

关联参数：可以与`--group_conv_not_trans_depthwise_layer`联合使用。

参数取值：

参数值：[0, 1]

参数默认值：1

推荐配置及收益：由于Hi3516CV610上depthwise conv不支持高精度，当网络配置高精度出现由于depthwise conv导致精度不够问题时，可以配置为false，使group conv能走高精度，以提升精度，但是这样会增加om大小，带宽和耗时。

示例：

```
--group_conv_trans_depthwise_enable=1
```

依赖约束：仅支持Hi3516CV610。

3.3.2.12 --group_conv_not_trans_depthwise_layer

功能说明：当`group_conv_trans_depthwise_enable`配置为1时，可以配置某些group conv层不转换成depthwise conv，以平衡精度与内存及耗时。

关联参数：可以与`--group_conv_trans_depthwise_enable`联合使用。

参数取值：字符串。网络模型中的节点（node_name）名称。

推荐配置及收益：无。

示例：

```
--group_conv_trans_depthwise_enable=1  
--group_conv_not_trans_depthwise_layer=group_conv1
```

依赖约束：仅支持Hi3516CV610。

3.3.2.13 --n_loop_enable

功能说明：当 $n > 1$ ，是否开启n循环。

关联参数：当开启该功能时，`--batch_num`将强制为1



参数取值：

- 参数值：[0,1]
 - 0：去使能。
 - 1：使能。
- 参数默认值：0

推荐配置及收益：开启n循环可以使网络使用n==1的shape进行指令生成：更小的shape将更易进行片上buffer交互，减少ddr交互，提升性能。但如果网络n>1的shape不大，算子间在未开启n循环的时候就能使用片上buffer交互，那么该配置将没有收益，或者会有负收益。因此该配置可以用来尝试是否有收益再使用。

示例：

```
--n_loop_enable=1
```

依赖约束：Hi3516CV610不支持。

3.3.3 调试选项

3.3.3.1 --save_original_model

功能说明：是否生成原始模型文件，用于功能仿真。原始模型文件包含了离线模型文件，所以也可用于上板运行。

关联参数：该参数需要与 **--output** 参数配合使用。

参数取值：

- 参数值
 - false：不生成原始模型文件。
 - true：生成原始模型文件。
- 参数默认值：false
- 参数值约束：若设置为true，在--output参数指定路径下生成原始模型文件（以后缀“*_original.om”格式结尾），用于功能仿真，也可用于上板运行。

推荐配置及收益：无

示例：

```
--output=/home/test/out/caffe_resnet50 --save_original_model=true
```

模型转换成功后，在out目录下生成原始模型文件caffe_resnet50_original.om。

依赖约束：无

3.3.3.2 --dump_mode

功能说明：是否生成带shape信息的json文件。

关联参数：该参数需要与**--json**、**--mode=1**、**--framework**、**--om**参数（需要为原始模型文件，如果为Caffe框架模型文件，还需要增加**--weight**参数）配合使用。

参数取值

- 参数值：



- 0: 不使能。
- 1: 使能。
- 参数默认值: 0

推荐配置及收益: 无

示例:

```
atc --mode=1 --om=$HOME/test/resnet50.prototxt --json=$HOME/test/out/resnet50.json --framework=0 --weight=$HOME/test/resnet50.caffemodel --dump_mode=1
```

依赖约束: 无

3.3.3.3 --dump_data

功能说明: 导出ATC转换模型过程中的数据到文件。

关联参数: 无

参数取值

- 参数值: 范围[0,31]
 - 0: 不导出。
 - 1: 导出校准量化参数时每层quant->dequant->forward的数据到mapper_quant目录。文件为protobuf格式, .dump后缀。
 - 2: 导出使用量化参数仿真时每层quant->forward->dequant的数据到mapper_simulate目录, 文件为protobuf格式, .dump后缀。
 - 4: 导出校准量化参数时的权重、模型参数等数据。
 - 8: 导出校准量化参数时每层quant->dequant->forward的数据到mapper_quant目录, 文件为txt格式, .float后缀。
 - 16: 导出使用量化参数仿真时每层quant->forward->dequant的数据到mapper_simulate目录, 文件为txt格式, .float后缀。
- 值{1,2,4}可以组合成{3,5,6,7}, 如配置3, 即1+2, 同时导出mapper_quant和mapper_simulate。
- 参数默认值: 0
- 参数值约束: mapper_simulate依赖mapper_quant, 即导出mapper_simulate时需同时导出mapper_quant。

推荐配置及收益: 无

示例:

```
--image_list=input_data.txt --dump_data=3
```

依赖约束: 需配置--image_list才能导出数据, 否则编译报错。

3.3.3.4 --is_precheck

功能说明: 预检查输入的参数、模型等是否满足转换离线模型的要求。满足则返回成功, 但不会生成离线模型; 不满足, 则返回失败, 用户按提示信息修改参数或模型。

关联参数: 无

参数取值



- 参数值：[0,1]
 - 0：关闭预检查。
 - 1：使能预检查。
- 参数默认值：0

推荐配置及收益：转换模型需要校准生成量化参数，比较耗时，使能预检查可以跳过校准，快速检查是否可以正常转换模型，节省时间。

示例：

```
--is_precheck=1
```

依赖约束：无

3.3.3.5 --log_level

功能说明：ATC的日志级别。

关联参数：无

参数取值

- 参数值：[0,3]
 - 0：必要的日志信息。
 - 1：接口级的日志信息。
 - 2：模块级的日志信息。
 - 3：函数级的日志信息。
- 参数默认值：0

推荐配置及收益：配置值越大，输出日志信息越多，转换模型的时间越长，推荐配置为0。

示例：

```
--log_level=0
```

依赖约束：无

3.3.3.6 --forward_quantization_option

功能说明：ATC转换模型校准时的量化选项。控制推理时是否使能数据量化或权重量化。

关联参数：无

参数取值

- 参数值：
 - 0：关闭数据和权重量化。
 - 1：使能数据量化。
 - 2：使能权重量化。
 - 3：使能数据和权重量化。
- 参数默认值：3

推荐配置及收益：无



示例：

```
--forward_quantization_option=0
```

依赖约束：无

3.3.3.7 --cutoff_layer

功能说明：删除指定层名以下的层，包含指定的层。定位网络精度问题，只需要跑前面的层，不需要跑后面的层时，使用此参数裁剪网络。

关联参数：无

参数取值：字符串。网络模型中的节点（node_name）名称。

推荐配置及收益：无。

示例：删除conv1以下的层，包含conv1。

```
--cutoff_layer=conv1
```

依赖约束：无

3.3.3.8 --board_single_push_enable

功能说明：板端是否单步运行。定位网路问题的时候，可以用来排除是否指令时序问题。

参数取值：

- 参数值：
 - 0：去使能
 - 1：使能
- 参数默认值：0

示例：

```
--board_single_push_enable=1
```

依赖约束：Hi3516DV500不支持。

3.4 仅文件方式支持的参数

以下参数仅支持以cfg文件方式配置，不支持命令行方式配置，用于兼容使用NNIE的cfg配置文件转模型。cfg文件格式见[参数配置方式](#)。

3.4.1 模型输入选项

以下配置不能和insert_op_conf同时配置。

3.4.1.1 image_type

功能说明：输入数据格式。

关联参数：一个输入对应一组image_type，[norm_type](#)，[data_scale](#)，[mean_file](#)。

参数取值：



- 参数值：整型数。
 - 0: Feature map
 - 1: BGR_PLANAR
 - 2: YUV420SP
 - 3: YVU420SP
 - 4: YUV422SP
 - 5: YVU422SP
 - 6: YUV400
 - 7: RGB_PLANAR
 - 8: RGB_PACKAGE
 - 9: BGR_PACKAGE
 - 10: XRGB_PLANAR
 - 11: XBGR_PLANAR
 - 12: RGBX_PLANAR
 - 13: BGRX_PLANAR
 - 14: XRGB_PACKAGE
 - 15: XBGR_PACKAGE
 - 16: RGBX_PACKAGE
 - 17: BGRX_PACKAGE
 - 18: RAW_RGGB
 - 19: RAW_GRGB
 - 20: RAW_GBRG
 - 21: RAW_BGGR
 - 22: YUV444SP
 - 23: YVU444SP
 - 24: UVSP
 - 25: VUSP

参数值约束:

- 图像输入时shape必须为4d。
- 图像输入类型：
 - 若图像输入为YUV400，要求输入channel为1；
 - 若图像输入为UVSP、VUSP，要求输入channel为2；
 - 若图像输入为YUV420SP、YVU420SP、YUV422SP、YVU422SP、YUV444SP、YVU444SP、BGR_PLANAR、RGB_PLANAR、RGB_PACKAGE、BGR_PACKAGE，要求输入channel为3；
 - 其他输入格式要求输入channel为4。
- 不能和insert_op_conf同时配置。

推荐配置及收益：无

示例：

```
[image_type] 1  
[norm_type] 5
```



```
[data_scale] 0.00390625  
[mean_file] mean.txt
```

依赖约束：无

3.4.1.2 norm_type

功能说明：对输入数据的预处理方法。

关联参数：一个输入对应一组 **image_type**, **norm_type**, **data_scale**, **mean_file**。

参数取值：整型数。

- 0：不做任何预处理；
- 1：减图像均值；
- 2：减通道均值；
- 3：对图像像素值乘以data_scale；
- 4：减图像均值后再乘以data_scale；
- 5：减通道均值后再乘以data_scale。

参数值约束：不能和insert_op_conf同时配置

推荐配置及收益：无

示例：

```
[image_type] 1  
[norm_type] 5  
[data_scale] 0.00390625  
[mean_file] mean.txt
```

依赖约束：无

3.4.1.3 data_scale

功能说明：数据预处理缩放比例，配置为浮点数，配合norm_type使用。

关联参数：一个输入对应一组 **image_type**, **norm_type**, **data_scale**, **mean_file**。

参数取值：浮点数。

参数值约束：不能和insert_op_conf同时配置

参数默认值：0.00390625

推荐配置及收益：无

示例：

```
[image_type] 1  
[norm_type] 5  
[data_scale] 0.00390625  
[mean_file] mean.txt
```

依赖约束：无

3.4.1.4 mean_file

功能说明：均值文件。



关联参数：一个输入对应一组 **image_type**, **norm_type**, **data_scale**, mean_file。

参数取值：

- 参数值：文件路径与文件名。
- 参数值格式：路径和文件名，支持大小写字母（a-z, A-Z）、数字（0-9）、下划线（_）、中划线（-）、句点（.）、中文字符。

参数值约束：

- 不能和insert_op_conf同时配置。
- norm_type为1、4时，表示均值文件xxx.binaryproto，caffe框架导出的预处理文件，已经过时，不建议使用。
- norm_type为2、5时，表示通道均值文件。
- norm_type为0、3时，用户也需要配置mean_file项，但具体内容可以是一个无效路径，比如null；通道均值文件中每一行的浮点数表示对应的通道均值，如单通道只有一个值。

示例：3个通道的mean.txt

```
123.675
116.28
103.53
```

推荐配置及收益：无

示例：

```
[image_type] 1
[norm_type] 5
[data_scale] 0.00390625
[mean_file] mean.txt
```

依赖约束：无

3.4.1.5 RGB_order

功能说明：模型推理时的通道顺序，即对输入数据做通道转换后、输出数据做通道转换前的通道顺序。

关联参数：**image_type**、**--image_report_type**

参数取值：字符串。取值范围{RGB、BGR、XRGB、RGBX、XBGR、BGRX、RGGB、GRBG、GBRG、BGGR}

参数值约束：

- 配置值需和image_type和image_report_type的类型匹配：
 - YUV420SP、YVU420SP、YUV422SP、YVU422SP、YUV444SP、YVU444SP、UVSP、VUSP、BGR_PLANAR、RGB_PLANAR、RGB_PACKAGE、BGR_PACKAGE可取值范围为RGB、BGR;
 - XRGB_PLANAR、XBGR_PLANAR、RGBX_PLANAR、BGRX_PLANAR、XRGB_PACKAGE、XBGR_PACKAGE、RGBX_PACKAGE、BGRX_PACKAGE可取值范围为XRGB、XBGR、RGBX、BGRX;
 - RAW_RGGB、RAW_GRBG、RAW_GBRG、RAW_BGGR可取值范围为RGGB、GRBG、GBRG、BGGR;
 - YUV400忽略此配置。



- 多个输入时，共用一个配置。
- 不能与input_rgb_order、output_rgb_order（Hi3516CV610不支持）同时配置。

推荐配置及收益：无

示例：

```
[RGB_order] RGB
```

依赖约束：image_type或image_report_type配置为图像格式时才生效。

3.4.1.6 input_rgb_order

功能说明：模型输入数据做通道转换后的通道顺序。

关联参数：[image_type](#)

参数取值：字符串。取值范围{RGB、BGR、XRGB、RGBX、XBGR、BGRX、RGGB、GRBG、GBRG、BGGR}

参数值约束：

- 配置值需和image_type的类型匹配：
 - YUV420SP、YVU420SP、YUV422SP、YVU422SP、YUV444SP、YVU444SP、UVSP、VUSP、BGR_PLANAR、RGB_PLANAR、RGB_PACKAGE、BGR_PACKAGE可取值范围为RGB、BGR;
 - XRGB_PLANAR、XBGR_PLANAR、RGBX_PLANAR、BGRX_PLANAR、XRGB_PACKAGE、XBGR_PACKAGE、RGBX_PACKAGE、BGRX_PACKAGE可取值范围为XRGB、XBGR、RGBX、BGRX;
 - RAW_RGGB、RAW_GRGB、RAW_GBRG、RAW_BGGR可取值范围为RGGB、GRBG、GBRG、BGGR;
 - YUV400忽略此配置。
- 多个输入时，共用一个配置。
- 不能与RGB_order同时配置。

推荐配置及收益：无

示例：

```
[input_rgb_order] RGB
```

依赖约束：image_type配置为图像格式时才生效。

3.4.2 ATC 输入选项

3.4.2.1 prototxt_file

仅文件方式支持prototxt_file，等同参数--[model](#)

3.4.2.2 caffemodel_file

仅文件方式支持caffemodel_file，等同参数--[weight](#)



3.5 已废弃参数

--recurrent_cont：仅支持continuous模式，不需要配置。

3.6 与 NNIE 参数差异

NNIE	ATC	是否差异	差异
batch_num	batch_num	是	NNIE：1. 默认值256；2. 没有参数值约束。 ATC：1. 参数默认值：网络包含AICPU层时，或网络不包含batch层时，默认为1。其他情况默认为16；2. 参数值约束：网络包含Recurrent层且Recurrent层连接非FC层时，网络包含ROI Pooling/PSROI Pooling层、RPN硬化层、IF/LOOP/SCAN这类控制层时，不支持batch，强制设置batch_num为1。
caffemodel_file	caffemodel_file (weight)	否	--
compile_mode	compile_mode	是	NNIE：支持0/1/2配置，2：User-specify(用户配置模式)：需要用户在prototxt中标明所有使用高精度计算的层。 ATC：支持0/1配置。
compress_mode	不支持，可以使用weight_cmp_ratio达到类似效果。	--	--
data_scale	data_scale	是	NNIE：data_scale取值范围 (1/4096, FLT_MAX) , FLT_MAX=3.402823466e+38。 ATC：data_scale无取值范围。不能和insert_op_conf同时配置。
gfpq_param_file	gfpq_param_file	是	NNIE：文件内容为非线性量化参数。 ATC：文件内容为线性量化参数。
image_height	image_height	是	NNIE：image_height取值范围 [8, 4096]。 ATC：image_height取值范围 [1, 4096]。



NNIE	ATC	是否差异	差异
image_list	image_list	是	NNIE: 支持的图片格式: ".bmp", ".dib", ".jpeg", ".jpg", ".jpe", ".jp2", ".png", ".webp", ".pbm", ".pgm", ".ppm", ".sr", ".ras", ".tiff", ".tif", ".BMP", ".DIB", ".JPEG", ".JPG", ".JPE", ".JP2", ".PNG", ".WEBP", ".PBM", ".PGM", ".PPM", ".SR", ".RAS", ".TIFF", ".TIF"。 ATC: 支持图片后缀bmp, jpeg, jpg, jpe, jp2, png。
image_type	image_type	是	NNIE: image_type取值范围{0,1,3,5}。 ATC: image_type取值范围[1, 25]。
image_width	image_width	是	NNIE: image_height取值范围 [8, 4096]。 ATC: image_height取值范围 [1, 4096]。
instruction_name	output	否	--
internal_stride	internal_stride	是	NNIE: internal_stride取值{16, 32}。 ATC: internal_stride取值{16,32,64,128,256}。
is_check_prototxt	不支持, 可以使用check_report达到类似效果。	--	--
is_simulation	支持, 效果参考save_original_model。	是	NNIE: 转换的模型只能用于功能仿。 ATC: 转换的模型能同时用于板端、指令仿和功能仿。
log_level	log_level	否	--
max_roi_frame_cnt	max_roi_frame_cnt	是	NNIE: max_roi_frame_cnt取值[1, 5000]。 ATC: max_roi_frame_cnt取值[1, 2048]。
mean_file	mean_file	否	--
net_type	不支持, 当前根据opType识别。	--	--
norm_type	norm_type	否	--
prototxt_file	prototxt_file (model)	否	--
recurrent_tmax	recurrent_tmax	否	--



NNIE	ATC	是否差异	差异
RGB_order	RGB_order	是	NNIE: RGB_order取值{RGB、BGR}。 ATC: RGB_order取值{RGB、BGR、XRGB、RGBX、XBGR、BGRX、RGGB、GRBG、GBRG、BGGR}。
roi_coordinate_file	不支持，roi作为data层，通过image_list配置。	--	--
sparse_rate	不支持	--	--



4 定制网络修改

4.1 简介

本章节修改只适用于Caffe网络模型。

网络的算子可以分为如下几类：

- 标准算子：图像分析引擎支持的Caffe标准算子，比如Convolution等。
- 扩展算子：图像分析引擎支持的公开但非Caffe标准算子，分为 2 种：
 - 一种是基于Caffe框架进行自定义扩展的算子，比如Faster RCNN中的ROI Pooling、SSD中的归一化算子Normalize等。
 - 另外一种是来源于其他图像分析方法框架的自定义算子，比如YOLOV2中Passthrough等。

Faster RCNN、SSD等网络模型都包含了一些原始Caffe框架中没有定义的算子结构，如ROI Pooling、Normalize、PSROI Pooling和Upsample等。为了使图像分析引擎能支持这些网络，需要对原始的Caffe框架网络模型进行扩展，降低开发者开发自定义算子/开发后处理代码的工作量。若开发者的Caffe框架网络模型中使用了这些扩展算子，在进行模型转换时，需要先在prototxt中修改/添加扩展层的定义，才能成功进行模型转换。

本章节提供了图像分析引擎的扩展算子列表，并给出了如何根据扩展算子修改prototxt文件方法。

4.2 Recurrent 网络 prototxt 示例

须知

带continuous模式下：同caffe prototxt一致，data层及Recurrent层包含continuous，但是N维度必须1；

请参考customer/Software/sample/中lstm、rnn、gru 的sample写法。

4.2.1 prototxt 针对 RNN 层书写规范

RNN的基本计算公式如下 (与Caffe一致):

输入: $x_t, cont, h_{t-1}$

输出: O_t, h_t

隐藏层: $h_t = \tanh(w_{xh}x_t + w_{hh}h_{t-1} + b_h)$

输出层: $o_t = \tanh(w_{ho}h_t + b_o)$

若有额外固定输入向量 x_{static} , 计算公式变为:

输入: $x_t, cont, h_{t-1}$

输出: O_t, h_t

隐藏层: $h_t = \tanh(w_{xh}x_t + w_{hh}h_{t-1} + w_{sh}x_{static} + b_h)$

输出层: $o_t = \tanh(w_{ho}h_t + b_o)$

基于以上计算公式, RNN的prototxt有以下4种场景:

4.2.1.1 通常场景 (expose_hidden=false, 2 输入, 1 输出)

Input: $x_t(1 \sim T), cont(1 \sim T)$

Output: $o_t(1 \sim T)$

Prototxt示例如下, 有2个bottom和1个top, , 其中bottom[0]对应 $x_t(1 \sim T)$, bottom[1]对应 $cont(1 \sim T)$, top[0]对应 $o_t(1 \sim T)$:

- 若recurrent_param的expose_hidden 没配, 默认值为false;
- 不支持recurrent_param 的debug_info, 配置不会生效。

```
layer {
  name: "rnn1"
  type: "RNN"
  bottom: "data0_xt"
  bottom: "data1_cont"
  top: "rnn1_ht "
  recurrent_param {
    num_output: 1000
    weight_filler {
      type: "uniform"
      min: -0.08
      max: 0.08
    }
    bias_filler {
      type: "constant"
      value: 0
    }
  }
}
```

4.2.1.2 隐藏参数显式输入输出 (expose_hidden=true, 3 输入, 2 输出)

Input: $x_t(1 \sim T), cont(1 \sim T), h_0$

Output: $o_t(1 \sim T), h_T$

Prototxt示例如下，有3个bottom和2个top，其中bottom[0]对应 $x_t(1 \sim T)$ ，bottom[1]对应 $cont(1 \sim T)$ ，bottom[2]对应 h_0 ，top[0]对应 $o_t(1 \sim T)$ ，top[1]对应 h_T ；

- h_0 的向量维度须与recurrent_param的num_output一致；
- 只有前两个bottom与第一个top有时间的维度。
- expose_hidden=true配置下，不支持后接InnerProduct层。

```
layer {
  name: "rnn1"
  type: "RNN"
  bottom: "data0_xt"
  bottom: "data1_cont"
  bottom: "data2_h0"
  top: "rnn1_ht "
  top: "rnn1_hT"
  recurrent_param {
    num_output: 1000
    expose_hidden=1
    weight_filler {
      type: "uniform"
      min: -0.08
      max: 0.08
    }
    bias_filler {
      type: "constant"
      value: 0
    }
  }
}
```

4.2.1.3 具有额外的固定输入（expose_hidden=false，3 输入，1 输出）

Input: $x_t(1 \sim T), cont(1 \sim T), x_{static}$

Output: $o_t(1 \sim T)$

Prototxt示例如下，有3个bottom和1个top，其中bottom[0]对应 $x_t(1 \sim T)$ ，bottom[1]对应 $cont(1 \sim T)$ ，bottom[2]对应 x_{static} ，top[0]对应 $o_t(1 \sim T)$ ；

- $x_t(1 \sim T)$ 和 $cont(1 \sim T)$ 的向量维度，必须与 x_{static} 的向量维度一致；
- 如果recurrent_param 的expose_hidden 没配，默认值为false；
- 不支持recurrent_param 的debug_info，配置不会生效。

```
layer {
  name: "rnn1"
  type: "RNN"
  bottom: "data0_xt"
  bottom: "data1_cont"
  bottom: "data2_xstatic"
  top: "rnn1_ht "
  recurrent_param {
    num_output: 1000
    weight_filler {
      type: "uniform"
      min: -0.08
      max: 0.08
    }
  }
}
```



```

    bias_filler {
      type: "constant"
      value: 0
    }
  }
}

```

4.2.1.4 既有固定输入，又有显式的隐藏参数 (expose_hidden=true, 4 输入，2 输出)

Input: $x_t(1\sim T), cont(1\sim T), x_{static} h_0$

Output: $o_t(1\sim T), h_T$

Prototxt示例如下，有4个bottom和2个top，其中bottom[0]对应 $x_t(1\sim T)$ ，bottom[1]对应 $cont(1\sim T)$ ，bottom[2]对应 x_{static} ，bottom[3]对应 h_0 ，top[0]对应 $o_t(1\sim T)$ ，top[1]对应 h_T ；

- h_0 的向量维度必须与recurrent_param的num_output一致；
- $x_t(1\sim T)$ 和 $cont(1\sim T)$ 的向量维度，必须与 x_{static} 的向量维度一致；
- 只有前两个bottom与第一个top有时间的维度；
- expose_hidden=true配置下，不支持后接InnerProduct层。

```

layer {
  name: "rnn1"
  type: "RNN"
  bottom: "data0_xt"
  bottom: "data1_cont"
  bottom: "data2_xstatic"
  bottom: "data3_h0"
  top: "rnn1_ht"
  top: "rnn1_hT"
  recurrent_param {
    num_output: 1000
    expose_hidden=1
    weight_filler {
      type: "uniform"
      min: -0.08
      max: 0.08
    }
    bias_filler {
      type: "constant"
      value: 0
    }
  }
}

```

4.2.2 prototxt 针对 LSTM 层书写规范

LSTM的基本计算公式如下 (与Caffe一致)：

输入门: $i_t = \text{sigmoid}(w_{xi}x_t + w_{hi}h_{t-1} + b_i)$

遗忘门: $f_t = \text{sigmoid}(w_{xf}x_t + w_{hf}h_{t-1} + b_f)$

输入值: $g_t = \text{tanh}(w_{xg}x_t + w_{hg}h_{t-1} + b_g)$

当前cell: $c_t = i_t * g_t + f_t * c_{t-1}$



输出门: $o_t = \text{sigmoid}(w_{xo}x_t + w_{ho}h_{t-1} + b_o)$

若有额外固定输入向量 x_{static} , 计算公式变为:

输入门: $i_t = \text{sigmoid}(w_{xi}x_t + w_{hi}h_{t-1} + w_{si}x_{static} + b_i)$

遗忘门: $f_t = \text{sigmoid}(w_{xf}x_t + w_{hf}h_{t-1} + w_{sf}x_{static} + b_f)$

输入值: $g_t = \tanh(w_{xg}x_t + w_{hg}h_{t-1} + w_{sg}x_{static} + b_g)$

当前cell: $c_t = i_t * g_t + f_t * c_{t-1}$

输出门: $o_t = \text{sigmoid}(w_{xo}x_t + w_{ho}h_{t-1} + w_{so}x_{static} + b_o)$

基于以上计算公式, LSTM的prototxt有以下4种场景。

4.2.2.1 通常场景 (expose_hidden=false, 2 输入, 1 输出)

Input: $x_t(1 \sim T), cont(1 \sim T)$

Output: $h_t(1 \sim T)$

Prototxt示例如下, 有2个bottom和1个top, 其中bottom[0]对应 $x_t(1 \sim T)$, bottom[1]对应 $cont(1 \sim T)$, top[0]对应 $h_t(1 \sim T)$:

- 若recurrent_param的expose_hidden 没配, 默认值为false;
- 不支持recurrent_param 的debug_info, 配置不会生效。

```
layer {
  name: "lstm1"
  type: "LSTM"
  bottom: "data0_xt"
  bottom: "data1_cont"
  top: "lstm1_ht"
  recurrent_param {
    num_output: 1000
    weight_filler {
      type: "uniform"
      min: -0.08
      max: 0.08
    }
    bias_filler {
      type: "constant"
      value: 0
    }
  }
}
```

4.2.2.2 隐藏参数显式输入输出 (expose_hidden=true, 4 输入, 3 输出)

Input: $x_t(1 \sim T), cont(1 \sim T), h_0, c_0$

Output: $h_t(1 \sim T), h_T, c_T$

Prototxt示例如下, 有4个bottom和3个top, 其中bottom[0]对应 $x_t(1 \sim T)$, bottom[1]对应 $cont(1 \sim T)$, bottom[2]对应 h_0 , bottom[3]对应 c_0 , top[0]对应 $h_t(1 \sim T)$, top[1]对应 h_T , top[2]对应 c_T ;

- h_0, c_0 的向量维度须与 recurrent_param 的 num_output 一致;
- 只有前两个 bottom 与第一个 top 有时间的维度;
- 不支持 recurrent_param 的 debug_info, 配置不会生效;
- expose_hidden=true 配置下, 不支持后接 InnerProduct 层。

```
layer {
  name: "lstm1"
  type: "LSTM"
  bottom: "data0_xt"
  bottom: "data1_cont"
  bottom: "data2_h0"
  bottom: "data3_c0"
  top: "lstm1_ht"
  top: "lstm1_hT"
  top: "lstm1_cT"
  recurrent_param {
    num_output: 1000
    expose_hidden = 1
    weight_filler {
      type: "uniform"
      min: -0.08
      max: 0.08
    }
    bias_filler {
      type: "constant"
      value: 0
    }
  }
}
```

4.2.2.3 具有额外的固定输入 (expose_hidden=false, 3 输入, 1 输出)

Input: $x_t(1 \sim T), cont(1 \sim T), x_{static}$

Output: $h_t(1 \sim T)$

Prototxt 示例如下, 有 3 个 bottom 和 1 个 top, 其中 bottom[0] 对应 $x_t(1 \sim T)$, bottom[1] 对应 $cont(1 \sim T)$, bottom[2] 对应 x_{static} , top[0] 对应 $h_t(1 \sim T)$;

- $x_t(1 \sim T)$ 和 $cont(1 \sim T)$ 的向量维度, 必须与 x_{static} 的向量维度一致;
- 只有前两个 bottom 与第一个 top 有时间的维度;
- 如果 recurrent_param 的 expose_hidden 没配, 默认值为 false;
- 不支持 recurrent_param 的 debug_info, 配置不会生效。

```
layer {
  name: "lstm1"
  type: "LSTM"
  bottom: "data0_xt"
  bottom: "data1_cont"
  bottom: "data2_xstatic"
  top: "lstm1_ht"
  recurrent_param {
    num_output: 1000
    weight_filler {
      type: "uniform"
      min: -0.08
      max: 0.08
    }
  }
}
```

```

    bias_filler {
      type: "constant"
      value: 0
    }
  }
}

```

4.2.2.4 既有固定输入，又有显式的隐藏参数（`expose_hidden=true`，5 输入，3 输出）

Input: $x_t(1 \sim T), cont(1 \sim T), x_{static}, h_0, c_0$

Output: $h_t(1 \sim T), h_T, c_T$

Prototxt示例如下，有5个bottom和3个top，其中bottom[0]对应 $x_t(1 \sim T)$ ，bottom[1]对应 $cont(1 \sim T)$ ，bottom[2]对应 x_{static} ，bottom[3]对应 h_0 ，bottom[4]对应 c_0 ，top[0]对应 $h_t(1 \sim T)$ ，top[1]对应 h_T ，top[2]对应 c_T ；

- h_0, c_0 的向量维度必须与recurrent_param的num_output一致；
- $x_t(1 \sim T)$ 和 $cont(1 \sim T)$ 的向量维度，必须与 x_{static} 的向量维度一致；
- 只有前两个bottom与第一个top有时间的维度；
- 不支持recurrent_param 的debug_info，配置不会生效；
- `expose_hidden=true`配置下，不支持后接InnerProduct层。

```

layer {
  name: "lstm1"
  type: "LSTM"
  bottom: "data0_xt"
  bottom: "data1_cont"
  bottom: "data2_xstatic"
  bottom: "data3_h0"
  bottom: "data4_c0"
  top: "lstm1_ht"
  top: "lstm1_hT"
  top: "lstm1_cT"
  recurrent_param {
    num_output: 1000
    expose_hidden = 1
    weight_filler {
      type: "uniform"
      min: -0.08
      max: 0.08
    }
    bias_filler {
      type: "constant"
      value: 0
    }
  }
}

```

4.2.3 prototxt 针对 GRU 层书写规范

GRU的基本计算公式如下（与Caffe一致）：

重置门： $R_t = \text{sigmoid}(w_{xr}x_t + w_{hr}h_{t-1} + b_r)$

更新门： $Z_t = \text{sigmoid}(w_{xz}x_t + w_{hz}h_{t-1} + b_z)$

中间结果: $h_{hatt} = \tanh(w_{hhat}(R_t * h_{t-1}) + b_g)$

输出门: $h_t = \text{sigmoid}((1 - Z_t) * h_{t-1} + Z_t * h_{hatt})$

若有额外固定输入向量 x_{static} , 计算公式变为:

重置门: $R_t = \text{sigmoid}(w_{xr}x_t + w_{hr}h_{t-1} + w_{sr}x_{static} + b_i)$

更新门: $Z_t = \text{sigmoid}(w_{xz}x_t + w_{hz}h_{t-1} + w_{sz}x_{static} + b_i)$

中间结果: $h_{hatt} = \tanh(w_{hhat}(R_t * h_{t-1}) + b_g)$

输出门: $h_t = \text{sigmoid}((1 - Z_t) * h_{t-1} + Z_t * h_{hatt})$

基于以上计算公式, GRU的prototxt有以下4种场景:

4.2.3.1 通常场景 (expose_hidden=false, 2 输入, 1 输出)

Input: $x_t(1 \sim T), cont(1 \sim T)$

Output: $h_t(1 \sim T)$

Prototxt示例如下, 有2个bottom和1个top, 其中bottom[0]对应 $x_t(1 \sim T)$, bottom[1]对应 $cont(1 \sim T)$, top[0]对应 $h_t(1 \sim T)$:

- 若recurrent_param的expose_hidden 没配, 默认值为false;
- 不支持recurrent_param 的debug_info, 配置不会生效。

```
layer {
  name: "GRU1"
  type: "GRU"
  bottom: "data0_xt"
  bottom: "data1_cont"
  top: "ht"
  recurrent_param {
    num_output: 1000
    weight_filler {
      type: "uniform"
      min: -0.08
      max: 0.08
    }
    bias_filler {
      type: "constant"
      value: 0
    }
  }
}
```

4.2.3.2 隐藏参数显式输入输出 (expose_hidden=true, 3 输入, 2 输出)

Input: $x_t(1 \sim T), cont(1 \sim T), h_0$

Output: $h_t(1 \sim T), h_T$

Prototxt示例如下, 有2个bottom和2个top, 其中bottom[0]对应 $x_t(1 \sim T)$, bottom[1]对应 $cont(1 \sim T)$, bottom[2]对应 h_0 , top[0]对应 $h_t(1 \sim T)$, top[1]对应 h_T ;

- h_0 的向量维度须与recurrent_param的num_output一致;

- 只有前两个bottom与第一个top有时间的维度;
- 不支持recurrent_param 的debug_info, 配置不会生效;
- expose_hidden=true配置下, 不支持后接InnerProduct层。

```
layer {
  name: "GRU1"
  type: "GRU"
  bottom: "data0_xt"
  bottom: "data1_cont"
  bottom: "data2_h0"
  top: "ht"
  top: "hT"
  recurrent_param {
    num_output: 1000
    expose_hidden = 1
    weight_filler {
      type: "uniform"
      min: -0.08
      max: 0.08
    }
    bias_filler {
      type: "constant"
      value: 0
    }
  }
}
```

4.2.3.3 具有额外的固定输入 (expose_hidden=false, 3 输入, 1 输出)

Input: $x_t(1 \sim T)$, $cont(1 \sim T)$, x_{static}

Output: $h_t(1 \sim T)$

Prototxt示例如下, 有3个bottom和1个top, 其中bottom[0]对应 $x_t(1 \sim T)$, bottom[1]对应 $cont(1 \sim T)$, bottom[2]对应 x_{static} , top[0]对应 $h_t(1 \sim T)$;

- $x_t(1 \sim T)$ 和 $cont(1 \sim T)$ 的向量维度, 必须与 x_{static} 的向量维度一致;
- 只有前两个bottom与第一个top有时间的维度;
- 如果recurrent_param 的expose_hidden 没配, 默认值为false;
- 不支持recurrent_param 的debug_info, 配置不会生效。

```
layer {
  name: "GRU1"
  type: "GRU"
  bottom: "data0_xt"
  bottom: "data1_cont"
  bottom: "data2_xstatic"
  top: "ht"
  recurrent_param {
    num_output: 1000
    weight_filler {
      type: "uniform"
      min: -0.08
      max: 0.08
    }
    bias_filler {
      type: "constant"
      value: 0
    }
  }
}
```

```
}
}
```

4.2.3.4 既有固定输入，又有显式的隐藏参数（`expose_hidden=true`，4 输入，2 输出）

Input: $x_t(1 \sim T), cont(1 \sim T), x_{static}, h_0$

Output: $h_t(1 \sim T), h_T$

Prototxt示例如下，有4个bottom和2个top，其中bottom[0]对应 $x_t(1 \sim T)$ ，bottom[1]对应 $cont(1 \sim T)$ ，bottom[2]对应 x_{static} ，bottom[3]对应 h_0 ，top[0]对应 $h_t(1 \sim T)$ ，top[1]对应 h_T ；

- h_0 的向量维度必须与recurrent_param的num_output一致；
- $x_t(1 \sim T)$ 和 $cont(1 \sim T)$ 的向量维度，必须与 x_{static} 的向量维度一致；
- 只有前两个bottom与第一个top有时间的维度；
- 不支持recurrent_param 的debug_info，配置不会生效；
- `expose_hidden=true`配置下，不支持后接InnerProduct层。

```
layer {
  name: "gru1"
  type: "GRU"
  bottom: "data0_xt"
  bottom: "data1_cont"
  bottom: "data2_xstatic"
  bottom: "data3_h0"
  top: "ht"
  top: "hT"
  recurrent_param {
    num_output: 1000
    expose_hidden = 1
    weight_filler {
      type: "uniform"
      min: -0.08
      max: 0.08
    }
    bias_filler {
      type: "constant"
      value: 0
    }
  }
}
```

4.2.4 Recurrent 网络约束

若Recurrent网络中包含诸如Conv等4D规格的算子，则存在如下约束：

- Prototxt首层的N轴为1，即维度为 $1 \times C \times H \times W$ ；
- 若batch_num配置为大于1的值，Recurrent算子的第二个输入continuous必须为Data层；
- 若batch_num配置为大于1的值，Prototxt构图时，需确保每张图片的计算不存在数据依赖。例如，不同图片所产生的帧数据不能拼接为整体以作为Recurrent算子第一个输入。

4.3 检测网硬化加速

- 对于Hi3519DV500，针对Faster RCNN、RFCN、SSD、YOLOV1、YOLOV2、YOLOV3等检测网络，支持对Proposal、SsdDetectionOutput、YoloDetectionOutput等层进行硬化，达到加速目的。本节描述如何把Proposal、SsdDetectionOutput、YoloDetectionOutput改为RPN硬化的**DetectionOutput**层。
注意：DetectionOutput、DecBBox、Sort、Nms、Filter等硬化层不能作为首层；输出的得分是float型。
- 对于Hi3516CV610，支持将SSD YOLOV5、YOLOV7、YOLOV8后处理模块中的DecBBox算子硬化，为了向前兼容，将Sort、Nms、Filter算子转aicpu算子处理。该方案其网络修改方法与Hi3519DV500相同。另外，为提升检测网后处理的灵活性，Hi3516CV610支持将检测网后处理中生成候选框部分的处理流程拆分成小算子处理，在生成候选框后，后接定制的SortVector、FilterVector算子，最后通过cpu计算得到最终检测框。详见[Hi3516CV610检测网后处理流程](#)。

4.3.1 DecBBox、Sort、Nms、Filter 层功能说明

针对Faster RCNN、RFCN、SSD、YOLOV1、YOLOV2、YOLOV3等检测网络，DecBBox会根据prototxt里面的calc_mode的参数配置解析对应的网络模型，将不同个数以及不同格式的tensor转换成统一的格式。因此DecBBox的输入取决于calc_mode参数的配置，下文会有详细介绍。DecBBox的输出为 $1 \times C \times 6 \times N$ 的tensor，其中C为检测类别的数量，N为锚点的数量，height等于6表示检测框xmin, ymin, xmax, ymax, score, classID等六个信息，数据类型均为浮点型。当不需要输出类别信息时，DecBBox的输出为 $1 \times C \times 5 \times N$ 。

Filter层的作用是根据设定的score的阈值将DecBBox输出的分数小于等于阈值的检测框滤掉，阈值的数据类型为浮点型，输入范围为[0,1)。

Sort层的作用是根据分数大小对DecBBox层的输出进行排序，当参数multi_class_sorting配置为true时，Sort层采取所有类别混合排序的策略，当参数multi_class_sorting配置为false时，Sort层采取每个类别之间根据分数分开排序的策略。Sort层支持top_k的配置，即保留候选框的最大个数。当实际检测框个数小于top_k时，按实际检测框的数量输出。阈值top_k的数据类型为uint型，支持大于1的正整数。

Nms(Non-Maximum Suppression)层的作用是在两个候选框交叠面积除以两张图片占用的总面积大于一定阈值的时候过滤掉得分较低的检测框。阈值的数据类型为浮点型，输入的数据范围支持[0,1)。

Nms层和Filter层所需要的阈值信息由用户给定的data层输入，输入数据类型为float，一共包含四个点，分别对应Nms的阈值、Filter层的得分阈值、Filter的高度阈值和Filter层的宽度阈值。

注意：Filter层、Sort层、Nms层只能接在DecBBox层后面，Filter层、Sort层、Nms层之间的连接顺序和数量任意。当Sort层接在DecBbox层后面时，multi_class_sorting只支持配false。

4.3.2 硬化层参数配置



须知

FilterBox层暂不支持配置top_k参数，配置时不生效。SSD，Faster RCNN，RFCN网络需配置锚点信息的文件。配置的nms_threshold, low_score_threshold, min_height, min_width等参数仅用作ATC推理时使用，实际板端仿真使用参数需通过API接口配置。API配置参数与推理参数建议保持一致。

表 4-1 硬化层参数配置限制

参数	参数意义	DecBBox	FilterBox	Sort	Nms	DetectionOutput
top_k	输出框数配置，prototxt中配置	NA	NA	[1 ~ 10000]	[1 ~ 10000]	NA
num_classes	分类数目配置，prototxt文件中配置。	NA	NA	NA	NA	[1~1000]
multi_class_sorting	多类sort配置，prototxt文件中配置。	NA	NA	true/false	NA	NA
calc_mode	计算模式配置，必须和网络类型匹配，prototxt中配置。	[0~5],8	NA	NA	NA	NA

表 4-2 Faster RCNN RFCN SSD 硬化层参数配置

层/参数	参数	参数意义	Faster RCNN/ RFCN	SSD
DetectionOutput	num_anchors	锚点数目，必须配置	√	√
	num_classes	分类数目，必须配置	1	√
	num_coords	坐标数目，必须配置为4	4	4
DecBBox	share_location	是否是共享位置预测	false	true
	share_variance	是否共享方差，SSD网络必须配置为false	NA	false
	clip_bbox	是否使能框裁剪，只支持配置为true	true	true



层/参数	参数	参数意义	Faster RCNN/ RFCN	SSD
	code_type	必须配置为CENTER_SIZE	CENTER_SIZE	CENTER_SIZE
	bias	YOLOV2/V3/V5/V7网络必须配置, 值域[0,1024.0]	NA	NA
	variance	方差配置, SSD网络必须配置, 且个数必须为4, 值域[0,1.0]	NA	示例: variance: 0.1 variance: 0.1 variance: 0.2 variance: 0.2
	calc_mode	计算模式, 必须配置为表格中网络对应数值	0	4
FilterBox	top_k	输出框数, 暂不支持, 配置时不生效	NA	NA
Sort	multi_class_sorting	是否使用多类sort	false	true/false 具体配置请参考prototxt示例
	top_k	输出框数	[1~10000]	[1~10000]
Nms	top_k	输出框数	[1~10000]	[1~10000]

表 4-3 YOLOV1/V2/V3 硬化层参数配置

层/参数	参数	参数意义	YOLOV1	YOLOV2	YOLOV3
Detection Output	num_anchors	锚点数目, 必须配置	√	√	√
	num_classes	分类数目, 必须配置	√	√	√
	num_coords	坐标数目, 必须配置为4	4	4	4
	num_grids_width	YOLO网络栅格Width, YOLO网络必须配置	√	√	√
	num_grids_height	YOLO网络栅格Height, YOLO网络必须配置	√	√	√
DecBBox	share_location	是否是共享位置预测,	true	true	true
	share_variance	是否共享方差, SSD网络必须配置为false	NA	NA	NA
	clip_bbox	是否使能框裁剪,只支持配置为true	true	true	true



层/参数	参数	参数意义	YOLOV1	YOLOV2	YOLOV3
	code_type	必须配置为CENTER_SIZE	CENTER_SIZE	CENTER_SIZE	CENTER_SIZE
	bias	YOLOV2/V3/V5/V7网络必须配置,值域[0~1024.0]	NA	示例 bias: 1.08 bias: 1.19 bias: 3.42 bias: 4.41 bias: 6.63 bias: 11.3 bias: 9.42 bias: 5.11 bias: 16.6 bias: 10.5	示例: bias: 116 bias: 90 bias: 156 bias: 198 bias: 373 bias: 326
	variance	方差配置, SSD网络必须配置, 且个数必须为4, 值域[0,1.0]	NA	NA	NA
	calc_mode	计算模式, 必须配置为表格中网络对应数值	1	2	3
FilterBox	top_k	输出框数, 暂不支持, 配置时不生效	NA	NA	NA
Sort	multi_class_sorting	是否使用多类sort, 必须配置为表格中网络对应数值	false	false	false
	top_k	输出框数	[1~10000]	[1~10000]	[1~10000]
Nms	top_k	输出框数	[1~10000]	[1~10000]	[1~10000]

4.3.3 Faster RCNN 网络


Faster RCNN Proposal层硬化结构如[图4-1](#)所示。

输出给Proposal硬化后的DetectionOutput层的得分数据类型必须是float类型, 并且此Softmax层和Proposal硬化层之间不能有任何计算层, 参考如下所示:

```
layer {
  name: "rpn_cls_prob"
  type: "Softmax"
  bottom: "rpn_cls_score_reshape"
  top: "rpn_cls_prob"
}
```

Proposal硬化层描述请参考“[算子规格说明](#)”中[DetectionOutput](#)章节。

图 4-1 Faster RCNN Proposal 层硬化结构图



Faster RCNN Proposal硬化层的输入为两个tensor，分别对应图4-1中的bottom0以及bottom1。假设N为锚点的总数量，则bottom0的维度为 $1 \times 1 \times 1 \times N$ ，bottom1的维度为 $1 \times 1 \times 4 \times N$ ，输入数据为大于0的float类型数据。DecBbox层中心点宽高的具体计算公式如下：

$$DecCx = priWidth * dx(P) + priCx$$

$$DecCy = priHeight * dy(P) + priCy$$

$$DecWidth = \exp(dw(P)) * priWidth$$

$$DecHeight = \exp(dh(P)) * priHeight$$

其中DecCx, DecCy, DecWidth, DecHeight分别对应检测框的中心点和宽高；priWidth, priHeight, priCx, priCy为锚点的宽高和中心点坐标。锚点的坐标由外部输入文件anchor.txt（对应[generate_anchors_file]配置项）提供。具体格式为N行4列的数据，N为锚点的数量，4列数据分别对应锚点的xmin, ymin, xmax, ymax，输入数据为大于0的整数，数据类型为float类型。其他四组输入dx(P), dy(P), dw(P), dh(P)与图中的bottom对应。具体细节可参考sample用例。

Faster RCNN Proposal硬化层的输出信息由两个report层构成。第一个report层的输出信息为检测框的数量，第二个report层的输出信息为：xmin, ymin, xmax, ymax, 得分以及类别，检测框的输出顺序按分数由大到小排列。假设最终有300个检测框，则第一个report层的输出信息为：检测框数量(300)；第二个report层的信息为：检测框的xmin（300个xmin），检测框的ymin（300个ymin），检测框的xmax（300个xmax），检测框的ymax(300个ymax)，对应的框的得分(300个分数，由大到小)，以及对应的框的类别（300个classs ID）。注意，由于proposal层的类别信息（即classID）仅分为前景和背景，图中bottom0只对应前景的分数信息，因此实际最终的输出信息只有前景的检测框的个数、坐标、分数以及classID。

4.3.4 RFCN 网络


RFCN Proposal层硬化结构如图4-2所示，发布包中提供了基于resnet50的sample：samples/2_object_detection/rfc/rfc_resnet50，请参考此示例进行适配。

输出给Proposal硬化后DetectionOutput层的得分数数据类型必须是float类型，并且此Softmax层和Proposal硬化层之间不能有任何计算层，如下所示：

```
layer {
  name: "rpn_cls_prob"
  type: "Softmax"
  bottom: "rpn_cls_score_reshape"
  top: "rpn_cls_prob"
}
```

Proposal硬化层描述请参考samples/2_object_detection/rfc/rfc_resnet50/caffe_model/rfc_resnet50.prototxt。

图 4-2 RFCN Proposal 层硬化结构图



RFCN网络Proposal硬化层的输入输出与Faster RCNN Proposal一致，此处不再赘述。

4.3.5 SSD 网络

SSD DetectionOutput层硬化结构如图4-3所示，发布包中提供了sample: samples/2_object_detection/ssd，请参考此示例进行适配。


输出给DetectionOutput硬化层的得分数据类型为float类型，并且此Softmax层和DetectionOutput硬化层之间不能有任何计算层，如下所示：

```
layer {
  name: "mbox_conf_softmax"
```

```
type: "Softmax"
bottom: "mbox_conf_permute"
top: "mbox_conf_softmax"
softmax_param {
  axis: 1
}
}
```

DetectionOutput硬化层描述请参考sample/samples/2_object_detection/ssd/caffe_model/ssd.prototxt。

图 4-3 SSD DetectionOutput 层硬化结构图



SSD网络的rpn模块输入由三个部分组成，分别对应上图中的mbox_conf_extract、permute层和RPN threshold。具体公式如下：

$$DecCx = Var1 * L0c1 * priWidth + priCx$$

$$DecCy = Var2 * L0c2 * priHeight + priCy$$

$$DecWidth = \exp(Var3 * L0c3) * priWidth$$

$$DecHeight = \exp(Var4 * L0c4) * priHeight$$

其中DecCx, DecCy, DecWidth, DecHeight分别对应检测框的中心点和宽高；Var1, Var2, Var3, Var4为调整系数；L0c1, L0c2, L0c3, L0c4为框的预测信息；priWidth, priHeight, priCx, priCy为锚点的中心点坐标和宽高。锚点的坐标以及调整系数由外部输入文件anchor.txt（对应 [generate_anchors_file]配置项）提供。具体格式为N行8列的数据，N为锚点的数量，8列数据分别对应锚点的xmin, ymin, xmax, ymax 以及调整系数var1, var2, var3, var4。

permute层提供 $L0c1, L0c2, L0c3, L0c4$ 坐标信息，维度为 $1 \times 1 \times 4 \times N$ ， N 为框的数量。

mbox_conf_extract提供分数信息和类别信息，维度为 $1 \times (C-1) \times 1 \times N$ ，其中 C 为包含背景类别的数量，减1表示去掉背景， N 为锚点数量。如果类别不需要去掉背景，请删除层mbox_conf_extract，直接mbox_conf_softmax输出给DetectionOutput层，修改DetectionOutput层的num_classes 为包含背景类别数。


rpn_threshold提供4个阈值，分别是nms_threshold、low_score_threshold、min_height、min_width，ATC转换模型时自动加的数据层，在板端ACL运行时通过data层输入。

SSD的输出信息由两个report层构成，第一个report层的输出信息为检测框输出的数量，第二个report层的信息为xmin, ymin, xmax, ymax, 得分以及类别，检测框的输出顺序按分数由大到小排列。假设最终有300个检测框，则第一个report层输出的信息依次为：检测框数量(300)；第二个report层输出的信息为：检测框的xmin (300个xmin)，检测框的ymin (300个ymin)，检测框的xmax (300个xmax)，检测框的ymax(300个ymax)，对应的框的得分(300个分数，由大到小)，以及对应的框的类别 (300个class ID)。

4.3.6 YOLOV1 网络

YOLOV1 DetectionOutput层硬化结构如图4-4所示，发布包中提供了sample:samples/2_object_detection/yolo，请参考此示例进行适配。

图 4-4 YOLOV1 DetectionOutput 层硬化结构图



YOLOV1的输入维度为 $1 \times 1 \times (C + 5) \times N$ 的tensor，数据类型为float类型，其中C为类别的数量，N为检测框的个数。图4-4中直观的显示了rpn层输入的组成部分，左边的permute层对应类别信息，维度为 $1 \times 1 \times C \times N$ ；中间的permute层对应坐标的信息，维度为 $1 \times 1 \times 4 \times N$ ，对应的取值范围为[0, 1]；reshape层对应分数的信息，维度为 $1 \times 1 \times 1 \times N$ 。这三个层被concat层连接成 $1 \times 1 \times (C + 5) \times N$ 的tensor作为rpn层的输入。其计算公式如下：

x方向（y方向计算流程与x方向类似）：

$$cX = (col + x) / gridNumWidth$$

$$halfW = w * w * 0.5$$

$$pMinX = cX - halfW$$

$$pMaxX = cX + halfW$$

score:

$$finalScore = objScore * classScore$$



其中col为列索引，gridNumWidth为锚点宽，x和w为上一层的输出，cX为检测框中心点x坐标，halfW为检测框宽*0.5，pMinX为检测框Xmin，pMaxX为检测框Xmax。objScore和classScore为上一层的输出，finalScore为最终分数。

YOLOV1的输出信息由两个report层构成，第一个report层输出各类别检测框输出的数量，第二个report层输出各类别检测框的xmin, ymin, xmax, ymax, 得分以及类别，每一类的排序按检测框的输出顺序按分数由大到小排列。


4.3.7 YOLOV2 网络

YOLOV2 DetectionOutput层硬化结构如[图4-5](#)所示，发布包中提供了sample: samples/2_object_detection/yolo，请参考此示例进行适配。

须知

DetectionOutput输出的是 $1 \times 1 \times 6 \times \text{top_k}$ 的格式，类别中存放得分最高的分类序号，同YOLOV2/V3中的 $1 \times \text{class_num} \times 6 \times \text{top_k}$ 不同。

图 4-5 YOLOV2 DetectionOutput 层硬化结构图



YOLOV2相比于YOLOV1在计算检测框宽高时增加了bias1, bias2两个参数。其中bias1和bias2的需要在prototxt中配置, bias1和bias2的数量等于每个grid内锚点的数量的两倍, 输出顺序依次为每个锚点的bias1以及每个锚点的bias2。假设每个grid内一共有3个锚点, 则需要输入的对应的bias顺序为: 锚点0的bias1, bias2; 锚点1的bias1, bias2以及锚点2的bias1, bias2。数据类型为float, 取值范围为大于0的浮点数。详细设置可参照sample中的测试用例。YOLOV2的输入tensor规格与YOLOV2相同, 对应图4-5中的最后一个permute层, 此处不再赘述。其计算公式如下:

x方向 (y方向计算流程与x方向类似) :

$$cX = (\text{sigmoid}(X) + \text{col}) / \text{gridNumWidth} * \text{img_w}$$

$$\text{halfW} = \exp(w) * \text{bias} / \text{gridNumWidth} * 0.5 * \text{img_w}$$

$$pMinX = cX - \text{halfW}$$

$$pMaxX = cX + halfW$$

score:

$$finalScore = sigmoid(objScore) * max(softmax(classScore))$$


其中col为列索引, gridNumWidth为锚点宽, x和w为上一层的输出, bias为锚点参数, cX为检测框中心点x坐标, halfW为检测框宽*0.5, pMinX为检测框Xmin, pMaxX为检测框Xmax。objScore和classScore为上一层的输出, finalScore为最终分数。

YOLOV2的输出信息由两个report层构成, 第一个report层输出检测框的数量, 第二个report层输出各类别检测框的xmin, ymin, xmax, ymax, 得分以及类别, 按检测框的输出顺序按分数由大到小排列。假设最终有300个检测框, 则第一个report层为输出检测框数量(300); 第二个report层输出检测框的xmin (300个xmin), 检测框的ymin (300个ymin), 检测框的xmax (300个xmax), 检测框的ymax(300个ymax), 对应的框的得分(300个分数, 由大到小), 以及对应的框的类别 (300个classs ID)。

4.3.8 YOLOV3/V4/V5/V7 网络

YOLOV3/V4/V5/V7 DecBBox/DetectionOutput层硬化结构如图4-6所示, 发布包中提供了sample: samples/2_object_detection/yolo, 请参考此示例进行适配。仅Hi3519DV500 YOLOV3/V4/V5/V7支持所类别多阈值功能, 且最大支持80类阈值配置, 其中ONNX DecBBox算子中multi_label属性需要配置为1, 不支持高精度。当配置多个阈值时, 启动多类别多阈值功能, 其中YOLOV3/V4会损失17%左右的性能, YOLOV5/V7会损失60%左右的性能。

图 4-6 YOLOV3/V4/V5/V7 DecBBox/DetectionOutput 层硬化结构图



YoloV3/V4/V5/V7的输入tensor规格以及prototxt中bias的规格与YOLOV2相同, 此处不再赘述。YOLOV3/V4的计算公式如下:

x方向（y方向计算流程与x方向类似）：

$$cX = (\text{sigmoid}(X) + \text{col}) / \text{gridNumWidth} * \text{img_w}$$

$$\text{halfW} = \exp(w) * \text{bias} * 0.5$$

$$pMinX = cX - \text{halfW}$$

$$pMaxX = cX + \text{halfW}$$

score:

$$\text{finalScore} = \text{sigmoid}(\text{objScore}) * \max(\text{sigmoid}(\text{classScore}))$$

YOLOV5/V7的计算公式如下：

x方向（y方向计算流程与x方向类似）：

$$cX = (2 * \text{sigmoid}(X) - 0.5 + \text{col}) / \text{gridNumWidth} * \text{img_w}$$

$$\text{halfW} = 2 * \text{sigmoid}(w) * 2 * \text{sigmoid}(w) * \text{bias} / \text{gridNumWidth} * 0.5 * \text{img_w}$$

$$pMinX = cX - \text{halfW}$$

$$pMaxX = cX + \text{halfW}$$

score:

$$\text{finalScore} = \text{sigmoid}(\text{objScore}) * \max(\text{sigmoid}(\text{classScore}))$$


其中col为列索引，gridNumWidth为锚点宽，x和w为上一层的输出，bias为锚点bias参数，cX为检测框中心点x坐标，halfW为检测框宽*0.5，pMinX为检测框Xmin，pMaxX为检测框Xmax。objScore和classScore为上一层的输出，finalScore为最终分数。

YoloV3/V5/V7的输出信息由两个report层构成，第一个report层输出检测框的数量，第二个report层输出各类别检测框的xmin, ymin, xmax, ymax, 得分以及类别，按检测框的输出顺序按分数由大到小排列。假设最终有300个检测框，则第一个report层为输出检测框数量(300)；第二个report层输出检测框的xmin（300个xmin），检测框的ymin（300个ymin），检测框的xmax（300个xmax），检测框的ymax(300个ymax)，对应的框的得分(300个分数，由大到小)，以及对应的框的类别（300个class ID）。

4.3.9 YOLOV8 网络

YOLOV8DecBBox/Sort/Nms/Filter层硬化结构图如图4-7所示，发布包提供了sample:samples/2_object_detection/yolo，请参考此示例进行适配。

图 4-7 YOLOV8 DecBBox/Sort/Nms/Filter 层硬化结构图



YOLOV8的输入tensor规格、输出信息与YOLOV2相同，此处不再赘述。

坐标计算部分由DecBBox之前的算子实现，参考YOLOV8源码，采用DFL损失函数。

score在DecBBox中计算，计算公式如下：


$$finalScore = \max(\text{sigmoid}(\text{classScore}))$$

4.3.10 Hi3516CV610 检测网后处理流程

Hi3516CV610在sample中提供了SSD、YOLOV3、YOLOV5、YOLOV7、YOLOV8官方模型的处理步骤，其对应caffe、onnx以及om模型的后缀名为"_new_rpn"，后处理流程如图4-8所示。其sample的部署详见发布包：samples/2_object_detection/yolo(ssd)。

其中FilterVector算子介绍和参数配置方法详见FilterVector和FilterVector章节。受硬件限制，与Hi3519DV500的Filter算子相比，Hi3516CV610的FilterVector算子的输入为向量，且支持top_k配置，当top_k配置值小于实际框数量时，只会保留前top_k个符合阈值要求的框。

图 4-8 Hi3516CV610 检测网后处理流程图



4.4 Transformer 网络硬化加速

针对SwinT、MOTR等Transformer网络，对网络进行定制化修改，通过新增算子、扩展已有算子规格、增加网络优化特性等，实现网络在芯片上部署和硬化加速。对Transformer网络的定制化修改中，以CNN为基础进行等效替换，整个网络的数据流从HWC转置为CHW实现，Q、K、V的Attention操作均转为Conv实现，同时对数据变形、转置、切分和合并等操作进行融合，转化为利于硬件加速的等效算子实现。


4.4.1 SwinT 网络

SwinT网络新增算子包含Roll、WinPartition、WinPartitionReverse、LayerNorm、Gelu2。

Roll

Roll算子封装了一系列Slice、Concat操作，对应onnx网络结构如图4-9所示。算子规格详见"Roll"。


图 4-9 Roll 算子对应原生 onnx 网络结构



WinPartition

WinPartition算子封装了一系列Reshape、Transpose等操作，对应onnx网络结构如图4-10所示。算子规格详见"WinPartition"。


图 4-10 WinPartition 算子对应原生 onnx 网络结构



WinPartitionReverse

WinPartitionReverse算子对应WinPartition的逆操作，封装了一系列Reshape、Transpose等操作，对应onnx网络结构如图4-11所示。算子规格详见"WinPartitionReverse"。

图 4-11 WinPartitionReverse 算子对应原生 onnx 网络结构



LayerNorm

仅支持对单个维度进行layernorm运算，算子规格详见"[LayerNorm](#)"

Gelu

算子规格详见"[Gelu](#)"。


4.4.2 MOTR 网络

MOTR网络新增算子包含InverseSigmoid、GridSampleXDec、PosEncode、MulReduceSum。

InverseSigmoid

InverseSigmoid为Sigmoid的逆过程，公式为 $y = -\log((1/x) - 1)$ ，对应onnx网络结构如[图4-12](#)所示。算子规格详见"[InverseSigmoid](#)"。


图 4-12 InverseSigmoid 对应原生 onnx 网络结构



GridSampleXDec

GridSampleXDec算子封装了一系列Reshape、Transpose、Slice、Squeeze、Div、Sub、Mul、Add、GridSample等操作，对应onnx网络结构如[图4-13](#)所示。算子规格详见"[GridSampleXDec](#)"。


图 4-13 GridSampleXDec 算子对应原生 onnx 网络结构



PosEncode

PosEncode算子封装了一系列Squeeze、Transpose、Mul、Unsqueeze、Div、Sin、Cos、Concat、Reshape等操作，对应onnx网络结构如[图4-14](#)所示。算子规格详见"[PosEncode](#)"。


图 4-14 PosEncode 对应原生 onnx 网络结构



MulReduceSum

MulReduceSum封装了Gather、Unsqueeze、Mul、Reducesum、Reshape等操作，对应onnx网络结构如图4-15所示。算子规格详见"[MulReduceSum](#)"。

图 4-15 MulReduceSum 对应原生 onnx 网络结构





5 算子规格说明

须知

- Caffe与Onnx框架算子规格中，如无特别说明，输入、输出形状支持范围如下：
向量：channel ≤ 65535 ，矩阵：width ≤ 65535 ，张量：width ≤ 65535
分辨率要求channel对齐到8后，所有维度的乘积不能超过1073741824。
- 算子规格的参数数据类型为ATC算子的数据类型，与Onnx/Caffe 不一致的数据类型将强转为ATC算子的数据类型。

5.1 Caffe 框架算子规格

该算子规格仅适用于Caffe框架原生IR定义的网络模型。

其他约束：不支持层名为空。

Hi3516CV610约束：如算子无特殊说明，不支持输入或输出存在轴长度超过65535。

5.1.1 图像分析引擎

5.1.1.1 AbsVal

功能描述：求绝对值。支持高维度输入。

5.1.1.2 ArgMax

功能描述：沿某轴找出topk值及索引(因硬件限制，当前只支持top 1)。

规格约束：不支持5D shape输入

参数名	数据类型	参数含义	规格
out_max_val	bool	默认为false, 如果为true, 生成pair(argmax, maxval)	支持



参数名	数据类型	参数含义	规格
top_k	uint32	最大的k个值	只支持配置为1
axis	uint32	无默认值，表示取top_k值的维度，若不设该值，则表示将所有维度flatten之后，再应用top_k取值	支持配置[-4,3]，但取-4和0时会报错。 Hi3519DV500： 不支持对argmax轴进行切分。没有配置axis时，须满足输入channel × height × width < 65536，且均小于65536。配置axis轴时，argmax轴应小于65536。 Hi3516CV610： 不支持对argmax轴进行切分。没有配置axis时，须满足输入channel × height × width < 4096。配置axis轴时，argmax轴应小于4096。

5.1.1.3 BatchNorm

功能描述：数据归一化。

参数名	数据类型	参数含义	规格
use_global_stats	bool	false表示使用滑动平均；true表示使用全局的，不每次进行计算	支持
moving_average_fraction	float	默认为.999，每次迭代滑动平均衰减系数	不解析生效
eps	float	默认为1e-5，用来防止被0除	支持配置

5.1.1.4 Bias

功能描述：计算两个输入数据的和。

参数名	数据类型	参数含义	规格
axis	int32	默认为1，不同的值对应的相加维度不同	支持配置范围为[-4, 3]，默认为1，遵循caffe规则
num_axes	int32	默认为1，当只有一个bottom时有效，指定训练的bias参数维度大小，-1表示从axis指定的轴开始的全部维度，0表示参数只有一个scalar	与axis配套使用，遵循caffe规则

5.1.1.5 BNLL

功能描述：按照一固定公式计算，激活函数。支持高维度输入。



5.1.1.6 Clip

功能描述：数据截断。

Hi3516CV610 规格约束：参数max的值必须不小于参数min的值，如果不满足约束，将按照[min, min]的边界条件对数据进行截断

参数名	数据类型	参数含义	规格
min	float	截断的最小值	支持，配置范围： [-65504,65504]
max	float	截断的最大值	支持，配置范围： [-65504,65504]

5.1.1.7 Concat

功能描述：至少两个输入，将它们在某个维度上拼接起来，支持高维度输入。

参数名	数据类型	参数含义	规格	其他约束
axis	int32	默认为1，表示哪个维度concat，可以为负数	支持配置， 令dim表示输入shape的维数，如NCHW的维数为4，按如下两种情况配置属性： 1. dim等于4且第0维等于1场景，支持配置 [-4, 3] 2. dim大于4，或者dim等于4且第0维非1场景，支持配置[-dim, -dim+axis_r1] U [-2, -1] U [dim-2, dim-1] U [0, axis_r1]。其中axis_r1为最左非1轴，即shape从左到右出现的第一个非1轴，如[1, 2, c, h, w]，则axis_r1=1。	-
concat_dim	uint32	跟axis含义相同，不支持负值	已废弃，不建议使用，axis与concat_dim不应同时使用。	bottom number<=32

5.1.1.8 Convolution

功能描述：对输入做卷积。

规格约束：

- Hi3519DV500：当Convolution的输入NCHW的N不等于1时，输入和输出channel 需满足以下条件： $(data_bit_num * channel) \% 64 == 0$ ，例如当输入



为8bit, channel需为8的倍数; 当Convolution输入是数据层时, 输入无上述限制; 支持图片输入, 支持的类型包括YUV420、YVU420、BGR_PLANNAR、RGB_PLANNAR、BGR_PACKAGE、RGB_PACKAGE; 不支持group > 1。

- Hi3516CV610: 当Convolution的输入NCHW的N不等于1时, 输入和输出channel都需为8的倍数; 不支持图片输入; 不支持group > 1; 不支持S16计算, 如果配置S16会回退为S8。

data_bit_num 表示计算数据位宽, 当计算数据类型为U4/S4时, data_bit_num = 4; 当计算数据类型为U8/S8时, data_bit_num = 8; 当计算数据类型为U16/S16时, data_bit_num = 16。

参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
num_output	uint32	输出的channel大小	支持配置, 最大32768	支持配置, 最大16384
bias_term	bool	默认为1, 表示是否加bias	支持配置0或1	
pad	uint32	默认为0, 表示补边的大小	支持, 配置范围: [0, 15]; 不能与pad_h或者pad_w同时配置	支持, 配置范围: [0, 7]; 不能与pad_h或者pad_w同时配置
kernel_size	uint32	kernel的大小	支持范围: [1, 64], 受dilation、输入数据类型和输出数据类型的影响	支持范围: [1, 15], 受dilation、输入数据类型和输出数据类型的影响
stride	uint32	默认为1, stride的大小	支持范围: [1, 255]	支持范围: [1, 16]
dilation	uint32	默认为1, dilation的大小	支持范围: [1, 15], 配置后 $(kernel-1) \times dilation + 1 \leq 255$	支持范围: [1, 8]
pad_h	uint32	默认为0, 表示height方向的padding	支持, 配置范围: [0, 15], 且须满足 $pad_h \leq (kernel_h-1) \times dilation_h + 1$; 不能与pad同时配置	支持, 配置范围: [0, 7], 且须满足 $pad_h \leq (kernel_h-1) \times dilation_h + 1$; 不能与pad同时配置
pad_w	uint32	默认为0, 表示width方向的padding	支持, 配置范围: [0, 15], 且须满足 $pad_w \leq (kernel_w-1) \times dilation_w + 1$; 不能与pad同时配置	支持, 配置范围: [0, 7], 且须满足 $pad_w \leq (kernel_w-1) \times dilation_w + 1$; 不能与pad同时配置
kernel_h	uint32	kernel的height大小	支持, 配置范围: [1, 255]	支持, 配置范围: [1, 15]
kernel_w	uint32	kernel的width大小	支持, 配置范围: [1, 255]	支持, 配置范围: [1, 15]
stride_h	uint32	stride的height大小	支持范围: [1, 255]	支持范围: [1, 16]
stride_w	uint32	stride的width大小	支持范围: [1, 255]	支持范围: [1, 16]



参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
group	uint32	默认为1，group的大小	支持	
axis	int32	默认为1，axis值之前的维度认为是独立输入，axis之后的维度认为是空间维度，即在做卷积时会求和。	不支持配置	

5.1.1.9 CReLU

功能描述：激活函数 $CReLU(x)=[ReLU(x), ReLU(-x)]$ 。

5.1.1.10 Crop

功能描述：数据裁剪。

参数名	数据类型	参数含义	规格
axis	int32	默认为2，裁剪维度	支持，配置范围：[-4, 3]
offset	uint32	默认为0，裁剪偏移	支持，配置范围：[0, UINT32_MAX]

5.1.1.11 Deconvolution

功能描述：卷积的反过程，将卷积的前向传播和后向传播置换。

规格约束：(dilation × (kernel - 1)) 大于等于pad。当输入NCHW的N不等于1时，不支持。

参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
num_output	uint32	输出的channel大小	支持配置，最大32768	支持配置，最大16384；
bias_term	bool	默认为1，表示是否加bias	支持配置0或1	
pad	uint32	默认为0，表示补边的大小	支持，配置范围：[0, 15]，kernel、stride和dilation影响支持范围；不能与pad_h或者pad_w同时配置	支持，配置范围：[0, 7]，kernel、stride和dilation影响支持范围；不能与pad_h或者pad_w同时配置



参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
kernel_size	uint32	kernel的大小	支持范围：[1,64]，受dilation、input_channel、输入数据类型和输出数据类型的影响	支持范围：[1,15]，受dilation、input_channel、输入数据类型和输出数据类型的影响
stride	uint32	默认为1，stride的大小	支持范围：[1, 255]	支持范围：[1, 16]
dilation	uint32	默认为1，dilation的大小	支持范围：[1, 15]，配置后 $(kernel-1)*dilation+1 \leq 255$;	支持范围：[1, 8]
pad_h	uint32	默认为0，表示height方向的padding	支持，配置范围：[0, 15]，kernel、stride和dilation影响支持范围；不能与pad同时配置	支持，配置范围：[0, 7]，kernel、stride和dilation影响支持范围；不能与pad同时配置
pad_w	uint32	默认为0，表示width方向的padding	支持，配置范围：[0, 15]，kernel、stride和dilation影响支持范围；不能与pad同时配置	支持，配置范围：[0, 7]，kernel、stride和dilation影响支持范围；不能与pad同时配置
kernel_h	uint32	kernel的height大小	支持，配置范围：[1, 255]	支持，配置范围：[1, 15]
kernel_w	uint32	kernel的width大小	支持，配置范围：[1, 255]	支持，配置范围：[1, 15]
stride_h	uint32	stride的height大小	支持范围：[1, 255]	支持范围：[1, 16]
stride_w	uint32	stride的width大小	支持范围：[1, 255]	支持范围：[1, 16]
group	uint32	默认为1，group的大小	支持	
axis	int32	默认为1，axis值之前的维度认为是独立输入，axis之后的维度认为是空间维度，即在做卷积时会求和。	不支持配置	

5.1.1.12 DepthwiseConv

功能描述：对输入做卷积。

规格约束：

pad与pad_h/pad_w参数不可以同时配置。

- Hi3519DV500：需满足 $kernel_h * ALIGN128(kernel_w * 8 * data_bit_num) / 8 \leq 3 * 131072$ ；当DepthwiseConv的输入NCHW的N不等于1时，输入和输出channel



需满足以下条件：(data_bit_num * channel) % 64 == 0，例如当输入为8bit，channel需为8的倍数。

- Hi3516CV610: 需满足 $\text{kernel_h} * \text{ALIGN128}(\text{kernel_w} * 8 * \text{data_bit_num}) / 8 \leq 3 * 16384$

data_bit_num 表示计算数据位宽，当计算数据类型为U4/S4时，data_bit_num = 4；当计算数据类型为U8/S8时，data_bit_num = 8；当计算数据类型为U16/S16时，data_bit_num = 16。

参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
num_output	uint32	输出的channel大小	支持配置，最大32768，需要= input_channel	支持配置，最大16384，需要= input_channel
bias_term	bool	默认为1，表示是否加bias	支持配置0或1	
pad	uint32	默认为0，表示补边的大小	支持，配置范围：[0, 15]，且 $\text{pad} \leq \text{kernel_size}$ ；不能与pad_h或者pad_w同时配置	支持，配置范围：[0, 7]，且 $\text{pad} \leq \text{kernel_size}$ ；不能与pad_h或者pad_w同时配置
kernel_size	uint32	kernel的大小	支持范围：[1, 64]，受dilation、stride、input_channel、输入数据类型和输出数据类型的影响	支持范围：[1, 15]，受dilation、stride、input_channel、输入数据类型和输出数据类型的影响
stride	uint32	默认为1，stride的大小	支持范围：[1, 255]	支持范围：[1, 16]
dilation	uint32	默认为1，dilation的大小	支持范围：[1, 15]，配置后 $(\text{kernel}-1) * \text{dilation} + 1 \leq 255$	支持范围：[1, 8]
pad_h	uint32	默认为0，表示height方向的padding	支持，配置范围：[0, 15]，且 $\text{pad_h} \leq \text{kernel_h}$ ；不能与pad同时配置	支持，配置范围：[0, 7]，且 $\text{pad_h} \leq \text{kernel_h}$ ；不能与pad同时配置
pad_w	uint32	默认为0，表示width方向的padding	支持，配置范围：[0, 15]，且 $\text{pad_w} \leq \text{kernel_w}$ ；不能与pad同时配置	支持，配置范围：[0, 7]，且 $\text{pad_w} \leq \text{kernel_w}$ ；不能与pad同时配置
kernel_h	uint32	kernel的height大小	支持，配置范围：[1, 255]	支持，配置范围：[1, 15]
kernel_w	uint32	kernel的width大小	支持，配置范围：[1, 255]	支持，配置范围：[1, 15]



参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
stride_h	uint32	stride的height大小	支持范围: [1, 255]	支持范围: [1, 16]
stride_w	uint32	stride的width大小	支持范围: [1, 255]	支持范围: [1, 16]
axis	int32	默认为1, axis值之前的维度认为是独立输入, axis之后的维度认为是空间维度, 即在做卷积时会求和。	不支持配置	

5.1.1.13 DetectionOutput

功能描述: RPN 硬化层。

参数名	数据类型	参数含义	规格
param_type	ParamType	RPN硬化层类型	支持, 4种类型DecBBBox, Sort, Nms, FilterBox
calc_mode	uint32	默认为0, DecBBBox的网络类型	支持7种类型 0: RCNN (Hi3516CV610不支持) 1: YOLOV1 (Hi3516CV610不支持) 2: YOLOV2 (Hi3516CV610不支持) 3: YOLOV3/V4 4: SSD 5: YOLOV5/V7 8: YOLOV8
top_k	uint32	默认为1, 输出框的个数	支持, 值域[1, 10000]
num_classes	uint32	默认为0, 分类数目	支持, 值域[1, 1000]。 YOLOV1/V2/V3/V4/V5/V7需要满足num_classes + 5 = input_h, YOLOV8需要满足num_classes + 4 = input_h
multi_class_sorting	bool	默认为false, 是否多类sort	支持
num_anchors	uint32	默认为0, 锚点数	支持, 值域[1, 524288], 需要满足num_anchors% (num_grids_width*num_grids_height) = 0。对于YOLO网络, 需要满足num_anchors=input_w



参数名	数据类型	参数含义	规格
num_coords	uint32	默认为4, 坐标数	支持, 仅支持4
share_location	bool	默认为false, 是否是共享位置预测	支持
share_variance	bool	默认为false, 是否共享方差	支持, SSD网络必须配置为false
clip_bbox	bool	默认为true, 是否使能框裁剪	仅支持true
code_type	CodeType	编码类型	仅支持CENTER_SIZE
bias	float	默认为0, 偏置	YOLOV2/V3/V5/V7网络必须配置,且满足 $\text{bias.size}/2=(\text{input_w}/(\text{num_grids_width} * \text{num_grids_height}))$ 。值域: [0,1024]。
variance	float	默认为0, 方差	支持SSD网络必须配置, 且个数必须为4, 值域: [0,1.0]
num_grids_width	uint32	YOLO网络栅格Width	YOLO网络必须配置,值域[1, 1024]
num_grids_height	uint32	YOLO网络栅格Height	YOLO网络必须配置,值域[1, 1024]

5.1.1.14 Eltwise

功能描述: 进行elementwise的计算操作, 包括相加、相乘、求最大。支持高维度输入。

参数名	数据类型	参数含义	规格
operation	EltwiseOp	默认为SUM, element-wise的操作, 加、乘、求最大	支持, 相加、相乘、求最大
coeff	float	blob_wise系数	仅在operation为相加时支持
stable_prod_grad	bool	对于乘操作, 大于两输入的情况, 选择是否使用更慢但更稳定的方法求梯度	不支持配置

5.1.1.15 ELU

功能描述: 一种固定公式的激活函数。支持高维度输入。

参数名	数据类型	参数含义	规格
alpha	float	默认为1, 公式中的alpha系数	支持



5.1.1.16 Exp

功能描述：计算exp。支持高维度输入。

参数名	数据类型	参数含义	规格
base	float	默认为-1.0	支持，-1或是正数
scale	float	默认为1.0	支持
shift	float	默认为0.0	支持

5.1.1.17 Extract

功能描述：沿某个维度切割输入数据，输出1个切割的数据。

参数名	数据类型	参数含义	规格
axis	int32	默认为1	支持，配置范围：[-4, 3]
slice_point_begin	uint32	默认为0	支持
slice_point_end	uint32	默认为1	支持

5.1.1.18 Flatten

功能描述：将输入的blob转成向量。支持高维度输入。

参数名	数据类型	参数含义	规格
axis	int32	flatten开始的维度	axis取值范围：[-4, 3]，默认值为1，-4与0含义相同。不支持N维度。
end_axis	int32	flatten结束的维度	end_axis取值范围：[-4, 3]，默认值为-1，表示最后一条轴。End_axis应大于axis。

5.1.1.19 GRU

功能描述：GRU网络，若前接非Data层，不支持非Data层的输出数据维度为4维。

参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
num_output	uint32	默认为0，输出的维度大小	支持，最大支持8192	支持，最大支持1872
debug_info	bool	默认为false，是否输出debug_info	不支持配置	



参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
expose_hidden	bool	默认为false，表示是否增加额外输入输出层，对于GRU是同时增加1层	支持配置false或true	

5.1.1.20 Hswish

功能描述：激活函数h-swish(x)= $x * \text{ReLU6}(x+3)/6$ 。支持高维度输入。

参数名	数据类型	参数含义	规格
negative_slope	float	默认为0，负值的斜率	支持

5.1.1.21 InnerProduct

功能描述：全连接层，计算内积。支持2、3、4维输入。

规格约束：当axis=1且输入数据为3维时，最高维仅支持1，其他情况支持最高维大于1。

参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
num_output	uint32	输出的维度大小	支持，最大支持32768	支持，最大支持16384
bias_term	bool	是否加bias	支持配置0或1	
axis	int32	默认为1，进行内积计算的维度	当Recurrent层后面紧接FC，或两者通过其他算子间接相连时，支持且仅支持axis=2，其他场景不支持配置。	
transpose	bool	是否转置权值矩阵	支持配置0或1	

5.1.1.22 Input

功能描述：输入层。支持高维度输入。

参数名	数据类型	参数含义	规格
shape	BlobShape	定义blob的大小，可以每个分别定义，可以统一定为同样大小，可以不定	支持最大input节点和输出节点加起来不能超过32个



5.1.1.23 Interp

功能描述：计算双线性插值。

参数名	数据类型	参数含义	规格	其他约束
height	uint32	输出的height大小	支持配置	不支持zoom_factor和shrink_factor同时配置 $Out = In + (In - 1) \times (zoom_factor - 1);$ $Out = (In - 1) / shrink_factor + 1;$ 仅支持通过负补边对输入进行裁剪； 仅支持Tensor输入； 输入输出w（补边后）不支持超过65535 输入w和h（补边后）不支持单独为1，但支持同时为1
width	uint32	输出的width大小	支持配置	
zoom_factor	uint32	默认为1，输出的放大倍数	支持配置，优先级高于height/width	
shrink_factor	uint32	默认为1，输出的缩小倍数	支持配置，优先级高于height/width	
pad_beg	uint32	默认为0，左补边和上补边的大小	支持配置为非正整数	
pad_end	uint32	默认为0，右补边和下补边的大小	支持配置为非正整数	

5.1.1.24 Log

功能描述：计算log。支持高维度输入。

参数名	数据类型	参数含义	规格
base	float	默认为-1.0	支持-1和除了1的任意正数
scale	float	默认为1.0	支持任意值
shift	float	默认为0.0	支持任意值

5.1.1.25 LRN

功能描述：一种normalization的方法。

参数名	数据类型	参数含义	规格
local_size	uint32	默认为5	支持3、5、7，需要满足Channel大于等于local_size
alpha	float	默认为1.0	支持
beta	float	默认为0.75	支持
norm_region	NormRegion	默认为ACROSS_CHANNELS	只支持ACROSS_CHANNELS
k	float	默认为1.0	不能为负数



5.1.1.26 LSTM

功能描述：LSTM网络，若前接非Data层，不支持非Data层的输出数据维度为4维。

参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
num_output	uint32	默认为0，输出的维度大小	支持，最大支持8192	支持，最大支持1872
debug_info	bool	默认为false,是否输出debug_info	不支持配置	-
expose_hidden	bool	默认为false,表示是否增加额外输入输出层，对于LSTM是同时增加2层	支持配置true或false	-

5.1.1.27 MatMul

功能描述：两个输入数据做矩阵乘。

参数名	数据类型	参数含义	规格
dim_1	uint32	第1个矩阵的行，即第1个输入的height	支持
dim_2	uint32	第1个矩阵的列，即第1个输入的width 第2个矩阵的行，即第2个输入的width	支持
dim_3	uint32	第2个矩阵的列，即第2个输入的height	支持

5.1.1.28 Mish

功能描述：激活函数 $\text{mish}(x)=x*\tanh(\ln(1+\exp(x)))$ 。支持高维度输入。

5.1.1.29 MVN

功能描述： $x'=(x-\text{mean}(x))/\text{std}(x)$ 。

规格约束：仅支持4D输入，输入W需小于65536。

参数名	数据类型	参数含义	规格
normalize_variance	bool	默认为true, 设为false时只减均值	支持配置true或false



参数名	数据类型	参数含义	规格
across_channels	bool	默认为false, 设为true时则CHW视为一个向量	支持配置true或false
eps	float	默认为1e-9, 用来防止除0	支持配置

5.1.1.30 Nop

功能描述：数据搬运。

5.1.1.31 Normalize

功能描述：一种数据归一化的方法。

规格约束：当运算轴为C轴，此时C的大小不得超过4096。

参数名	数据类型	参数含义	规格
across_spatial	bool	默认为true	只支持配置为false
channel_shared	bool	默认为true	支持
eps	float	默认为1e-10	支持
sqrt_a	float	默认为1	支持

5.1.1.32 PassThrough

功能描述：把height和width的数据展开到channel维度。

规格约束：只支持输入数据类型为NCHW，且输出C维度仅支持[1, 4096]。

参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
num_output	uint32	默认为0	支持[1, 4096]	
block_height	uint32	默认为0	支持[2, 255]	支持[2, 16]，且要被输入h整除
block_width	uint32	默认为0	支持[2, 255]	支持[2, 16]，且要被输入w整除

5.1.1.33 Permute

功能描述：数据转置。

规格约束：当存在以下场景规格时，用CPU进行计算



- 输入数据为4维场景，N轴与C轴发生交换，且N/C轴的长度均不为1
- N轴与H轴或W轴发生交换
- 输入数据维度高于4的场景，有维度高于C轴的轴参与转置
- C轴参与转置，并且所有维度高于C轴的轴长度乘积不小于1024

参数名	数据类型	参数含义	规格
order	uint32	整型数组	支持

5.1.1.34 Pooling

功能描述：对输入做pooling。

规格约束：

- Hi3519DV500 需满足 $\text{kernel_h} * \text{ALIGN128}(\text{kernel_w} * 8 * \text{dataBit}) / 8 \leq 7 * 128K$ 。
- Hi3516CV610 需满足 $\text{kernel_h} * \text{kernel_w} * 8 * \text{dataByte} \leq 4 * 16K$ ；当输入数据为Fp32,运算数据为S8时，需满足 $\text{kernel_h} * \text{kernel_w} * 8 * 2\text{Byte} + \text{kernel_h} * \text{kernel_w} * 8 \leq 4 * 16K$
- 部分超出图像分析引擎规格的用CPU进行计算
- MAX模式下同时输出最大值索引（即算子有两路输出）时，仅支持接upsample算子
- 支持NCHW格式， $N \geq 1$

参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
pool	PoolMethod	默认为MAX，pooling的类型，另一种是AVE	支持	
pad	uint32	默认为0，表示补边的大小	支持，配置范围：[0, 15]	支持，配置范围：[0, 11]
pad_h	uint32	默认为0，表示height方向的padding	支持，配置范围：[0, 15]	支持，配置范围：[0, 11]
pad_w	uint32	默认为0，表示width方向的padding	支持，配置范围：[0, 15]	支持，配置范围：[0, 11]
pad_up	uint32	默认为0，表示上面的padding	支持，配置范围：[0, 15]	支持，配置范围：[0, 11]
pad_down	uint32	默认为0，表示下面的padding	支持，配置范围：[0, 15]	支持，配置范围：[0, 11]
pad_left	uint32	默认为0，表示左面的padding	支持，配置范围：[0, 15]	支持，配置范围：[0, 11]
pad_right	uint32	默认为0，表示右面的padding	支持，配置范围：[0, 15]	支持，配置范围：[0, 11]



参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
pad_value	float	默认为0，表示padding的值	支持，配置范围：[-65536,65536]，值约束范围在[输入的最小值，0]或[0, 输入的最大值]	
kernel_size	uint32	kernel的大小	支持，配置范围：[1, 255]	支持，配置范围：[1, 127]
kernel_h	uint32	kernel的height大小	支持，配置范围：[1, 255]	支持，配置范围：[1, 127]
kernel_w	uint32	kernel的width大小	支持，配置范围：[1, 255]	支持，配置范围：[1, 127]
stride	uint32	默认为1，stride的大小	支持，配置范围：[1, 255]，stride <= input_size	支持，配置范围：[1, 16]，stride <= input_size
stride_h	uint32	stride的height大小	支持，配置范围：[1, 255]，stride_h <= input_h	支持，配置范围：[1, 16]，stride_h <= input_h
stride_w	uint32	stride的width大小	支持，配置范围：[1, 255]，stride_w <= input_w	支持，配置范围：[1, 16]，stride_w <= input_w
round_mode	RoundMode	默认为CEIL，计算输出形状的取整方式。	支持配置CEIL或FLOOR	
global_pooling	bool	默认为false，是否全平面做pooling	支持配置0或1	

5.1.1.35 Power

功能描述： $f(x)=(\text{shift}+\text{scale}*x)^{\text{power}}$ 。支持高维度输入。

参数名	数据类型	参数含义	规格
power	float	默认为1.0	支持
scale	float	默认为1.0	支持
shift	float	默认为0.0	支持

5.1.1.36 PReLU

功能描述：带参数的ReLU激活函数。



参数名	数据类型	参数含义	规格
channel_shared	bool	默认为false，表示负向斜率是否channel共享	支持

5.1.1.37 PSROIPooling

功能描述：位置敏感的候选区域池化。

规格约束：第二路输入仅支持rpn层或者data层

参数名	数据类型	参数含义	规格
spatial_scale	float	rois映射到原始feature map的缩放比例系数，默认为0.0	支持
output_dim	int32	输出数据的channel，默认为0	支持
group_size	int32	输出数据的宽度和高度，默认为0	支持

5.1.1.38 Reduction

功能描述：将输入的blob reduction成一个scalar。支持高维度输入。

参数名	数据类型	参数含义	规格
operation	Reduction Op	默认为SUM，可选ASUM、SUMSQ、MEAN	支持SUM、ASUM、SUMSQ、MEAN
axis	int32	表示从第几个维度开始后面的维度全部reduction	走图像分析引擎需满足以下约束，其余走cpu模式 1、设r为输入数据维度，支持范围： $[1, r - 1] \cup [1 - r, -1]$ 。 2、输入数据维度小于4；或者输入数据维度为4，且第一维shape=1。
coeff	float	默认为1.0，输出的系数	支持

5.1.1.39 ReLU/ReLU6/RReLU

功能描述：ReLU激活函数。支持高维度输入。

参数名	数据类型	参数含义	规格
negative_slope	float	默认为0，负值的斜率	支持



5.1.1.40 Reorg

功能描述：Yolov2算子，Height和Width折叠到Channel的变形操作。

规格约束：只支持输入数据类型为NCHW。

参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
stride	uint32	折叠的像素。	支持[2, 255]，输出C维度支持[1, 4096]	支持[2, 16]，要被输入h/w整除，输出C维度支持[1, 4096]

5.1.1.41 Reshape

功能描述：维度变换。支持高维度输入。

参数名	数据类型	参数含义	规格
shape	BlobShape	指示输出的维度大小，0表示跟bottom一致，-1表示该维度由输入的blob及输出的其他维度决定	支持高维度输入。
axis	int32	默认为0，表示shape中第一数值与输出的第几个起始维度对应	默认为0，遵循caffe规则 特殊内容：当axis<0时，实际起始维度为axis+1。如当shape=NCHW时，axis=-2，意味着仅对W轴reshape。
num_axes	int32	默认为-1，表示从axis开始做几个维度的reshape	默认值-1表示对axis起始的所有轴进行变换

5.1.1.42 Reverse

功能描述：将输入在指定的轴上进行反转。



参数名	数据类型	参数含义	规格	其他约束
axis	int32	表示需要反转的轴	支持配置为0，若前后接Recurrent(LSTM/RNN/GRU)层，则表示在Recurrent层输入或输出的帧数轴上做反转。	- 输入和输出必须是Recurrent (LSTM/RNN/GRU) 层，或者reverse的参数axis对应的维度值为1。 - 仅支持输出给一个算子 - Reverse和Recurrent之间不支持上报

5.1.1.43 RNN

功能描述：RNN网络，若前接非Data层，不支持非Data层的输出数据维度为4维。

参数名	数据类型	参数含义	规格	
			Hi3519DV500	Hi3516CV610
num_output	uint32	默认为0，输出的维度大小	支持，最大支持8192	支持，最大支持1872
debug_info	bool	默认为false,是否输出debug_info	不支持配置	
expose_hidden	bool	默认为false,表示是否增加额外输入输出层，对于RNN是增加1层	支持配置0或1	

5.1.1.44 ROI Pooling

功能描述：目标检测的候选框区域池化。

规格约束：第二路输入仅支持rpn层或者data层。

参数名	数据类型	参数含义	规格
pooled_h	uint32	输出数据的高度，默认为0	支持
pooled_w	uint32	输出数据的宽度，默认为0	支持
spatial_scale	float	rois映射到原始feature map的缩放比例系数，默认为1	支持



5.1.1.45 Scale

功能描述：计算两个输入数据的乘，支持两个输入维度大小不一致。

参数名	数据类型	参数含义	规格
axis	int32	默认为1，输入的bottom[0]做scale的起始维度，axis不同则bottom[1]的shape不同	支持配置范围为[-4, 3]，默认值1，遵循caffe规则
num_axes	int32	默认是1，当只有一个bottom的时候有效，表示做scale的维度，-1表示axis开始全部，0表示是参数只有一个scalar	与axis配套使用，遵循caffe规则；
bias_term	bool	默认为false，表示是否加bias	支持配置0或1；

5.1.1.46 ShuffleChannel

功能描述：将c分成group个子组，并通过逐一从每个子组中选择元素获得新的顺序。

参数名	数据类型	参数含义	规格	其他约束
group	uint32	将c分成group组	支持配置[1, c]，小于等于0或者大于c会报错	仅支持输入为向量、3阶张量、4阶张量

5.1.1.47 Sigmoid

功能描述：sigmoid激活函数。支持高维度输入。

5.1.1.48 Slice

功能描述：沿某个维度切割输入的blob，输出多个切割的blob，支持高维度输入。

参数名	数据类型	参数含义	规格
axis	int32	默认为1，表示切块的维度	令dim表示输入shape的维数，如NCHW的维数为4，按如下两种情况配置属性： 1. dim等于4且第0维等于1场景，支持配置 [-4, 3] 2. dim大于4，或者dim等于4且第0维非1场景，支持配置[-dim, -dim + axis_r1] U [-2, -1] U [dim-2, dim-1] U [0, axis_r1]。其中axis_r1为最左非1轴，即shape从左到右出现的第一个非1轴，如[1, 2, c, h, w]，则axis_r1=1。



参数名	数据类型	参数含义	规格
slice_point	uint32	表示输出的各个blob的切割点，不定义的则均分	1. 支持，切割点数小于32。 2. slice_point应按从小到大顺序排列
slice_dim	uint32	默认为1，跟axis含义相同	1. 参考axis规格，不支持负数。 2. axis与slice_dim不应同时使用

5.1.1.49 Silence

功能描述：屏蔽输出。

规格约束：只支持连接Slice，且Slice两个输出，屏蔽Slice的其中一个输出。

5.1.1.50 Softmax

功能描述：计算softmax函数。

参数名	数据类型	参数含义	规格	其他约束
axis	int32	默认为1，计算softmax的维度	$(-r, r-1]$, $r = \text{rank}(\text{input})$, axis不为0 若r为5，axis不为-4, 1	axis 为1时: 向量 $\text{channel} \leq 65536$ 张量 $\text{channel} \leq 4096$

Hi3516CV610 需满足:

- 运算轴为axisC时， $5*16*1024*8 \geq \text{input_c} * \text{dataBit} / 2$;
- 运算轴为axisH/axisW时， $5*16*1024*8 \geq 4 * \text{input_axis} * \text{dataBit}$

5.1.1.51 Split

功能描述：复制输入的blob到多个节点。

5.1.1.52 SPP

功能描述：对不同的输入做金字塔的pooling，输出一样的大小。

参数名	数据类型	参数含义	规格	其他约束
pyramid_height	uint32	spp的高，即做 2^n 次 pooling	支持， 2^n 次， $n < 7$;	等同pool+reshape+concat的规格
pool	PoolMethod	默认为MAX，pooling的类型，另一种是AVE	支持，pooling kernel/小于等于255	



5.1.1.53 Swish

功能描述：激活函数 $\text{swish}(x) = x * \text{sigmoid}(\beta * x)$ 。支持高维度输入。

参数名	数据类型	参数含义	规格
beta	float	默认为1，表示x的scale系数	支持

5.1.1.54 TanH

功能描述：tanh激活函数。支持高维度输入。

5.1.1.55 Threshold

功能描述：输入与一个阈值相比较，大于则输出1，小于等于则输出0。支持高维度输入。

参数名	数据类型	参数含义	规格
threshold	float	默认为0	支持

5.1.1.56 Tile

功能描述：沿某个维度复制，支持高维度输入（ $\text{shape} > 4$ ）。

参数名	数据类型	参数含义	规格
axis	int32	默认为1，表示tile轴的维度，如果配置的轴是最高轴到C轴其中的一个轴，要求最高轴到该轴之前的值必须是1。	假设数据维度为s，支持配置 $[-s, s-1]$ 。
tiles	int32	表示复制的份数	-

5.1.1.57 Upsample

功能描述：上采样。

参数名	数据类型	参数含义	规格	其他约束
interpolation_mode	InterpolationMode	默认为NEAREST，表示插值模式	仅支持interpolation_mode为NEAREST，scale仅支持2	scale等同于stride
scale	uint32	缩放倍数，默认为2		



5.1.1.58 SortVector

说明

Hi3519DV500不支持。

功能描述：对输入向量进行排序操作。

规格约束：输入shape只支持1*1*1*w格式。当后接算子的类型为SortVector或FilterVector时，不支持is_output_idx配1。输入shapeW取值范围为[1,4095]。

参数名	数据类型	参数含义	规格
top_k	uint32	默认为inputW，表示输出的值最大个数，配置后 outputW=min(top_k, inputW)。	支持配置
is_output_idx	bool	默认为false，值为false时表示输出为向量值，为true时表示输出为向量索引。	支持配置
is_report_vector_num	bool	默认为true，值为true时表示当算子为最后一层时，会后接两个report层，同时输出结果向量以及向量长度；值为false时后接一个report层，只输出结果向量。	支持配置

5.1.1.59 FilterVector

说明

Hi3519DV500不支持。

功能描述：对输入向量进行过滤操作。大于等于过滤阈值的数据会被保留，其余被过滤，过滤后的输出紧凑排布。

规格约束：输入shape只支持1*1*1*w格式。当后接算子的类型为SortVector或FilterVector时，不支持is_output_idx配1。



参数名	数据类型	参数含义	规格
top_k	uint32	默认为inputW，表示输出的值最大个数，配置后 outputW=min(top_k, inputW)。当top_k配置值小于实际框数量时，只会保留前top_k个符合阈值要求的框。	支持配置
is_output_idx	bool	默认为false，值为false时表示输出为向量值，为true时表示输出为向量索引。	支持配置
filter_thresh	float	默认为0.5，过滤阈值。	支持配置
is_report_vector_num	bool	默认为true，值为true时表示当算子为最后一层时，会后接两个report层，同时输出结果向量以及向量长度；值为false时后接一个report层，只输出结果向量。	支持配置

5.2 Onnx 框架算子规格

该算子规格仅适用于Onnx框架原生IR定义的网络模型。

5.2.1 图像分析引擎

5.2.1.1 Abs

opset version: 13

功能描述：求绝对值。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	否

5.2.1.2 Acos

opset version: 7

功能描述：逐点求arccosine。支持高维度输入。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是

5.2.1.3 Add

opset version: 13

功能描述：计算两个输入element-wise的和。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
A	input	float	数据	broadcast支持： 1. aicore在限定维度(dim<=5)内支持broadcast任意轴。 2. 设dimH为dim[0]到dim[-3]的总shape。在条件1内，存在以下场景会区分走aicore(dimH <= 4096)或cpu(dimH > 4096)： a. dim = 4，且dim[-3]需广播，dim[-4]不广播，dim[-4]>1。如input1=[2, 2, H, W], input2=[2, 1, H, W] b. dim = 5，且dim[-3]需广播，dim[-4]不广播，dim[-4]>1。如input1=[N1, 2, 2, H, W], input2=[N1, 2, 1, H, W] c. dim = 5，且dim[-3]，dim[-4]需广播，dim[-5]不广播，dim[-5] > 1。如input1=[N1, 2, 2, H, W], input2=[N1, 1, 1, H, W] 3. 高维度(dim>5) broadcast为cpu模式。 4. 以cpu模式支持双向在线广播。 5. 以aicore模式支持一路在线一路离线的双向广播。	是
B	input	float	数据		

5.2.1.4 ArgMax

opset version: 13

功能描述：返回指定轴上最大值的索引。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持，但不支持大于4的高维度	是
axis	attribute	int32	选取最大值所在的维度	假设 $r = \text{rank}(\text{input})$ ，支持axis为 $[-r+1, -1] \cup [1, r-1]$ 。	
keepdims	attribute	bool	是否保留收缩的轴	Hi3516CV610不支持配置为false	
select_last_index	attribute	bool	出现多个相同值为最大值的情况，选择返回第一次出现或最后一次出现最大值的坐标（0为第一次出现）	支持配置为0或1	

5.2.1.5 ArgMin

功能描述：返回指定轴上最小值的索引，Hi3519DV500该算子走CPU。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持，大于4维时，走CPU；axis指定的轴大小超过4096时，走CPU。	是
axis	input	int32	选取最小值所在的维度	$[-r, r-1]$ ， $r = \text{rank}(\text{input})$ 。其中axis==0时，走CPU。	
keepdims	attribute	bool	是否保留收缩的轴	支持。 keepdims为true时，走CPU	
select_last_index	attribute	bool	出现多个相同值为最小值的情况选择返回第一次出现或最后一次出现最小值的坐标（0为第一次出现）	支持	

5.2.1.6 Asin

opset version: 7



功能描述：逐点求arcsine。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是

5.2.1.7 Atan

opset version: 7

功能描述：逐点求arctangent。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是

5.2.1.8 AveragePool

功能描述：平均池化。

规格说明：支持NCHW格式，N>=1

opset version: 11

Hi3516CV610：当kernel_shape与输入数据的最后两维长度不一致时，需满足 $\text{kernel_h} * \text{kernel_w} * 8 * \text{dataBit} / 8 \leq 4 * 16K$ ；当输入数据为Fp32，运算数据为S8时，需满足 $\text{kernel_h} * \text{kernel_w} * 8 * 2\text{Byte} + \text{kernel_h} * \text{kernel_w} * 8 \leq 4 * 16K$



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	其他约束
auto_pad	attribute	string	pad模式	支持	是	部分超出图像分析引擎规格的用CPU 图像分析引擎规格: - Hi3519DV500: $1 \leq \text{kernel} \leq 255$; $1 \leq \text{stride} \leq 255$; $1 \leq \text{pad} \leq 7$ - Hi3516CV610: $1 \leq \text{kernel} \leq 127$; $1 \leq \text{stride} \leq 127$; $1 \leq \text{pad} \leq 5$ $\text{strides} \leq \text{input_size}$; $0 \leq \text{pad left} < \text{kernel width}$; $\text{pad right} < \text{kernel width}$; $0 \leq \text{pad up} < \text{kernel height}$; $\text{pad down} < \text{kernel height}$; 当前shape已支持(N,C,H,W), $N \geq 1$;
ceil_mode	attribute	int	计算输出形状时是用ceil还是floor	支持		
count_include_pad	attribute	int	计算边沿值时是否包含填充的元素	支持		
kernel_shape	attribute	int	kernel沿各轴的大小	支持 1D pooling:1维输入 2D pooling:2维输入		
pads	attribute	int	每个轴的开始和结束位置	支持 1D pooling:2维输入 2D pooling:4维输入		
strides	attribute	int	每个轴的stride	支持 1D pooling:1维输入 2D pooling:2维输入		
X	input	float	数据	支持		

5.2.1.9 BatchNormalization

opset version: 9

功能描述: 计算输入的batch normalization。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	否
scale	input	float	scale tensor	必须为离线	
B	input	float	bias tensor	必须为离线	
mean	input	float	mean tensor	必须为离线	
var	input	float	variance tensor	必须为离线	
epsilon	attribute	float	避免除零	支持	
momentum	attribute	float	每次迭代滑动平均衰减系数	不支持配置，配置时不生效	

5.2.1.10 Celu

opset version: 12

功能描述：一种固定公式的激活函数：

$$CELU(x) = \max(0, x) + \min(0, \alpha * (\exp(x/\alpha) - 1))$$

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
alpha	attribute	float	公式里的alpha值	支持（除alpha的值为0）	是
X	input	float	数据	支持	

5.2.1.11 Ceil

功能描述：对输入X元素进行向上取整得到Y。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	是

5.2.1.12 Clip

opset version: 13

功能描述：根据上下边界对数据进行裁剪。



Hi3516CV610 规格约束：参数max的值必须不小于参数min的值，如果不满足约束，将按照[max, max]的边界条件对数据进行裁剪。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	否
min	input(optional)	float	下边界	必须为离线，必须为scalar，可不配置	
max	input(optional)	float	上边界	必须为离线，必须为scalar，可不配置	

5.2.1.13 Compress

opset version: 11

功能描述：从输入张量中沿给定轴根据condition中每个索引是否为true来选择切片。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
input	input	float	数据	支持	否
condition	input	bool	指定轴上的slice或data是否被选择	长度小于等于shape(axis)，必须为离线输入	
axis	attribute	int32	指定compress的轴	[-r,r-1], r=rank(input), 若未指定则输入将被flatten	

5.2.1.14 Concat

opset version: 13

功能描述：将多个输入在指定维度拼接。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	可为多个	是



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
axis	attribute	int32	表示在某个维度拼接	支持配置， 令dim表示输入shape的维数，如NCHW的维数为4，支持按如下两种情况配置属性： 1. dim等于4且第0维等于1场景，支持配置 [-4, 3] 2. dim大于4，或者dim等于4且第0维非1场景，支持配置[-dim, -dim + axis_r1] U [-2, -1] U [dim-2, dim-1] U [0, axis_r1]。其中axis_r1为最左非1轴，即shape从左到右出现的第一个非1轴，如[1, 2, c, h, w]，则axis_r1=1。 其余场景用CPU实现。	

5.2.1.15 Constant

功能描述：生成离线数据。

opset version: 21

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
sparse_value	attribute	不支持	离线数据	只支持整型和浮点型	是
value	attribute	binary			
value_float	attribute	float			
value_floats	attribute	float			
value_int	attribute	不支持			
value_ints	attribute	不支持			
value_string	attribute	不支持			
value_strings	attribute	不支持			



5.2.1.16 ConstantOfShape

功能描述：生成离线数据。

opset version: 21

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
value	attribute	float	离线数据值	1、input只支持整型 2、value只支持浮点型	仅支持离线输入。
input	input	int64	离线数据shape		

5.2.1.17 Conv

opset version: 11

功能描述：对输入做卷积计算。

规格约束：

- Hi3519DV500：当Convolution的输入NCHW的N不等于1时，输入和输出channel需满足以下条件： $(data_bit_num * channel) \% 64 == 0$ ，例如当输入为8bit，channel需为8的倍数；当Convolution输入是数据层时，输入无上述限制；支持图片输入，支持的类型包括YUV420、YVU420、BGR_PLANNAR、RGB_PLANNAR、BGR_PACKAGE、RGB_PACKAGE；不支持group > 1。
- Hi3516CV610：当Convolution的输入NCHW的N不等于1时，输入和输出channel都需为8的倍数；不支持图片输入；不支持group > 1；不支持S16计算，如果配置S16会回退为S8。

data_bit_num 表示计算数据位宽，当计算数据类型为U4/S4时，data_bit_num = 4；当计算数据类型为U8/S8时，data_bit_num = 8；当计算数据类型为U16/S16时，data_bit_num = 16。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	$N \times C \times H \times W$	否
W	input	float	权重	必须为离线， $M \times C / group \times kH \times kW$	
B	input(optional)	float	偏置	M(M为Feature map数量)，必须为离线	



参数名	参数/输入	数据类型	参数含义	规格	是否支持 离线data 输入
auto_pad	attribute	string	指定padding的类型，可配置为NOTSET, SAME_UPPER, SAME_LOWER 或 VALID	auto_pad各参数定义见onnx文档	
dilations	attribute	list of ints	沿各轴dilation的大小	大小为2，配置后 (kernel-1) × dilation + 1 < 255	
group	attribute	int	默认为1，inputC和outputC需要切分的大小	支持	
kernel_shape	attribute	list of ints	卷积kernel的大小	大小为2，顺序为(height, width),受dilation、输入数据类型和输出数据类型的影响 - Hi3519DV500: 高，宽配置范围[1, 64] - Hi3516CV610: 高，宽配置范围[1, 15]	
pads	attribute	list of ints	各轴起始位置补边的大小	格式为 [x1_begin, x2_begin...x1_end, x2_end,...], 不可与auto_pad同时配置，配置范围： - Hi3519DV500: [0, 15] - Hi3516CV610: [0, 7] 且须满足pad ≤ (kernel-1) × dilation + 1	
strides	attribute	list of ints	沿各轴stride的大小	大小为2，顺序为(height, width), 配置范围： - Hi3519DV500: [1, 255] - Hi3516CV610: [1, 16]	



5.2.1.18 ConvTranspose

opset version: 11

功能描述：对输入做反卷积计算。

规格约束：(dilations × (kernel_shape - 1) 大于等于pads。当输入NCHW的N不等于1时，不支持。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	否
W	input	float	权重	必须为离线，C×M/group ×kH×kW	
B	input(optional)	float	偏置	必须为离线，M(M为Feature map数量)	
auto_pad	attribute	string	指定padding的类型，可配置为NOTSET, SAME_UPPER, SAME_LOWER 或 VALID	auto_pad各参数定义见备注	
dilations	attribute	list of ints	沿各轴dilation的大小	dilation的个数等于输入维度大小，支持1~15，配置后 (kernel-1) × dilation + 1 < 255	
group	attribute	int	默认为1，inputC和outputC需要切分的大小	支持	
kernel_shape	attribute	list of ints	卷积kernel的大小	大小为2，顺序为(height, width)受dilation、stride、input_channel、输入数据类型和输出数据类型的影响 - Hi3519DV500: 高，宽配置范围[1, 64] - Hi3516CV610: 高，宽配置范围[1, 15]	
output_padding	attribute	list of ints	在输出结果的基础上补边	不支持配置	
output_shape	attribute	list of ints	输出的形状	支持	



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
pads	attribute	list of ints	各轴起始位置补边的大小	格式为 [x1_begin, x2_begin...x1_end, x2_end,...], 不可与 auto_pad同时配置;若配置该项, 须配置4个数 [padUp, padLeft, padDown, padRight], 分别表示配置的上、左、下、右补边数. kernel、stride和dilation影响支持范围 - Hi3519DV500: 配置范围[0, 15] - Hi3516CV610: 配置范围[0, 7]	
strides	attribute	list of ints	沿各轴stride的大小	大小为2, 顺序为(height, width), 配置范围: - Hi3519DV500: [1, 255] - Hi3516CV610: [1, 16]	

5.2.1.19 Cos

opset version: 7

功能描述: 计算cosine。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
input	input	float	数据	支持	是

5.2.1.20 DecBBox

功能描述: RPN硬化层。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
0	input	float	数据	-	否



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
1	input	float	bias数据	YOLOV2/V3/V4/V5/V7网络必须配置,且满足 $\text{input.size}=(\text{input_w}/(\text{gridW}*\text{gridH}))$ 。值域: [0,1024]。	是
calc_mode	attribute	uint32_t	默认为0, DecBBox网络类型	支持7种类型 0: RCNN (Hi3516CV610不支持) 1: YOLOV1 (Hi3516CV610不支持) 2: YOLOV2 (Hi3516CV610不支持) 3: YOLOV3/V4 4: SSD 5: YOLOV5/V7 8: YOLOV8	否
num_classes	attribute	uint32_t	默认为0, 分类数目	支持, 值域[1, 1000]。 YOLOV1/V2/V3/V4/V5/V7 需要满足 $\text{num_classes} + 5 = \text{input_h}$, YOLOV8需要满足 $\text{num_classes} + 4 = \text{input_h}$	否
num_anchors	attribute	uint32_t	默认为0, 锚点数	支持, 值域[1, 524288]。需要满足 $\text{num_anchors} \% (\text{gridW}*\text{gridH}) = 0$ 。 对于YOLO网络, 需要满足 $\text{num_anchors}=\text{input_w}$	否
num_coords	attribute	uint32_t	默认为4, 坐标数	支持, 仅支持4	否
share_loc	attribute	bool	默认为false, 是否共享位置预测	支持	否
clip_bbox	attribute	bool	默认为true, 是否使能框裁剪	支持, 仅支持true	否



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
gridW	attribute	uint32_t	YOLO网络栅格Width	YOLO网络必须配置，值域[1，1024]	否
gridH	attribute	uint32_t	YOLO网络栅格Height	YOLO网络必须配置，值域[1，1024]	否
imgW	attribute	uint32_t	输入为Feature map时指定原图的宽	支持，值域[1，4096]	否
imgH	attribute	uint32_t	输入为Feature map时指定原图的高	支持，值域[1，4096]	否
useClassId	attribute	bool	默认为true，输出是否包含class id	支持，仅支持true	否
multi_label	attribute	bool	默认false，是否开启多类别功能	支持，仅19DV500支持true	否

5.2.1.21 DepthToSpace

opset version: 11

功能描述：重新排列空间数据块,将depth数据转移到进入space。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
input	input	float	数据	C必须是blocksize*blocksize的整数倍	是
blocksize	attribute	int	取空间的大小		
mode	attribute	string	排布方式	NPU仅支持DCR模式,CRD模式使用CPU	

5.2.1.22 Div

opset version: 13

功能描述：计算两个输入element-wise的除。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
A	input	float	数据	broadcast支持与Add一致。	是
B	input	float	数据		



5.2.1.23 Dropout

功能描述：当前仅支持将输入复制到输出。

opset version: 13

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	否
ratio	input(optional)	float	数据	不支持配置	
training_mode	input(optional)	bool	是否为training模式	不支持配置	
seed	attribute	int	随机数生成seed	不支持配置	

5.2.1.24 Elu

opset version: 6

功能描述：一种固定公式的激活函数。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	是
alpha	attribute	float	默认为1，公式中的alpha系数	支持	

5.2.1.25 Exp

opset version: 13

功能描述：计算exp。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
input	input	float	数据	支持	是

5.2.1.26 Erf

opset version: 13

功能描述：一种固定公式的误差函数，支持高维度输入。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	是

5.2.1.27 Filter

功能描述:RPN硬化层，对检测框进行过滤。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
0	input	float	数据	-	否
topK	attribute	uint32_t	最大输出框的个数	不支持，配置时不生效	否
conf_thres	attribute	float	最低分数阈值	支持，值域[0, 1)	否

5.2.1.28 Floor

功能描述：对输入X元素进行向下取整得到Y。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	是

5.2.1.29 Flatten

功能描述：将输入以指定轴为界拉伸成2D Matrix。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
input	input	float	数据	支持	是
axis	attribute	int32	指定分界轴	axis取值范围：[-4, 3]，默认值是1，axis值应小于等于输入张量的秩	是



5.2.1.30 Gather

功能描述：将指定轴方向指定indices的数据聚合在一起。

opset version: 13

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线输入	其他约束
data	input	float	数据	当axis为W轴时，输入W支持的最大值。 - Hi3519DV500: 65535 - Hi3516CV610: 4095	是	走图像分析引擎需满足：axis对应的shape维度，小于U16最大值65535的约束，其余走CPU模式。
indices	input	int32/int64	需要提取的indices	支持scalar/tensor输入。 - indices为在线输入时：[0,s-1], s=shape(axis) - indices为离线输入时：[-s,s-1], s=shape(axis)	是	
axis	attribute	int32	gather的轴	[-r,r-1], r=rank(input)	不涉及	

5.2.1.31 Gemm

功能描述：实现两个矩阵的乘积。

opset version: 13

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	其他约束
alpha	attribute	float	A×B的乘数	支持	是	只有当alpha=1、beta=1，transA为false，transB不做限制，C为一维向量，B和C都为离线输入时，即经过离线处理可以满足fc计算公式的[M,K]*[K,N]+[N]的条件时，使用图像分析引擎，其它情况用CPU。
beta	attribute	float	C的乘数	支持		
transA	attribute	int	决定A是否转置	支持		
transB	attribute	int	决定B是否转置	支持		
A	input	float	数据	支持		
B	input	float	数据	支持		
C	input	float	数据	optional		



5.2.1.32 GlobalAveragePool

功能描述：实现对同一-channel的所有元素平均池化。

规格说明：支持NCHW格式，N>=1

opset version: 1

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	其他约束
X	input	float	数据	支持	是	部分超出图像分析引擎规格的用CPU 图像分析引擎规格: Hi3519DV500: 1 <= input_h <=255 1 <= input_w <= 255 Hi3516CV610: 1 <= input_h <=127 1 <= input_w <= 127

5.2.1.33 GlobalMaxPool

功能描述：实现对同一-channel的所有元素最大池化。

规格说明：支持NCHW格式，N>=1

opset version: 1

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	其他约束
X	input	float	数据	支持	是	部分超出图像分析引擎规格的用CPU 图像分析引擎规格: Hi3519DV500: 1 <= input_h <=255 1 <= input_w <= 255 Hi3516CV610: 1 <= input_h <=127 1 <= input_w <= 127

5.2.1.34 GRU

opset version: 14



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	输入是否可选	约束
activation_alpha	attribute	float	激活函数的缩放值	不支持配置	不涉及	不涉及	支持两种输出格式： 1. 输出仅有1个参数：Y 2. 输出全部参数：Y，Y_h 输入和输出形状的最后维，Hi3516CV610最大支持1872。
activation_beta	attribute	float	激活函数的缩放值	不支持配置			
activations	attribute	string	输入、输出、遗忘、cell和hidden使用的激活函数	不支持配置			
clip	attribute	float	激活函数前对数据clip的阈值	支持			
direction	attribute	string	指定RNN是前向/反向/双向	支持			
hidden_size	attribute	int	隐藏层细胞单元个数	支持			
layout	attribute	int	数据排布格式	不支持配置，默认为0			
linear_before_reset	attribute	int	如果为1，则输出隐藏门时，在乘以重置门输出前先做线性变换	支持			
X	input	float	输入句子序列	支持	否	必填	
W	input	float	门权重	支持			
R	input	float	循环权重	支持			
B	input	float	门偏置	支持	仅为离线	可选	
sequence_lengths	input	int	句子长度	支持			
initial_h	input	float	hidden初始值	支持			
Y	output	float	所有帧hidden输出的集合	支持	是		
Y_h	output	float	最后一帧hidden输出	支持			
					不涉及	必填	
						可选	



5.2.1.35 Gelu

opset version: 20

功能描述：Transformer网络常用的高斯误差线性单元激活函数。onnx opset v20算子，opset v20以下需以自定义算子形式构造。曾用名Gelu2，兼容Gelu2算子。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	否
approximate	attribute	string	gelu近似算法	'fast_approximation': 高性能近似模式。 'better_approximation': 高精度近似模式。 - 支持官方'none', 'tanh', 但统一转为'fast_approximation'近似实现。	

5.2.1.36 GridSampleXDec

功能描述：GridSampleXDec根据输入的参考框和偏移，从输入的特征图中抽取对应的数据作为输出。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
offset	input	float	相对于参考框的偏移	仅支持shape结构为4维，仅支持h=1，且w要等于参考框的w。offset通道数=n_heads*n_points*2。	否
value	input	float	输入特征图数据	仅支持shape结构为4维。value 通道数需要被n_head整除。	
ref	input	float	参考框	仅支持shape结构为4维，仅支持h=1，c=4，且w要等于偏移的w	
n_heads	参数	int	输入特征及偏移的分组数	否	
n_points	参数	int	每组偏移的数量	否	
H	参数	int	参考框的高度缩放系数	否	-
W	参数	int	参考框的宽度缩放系数	否	-



5.2.1.37 HardSigmoid

opset version: 6

功能描述：根据公式进行计算 $y = \max(0, \min(1, \alpha * x + \beta))$ 。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是
alpha	attribute	float	系数	支持	
beta	attribute	float	偏置	支持	

5.2.1.38 Identity

opset version: 13

功能描述：将数据复制到输出。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
input	input	float	数据	支持	是

5.2.1.39 If

功能描述：进行分支判断计算。

opset version: 13

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
cond	input	bool	输入的条件值	支持	不支持。仅支持输入全在线。
else_branch	attribute	graph	如果为真执行的子图	支持	
then_branch	attribute	graph	如果为假执行的子图	支持	

5.2.1.40 InverseSigmoid

功能描述：InverseSigmoid为Sigmoid的逆过程，计算公式为： $y = -\log((1 / x) - 1)$



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线输入
data	input	float	数据	支持	否

5.2.1.41 InstanceNormalization

功能描述：计算 $y = \text{scale} * (x - \text{mean}) / \sqrt{\text{variance} + \text{epsilon}} + B$ 。

opset version: 6

规格约束：当运算轴为C轴，此时C的大小不得超过4096

当符合以下规格时，走CPU实现：

- scale 离线，bias在线，走CPU；
- N轴大小不为1时，走CPU。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
epsilon	attribute	float	避免除零	支持	是
input	input	float	数据	支持	
scale	input	float	数据	支持	
B	input	float	数据	支持	

5.2.1.42 LRN

opset version: 12

功能描述：计算Local Response Normalization。

Hi3516CV610 规格约束：channel不支持大于1024。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	否
alpha	attribute	float	scaling系数	支持	
beta	attribute	float	指数系数	支持	
bias	attribute	float	偏置(偏置必须大于等于0)	支持	
size	attribute	int32	local size	支持3、5、7，需要满足Channel大于等于size	



说明

向量：输入width <= 21840

5.2.1.43 LeakyRelu

opset version: 13

功能描述：激活函数 $f(x) = \alpha * x$ for $x < 0$, $f(x) = x$ for $x \geq 0$ 。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	是
alpha	attribute	float	leakage系数	支持	

5.2.1.44 Log

opset version: 13

功能描述：计算log。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	是

5.2.1.45 LogSoftmax

功能描述：根据指定公式计算 $\text{LogSoftmax}(\text{input}, \text{axis}) = \text{Log}(\text{Softmax}(\text{input}, \text{axis}=\text{axis}))$ 。

opset version: 13

Hi3516CV610需满足：运算轴为axisC时， $5*16K \geq \text{input_c} * \text{dataBit} / 2$ ；运算轴为axisH/axisW时， $5*16K \geq 4 * \text{input_axis} * \text{dataBit}$

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
input	input	float	数据	支持	否
axis	attribute	int32	指定softmax的轴	$[-r, r-1]$, $r = \text{rank}(\text{input})$, 若r为4, axis不为-4和0 若r为5, axis不为-5, -4, 0和1	



5.2.1.46 Loop

功能描述：对子图进行循环计算。

opset version: 13

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
body	attribute	graph	循环执行的子图	迭代次数必须为离线值	是。不支持所有输入同时都为离线输入。
M	input	int64	迭代的次数		
cond	input	bool	输入的条件值		
v_initial	input	variadic	迭代变量		

说明

不支持输出中含有scan_output的输出。

5.2.1.47 LSTM

opset version: 14

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	输入是否可选	约束
activation_alpha	attribute	float	激活函数的缩放值	不支持配置	不涉及	不涉及	支持三种输出格式： 1. 输出仅有1个参数：Y 2. 输出2个参数：Y, Y_h 3. 输出全部参数：Y, Y_h, Y_c 输入和输出形状的最后维，Hi3516CV610最大支持1872。
activation_beta	attribute	float	激活函数的缩放值	不支持配置			
activations	attribute	string	输入、输出、遗忘、cell和hidden使用的激活函数	不支持配置			
clip	attribute	float	激活函数前对数据clip的阈值	支持			
direction	attribute	string	指定RNN是前向/反向/双向	支持			
hidden_size	attribute	int	隐藏层细胞单元个数	支持			



参数名	参数/输入	数据类型	参数含义	规格	是否支持 离线 data 输入	输入 是否 可选	约束	
input_forget	attribute	int	如果为1，输入门与遗忘门融合	不支持配置，默认为0				
layout	attribute	int	数据排布格式	不支持配置，默认为0				
X	input	float	输入句子序列	支持	否	必填		
W	input	float	门权重	支持	仅为 离线			
R	input	float	循环权重	支持				
B	input	float	门偏置	支持		是		可选
sequence_lengths	input	int	句子长度	支持				
initial_h	input	float	hidden初始值	支持				
initial_c	input	float	cell初始值	支持				
P	input	float	peephole权重	支持	仅为 离线			
Y	output	float	所有帧hidden输出的集合	支持	不 涉 及	必填		
Y_h	output	float	最后一帧hidden输出	支持				可选
Y_c	output	float	最后一帧cell输出	支持				

5.2.1.48 LayerNorm

功能描述：LayerNorm 为层归一化，可以对网络中的每个神经元的输出进行归一化，使得网络中每一层的输出都具有相似的分布。Layernorm是对单轴进行归一化。

规格约束：当运算轴为C轴，此时C的大小不得超过4096。

LayerNorm与ONNX原生算子差异：

在ONNX原生算子中，LayerNormalization的支持归一化维度为W，HW和CHW，不支持对单H轴和单C轴进行归一化。而本LayerNorm算子支持对单W轴、单H轴及单C轴进行归一化，但不支持HW和CHW等多轴进行归一化。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线输入
data	input	float	数据	支持，最大支持4维	否
scale	input	float	scale tensor	支持	是
bias	input	float	bias tensor	支持	
axis	attribute	int32	归一化计算轴	选择运算轴，支持配置C、H、W，不支持HW、CHW，默认为1	不涉及
eps	attribute	float	防止除0错误	支持	

5.2.1.49 MatMul

功能描述：支持numpy-style的矩阵相乘。

opset version: 13

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	其他约束
A	input	float	数据	支持二维及以上。	是	1. 图像分析引擎不支持输入维度大于4维，用CPU实现 2. 不支持n>1且仅有c轴broadcast
B	input	float	数据	支持二维及以上。		

5.2.1.50 Max

opset version: 13

功能描述：计算多输入element-wise的最大值。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data_0	input	float	数据	broadcast支持与Add一致。	是。 支持两路输入全离线，不支持两路以上输入场景全离线。



5.2.1.51 MaxPool

功能描述：最大池化。

规格说明：支持NCHW格式，N>=1

opset version: 11

Hi3516CV610：当kernel_shape与输入数据的最后两维长度不一致时，需满足 $\text{kernel_h} * \text{kernel_w} * 8 * \text{dataBit} / 8 \leq 4 * 16K$ ；当输入数据为Fp32，运算数据为S8时，需满足 $\text{kernel_h} * \text{kernel_w} * 8 * 2\text{Byte} + \text{kernel_h} * \text{kernel_w} * 8 \leq 4 * 16K$

参数名	参数/输入	数据类型	参数含义	规格	是否支持 离线data 输入	其他约束
auto_pad	attribute	string	pad模式	支持	是	只支持dilation为1。 同时输出最大值索引（即算子有两路输出）时，仅支持接upsample算子。 部分超出图像分析引擎规格的用CPU 图像分析引擎规格： - Hi3519DV500: $1 \leq \text{kernel} \leq 255$; $1 \leq \text{stride} \leq 255$, $\text{strides} \leq \text{input_size}$; $1 \leq \text{pad} \leq 7$; - Hi3516CV610: $1 \leq \text{kernel} \leq 127$ $1 \leq \text{stride} \leq 16$, $\text{strides} \leq \text{input_size}$; $1 \leq \text{pad} \leq 5$ $0 \leq \text{pad left} < \text{kernel width}$; $\text{pad right} < \text{kernel width}$; $0 \leq \text{pad up} < \text{kernel height}$; $\text{pad down} < \text{kernel height}$; 当前shape已支持 (N,C,H,W)，N>=1;
ceil_mode	attribute	int	计算输出形状时是用ceil还是floor	支持		
dilations	attribute	int	每个轴的dilation值	支持 1D pooling:1维输入 2D pooling:2维输入		
kernel_shape	attribute	int	kernel沿各轴的大小	支持 1D pooling:1维输入 2D pooling:2维输入		
pads	attribute	int	每个轴的开始和结束位置	支持 1D pooling:2维输入 2D pooling:4维输入		
storage_order	attribute	int	存储序 (row major、column major)	支持		



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	其他约束
strides	attribute	int	每个轴的stride	支持 1D pooling:1维输入 2D pooling:2维输入		
X	input	float	数据	支持		

5.2.1.52 Mean

opset version: 13

功能描述：计算多输入element-wise的均值。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data_0	input	float	数据	broadcast支持与Add一致。	是不支持输入全离线。

5.2.1.53 Min

opset version: 13

功能描述：计算多输入element-wise的最小值。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data_0	input	float	数据	broadcast支持与Add一致。	是支持两路输入全离线，不支持两路以上输入场景全离线。

5.2.1.54 Mul

opset version: 13

功能描述：计算两个输入element-wise的乘积。支持高维度输入。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
A	input	float	数据	broadcast支持与Add一致。	是
B	input	float	数据		

5.2.1.55 MeanVarianceNormalization

功能描述：计算mvn。

opset version：13

规格约束：仅支持4D输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	仅支持axes为(0,2,3)/(0,1,2,3)	是

5.2.1.56 MulReduceSum

功能描述：onnx自定义算子，输入为GridSampleXDec和Softmax，用于替换GridSampleXDec后的Gather、Unsqueeze、Mul、Reducesum、Reshape小算子，作为集合实现。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	第一路输入，来自GridSampleXDec	仅支持shape结构为5维, [n1, nx0, c, h, w], 且n1*nx0*c需<4096; Hi3516CV610需满足n1*nx0*c<4000	否
Y	input	float	第二路输入，来自Softmax		



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
index	attribute	int64	从Y (shape=[n1, ny0, c, h, w])中gather第index块的数据(shape=[n1, 1, c, h, w])。	$0 \leq \text{index} < \text{ny0}$	

5.2.1.57 Neg

opset version: 13

功能描述：对输入数据，进行符号翻转。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	是

5.2.1.58 NMS

功能描述：RPN硬化层，对检测框进行非极大值抑制。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
0	input	float	数据	-	否
topK	attribute	uint32	最大输出框个数	支持，值域 [1,10000]	否
nms_thresh	attribute	float	nms阈值	支持，值域 [0, 1)	

5.2.1.59 PRelu

opset version: 9

功能描述：带参数的ReLU激活函数。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	1. 当前仅支持数据X在线，Slope数据离线 2. 以4D输入NCHW为例，Slope仅支持channel轴为1或C，即shape=[1, 1, 1, 1]或[1, C, 1, 1]；若是2D NC场景，则Slope shape可为[1, 1]或[1, C]。	否
slope	input	float	负数部分斜率		

5.2.1.60 Pow

opset version: 15

功能描述：计算 $f(x) = x^{\text{exponent}}$ 。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	不支持广播，不支持多个指数	是
Y	input	float	指数		

说明

数据为张量时：width≤16384

5.2.1.61 PosEncode

功能描述：针对transformer网络，把一个词映射成一个向量。

opset version: 11

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	仅支持shape结构为4维，仅支持h=1,c=1或4	否
Constant	input	float	离线数据	仅支持shape结构为4维，仅支持h=1,w轴维度与data保持一致；且c_constant需为偶数且不能取0。	是



5.2.1.62 Pad

功能描述：对输入的数据进行填充。

opset version: 21

规格约束：当存在以下场景规格时，用CPU进行计算

- 对N轴或者C轴进行填充时
- 对H或W轴进行填充，填充的数量超过15时
- Pad mode 为 reflect 模式时（Hi3519DV500无该规格约束）
- 对任意轴进行删除时

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
mode	attribute	string	3种模式"constant"、"reflect"、"edge"	支持	是（pads, constant_value仅支持离线输入）
data	input	float	数据		
pads	input	int64	指示每个轴的起始和结尾填充或删除的数量		
constant_value	input	float	如果mode为"constant", 填充的值，默认值为0		

5.2.1.63 Reciprocal

opset version: 13

功能描述：对每个点求倒数。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是

5.2.1.64 ReduceL1

opset version: 13

功能描述：对指定的轴计算l1_norm。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	约束
data	input	float	数据	支持	是	走图像分析引擎需满足以下约束，其余走cpu模式 1、axes是除N轴 (axis=0/-r)外的任意轴组合 2、reduce axis=-2轴或-2+r轴时，keepdims==0 3、输入数据维度=3或4，且第一维shape=1。
axes	attribute	list of ints	reduce的轴	list中的每个axis[-r,r-1], r=rank(input)		
keepdims	attribute	int	是否保留reduce的轴	支持，默认为1		

5.2.1.65 ReduceMax

opset version: 13

功能描述：对指定的轴求最大值。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	约束
data	input	float	数据	支持	是	走图像分析引擎需满足以下约束，其余走cpu模式 1、axes是除N轴 (axis=0/-r)外的任意轴组合 2、reduce axis=-2轴或-2+r轴时，keepdims==0 3、输入数据维度=3或4，且第一维shape=1。
axes	attribute	list of ints	reduce的轴	list中的每个axis[-r,r-1], r=rank(input)。		
keepdims	attribute	int	是否保留reduce的轴	支持，默认为1		

5.2.1.66 ReduceMean

opset version: 13

功能描述：对指定的轴计算求平均值。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	约束
data	input	float	数据	支持	是	走图像分析引擎需满足以下约束，其余走cpu模式 1、axes是除N轴(axis=0/-r)外的任意轴组合 2、reduce axis=-2轴或-2+r轴时，keepdims==0 3、输入数据维度=3或4，且第一维shape=1。
axes	attribute	list of ints	reduce的轴	list中的每个axis[-r,r-1], r=rank(input)		
keepdims	attribute	int	是否保留reduce的轴	支持，默认为1		

5.2.1.67 ReduceMin

opset version: 13

功能描述：对指定的轴计算最小值。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	约束
data	input	float	数据	支持	是	走图像分析引擎需满足以下约束，其余走cpu模式 1、axes是除N轴(axis=0/-r)外的任意轴组合 2、reduce axis=-2轴或-2+r轴时，keepdims==0 3、输入数据维度=3或4，且第一维shape=1。
axes	attribute	list of ints	reduce的轴	list中的每个axis[-r,r-1], r=rank(input)		
keepdims	attribute	int	是否保留reduce的轴	支持，默认为1		

5.2.1.68 ReduceSumSquare

opset version: 13

功能描述：对指定的轴计算平方和。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	约束
data	input	float	数据	支持	是	走图像分析引擎需满足以下约束，其余走cpu模式 1、axes是除N轴(axis=0/-r)外的任意轴组合 2、reduce axis=-2轴或-2+r轴时，keepdims==0 3、输入数据维度=3或4，且第一维shape=1。
axes	attribute	list of ints	reduce的轴	list中的每个axis[-r,r-1], r=rank(input)		
keepdims	attribute	int	是否保留reduce的轴	支持，默认为1		

5.2.1.69 ReduceSum/version<=12

功能描述：对指定的轴求和。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	约束
data	input	float	数据	支持	是	走图像分析引擎需满足以下约束，其余走cpu模式 1、axes是除N轴(axis=0/-r)外的任意轴组合 2、reduce axis=-2轴或-2+r轴时，keepdims==0 3、输入数据维度=3或4，且第一维shape=1。
axes	attribute	list of ints	reduce的轴	list中的每个axis[-r,r-1], r=rank(input)		
keepdims	attribute	int	是否保留reduce的轴	支持，默认为1		

5.2.1.70 ReduceSum/version13

功能描述：对指定的轴求和。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	约束
data	input	float	数据	支持	是	走图像分析引擎需满足以下约束，其余走cpu模式 1、axes是除N轴(axis=0/-r)外的任意轴组合 2、reduce axis=-2轴或-2+r轴时，keepdims==0 3、输入数据维度=3或4，且第一维shape=1。
axes	input	list of ints	reduce的轴	支持		
noop_with_empty_axes	attribute	int	当没有设置axes的时候，如果该处为false，则对所有轴规约，否则返回原data	list中的每个axis[-r,r-1], r=rank(input)		
keepdims	attribute	int	是否保留reduce的轴	支持，默认为1		

5.2.1.71 Relu

opset version: 13

功能描述：ReLU激活函数。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	是

5.2.1.72 Reshape

功能描述：将输入的维度转换为指定维度。支持高维度输入。

opset version: 21

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是
shape	input	int64	输出的具体形状	shape必须为离线	

5.2.1.73 Resize

功能描述：将输入按指定mode进行缩放。



opset version: 13 11 10

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
coordinate_transformation_mode	attribute	string	坐标轴转换的方式	nearest模式支持配置为asymmetric; linear模式支持配置为half_pixel, pytorch_half_pixel, align_corners, asymmetric	否
cubic_coeff_a	attribute	float	cube模式下缩放参数	不支持配置	
exclude_outside	attribute	int	是否包含张量之外的采样点	不支持配置	
extrapolation_value	attribute	float	coordinate_transformation_mode为"tf_crop_and_resize", 输入数据超出范围时使用的值。	不支持配置	
mode	attribute	string	插值模式	支持nearest, linear linear模式, 输入w不支持超过65535, 输入w和h不支持为1	
nearest_mode	attribute	string	插值模式配置为nearest时的取值方式	仅支持配置为floor	
X	input	float	数据	支持	
roi	input	float	roi区域	不支持配置	
scales	input	float	沿各个轴的缩放倍数	必须且只能离线配置scales或者sizes中的一个。 nearest模式, scales只支持(1,1,2,2), sizes只支持hw扩大两倍。	
sizes	input	int64	输出的shape		

5.2.1.74 RNN

opset version: 14



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	输入是否可选	约束
activation_alpha	attribute	float	激活函数的缩放值	不支持配置	不涉及	不涉及	支持两种输出格式： 1. 输出仅有1个参数：Y 2. 输出全部参数：Y, Y_h 输入和输出形状的最后维，Hi3516CV610最大支持1872。
activation_beta	attribute	float	激活函数的缩放值	不支持配置			
activations	attribute	string	输入、输出、遗忘、cell和hidden使用的激活函数	不支持配置			
clip	attribute	float	激活函数前对数据clip的阈值	支持			
direction	attribute	string	指定RNN是前向/反向/双向	支持			
hidden_size	attribute	int	隐藏层细胞单元个数	支持			
layout	attribute	int	数据排布格式	不支持配置，默认为0			
X	input	float	输入句子序列	支持	否	必填	
W	input	float	门权重	支持	仅为离线		
R	input	float	循环权重	支持			
B	input	float	门偏置	支持		是	
sequence_lengths	input	int	句子长度	支持			
initial_h	input	float	hidden初始值	支持			
Y	output	float	所有帧hidden输出的集合	支持	不涉及	必填	
Y_h	output	float	最后一帧hidden输出	支持		可选	

5.2.1.75 RoiAlign

功能描述：对候选Roi区域进行align操作

opset version: 10



参数名	参数/输入	数据类型	参数含义	规格 (Hi3519DV500)	规格 (Hi3516CV610)	是否支持 离线 data 输入
X	input	float	输入数据	支持	支持	否
rois	input	float	roi候选框数据	支持（候选框需设置为整数，且需要在X的有效区域上）	同Hi3519DV500	否
batch_indices	input	int64	操作的输入数据batch索引	仅支持为0，配置其它值不生效	同Hi3519DV500	否
coordinate_transformation_mode	attribute	string	坐标变换方式	不支持	不支持	-
mode	attribute	string	池化方式，avg或max	支持	支持	-
output_height	attribute	int	输出h大小	支持	支持	-
output_width	attribute	int	输出w大小	支持	支持	-
sampling_ratio	attribute	int	采样率	支持	支持，采样总数不大于36。采样总数=高的采样率*宽的采样率。当值为零时，采样总数=ceil(inH/outH)*ceil(inW/outW)	-
spatial_scale	attribute	float	坐标转换参数	支持	支持	-

5.2.1.76 Round

功能描述：对输入X求Round得到Y。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线 data输入
X	input	float	数据	支持	是



5.2.1.77 Roll

功能描述：对窗口内的数据做滚动偏移。

参数名	参数/输入	数据类型	参数含义	公共规格	是否支持离线输入
data	input	float	数据	仅支持4维	否
offset_x	input	int	X方向窗口偏移	标量，支持正值或负值，范围为(-W, W)，W为data输入的width	是（仅支持离线输入）
offset_y	input	int	Y方向窗口偏移	标量，支持正值或负值，范围为(-H, H)，H为data输入的height	是（仅支持离线输入）

5.2.1.78 Scan

opset version: 11

功能描述：做需要有时序的计算。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
body	attribute	graph	子图	当前不支持scan_input_directions和scan_output_directions为1的场景	是
num_scan_inputs	attribute	int64	需要迭代的tensor个数		
scan_input_axes	attribute	int64	需要迭代的tensor切块轴		
scan_input_directions	attribute	int64	需要迭代的tensor切块后输入方向		
scan_output_axes	attribute	int64	需要迭代的tensor输出拼接轴		
scan_output_directions	attribute	int64	需要迭代的tensor拼接方向		
initial_state_and_scan_inputs	input	variadic	数据		

5.2.1.79 Selu

opset version: 13

功能描述：Selu激活函数。默认参数下进图像分析引擎，即alpha==1.67326 && gamma==1.0507。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
alpha	attribute	float	系数	支持	是
gamma	attribute	float	系数	支持	
X	input	float	数据	支持	

5.2.1.80 Shape

功能描述：返回上层tensor的shape。

规格约束：不支持将shape层作为网络的最后一层。

opset version: 21

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	node	数据	支持	是

5.2.1.81 Sigmoid

opset version: 13

功能描述：计算sigmoid。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	是

5.2.1.82 Sign

opset version: 13

功能描述：计算输入tensor的元素符号。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
input	input	float	数据	支持	是

5.2.1.83 Sin

opset version: 7

功能描述：计算sine。支持高维度输入。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
input	input	float	数据	支持	是

5.2.1.84 Size

opset version: 13

功能描述：返回上层数据个数。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	node	数据	支持	是

5.2.1.85 Slice

opset version: 13

功能描述：将输入数据按照指定维度切割成多个数据。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
float	input	float	数据	一个	是。starts、ends、axes、steps必须为离线数据。
axes	attribute/ input	1-D 数据	表示切割的维度	[-r,r-1], r=rank(input) steps = 1时, 高维度仅支持配置axes取值为[-1,-2] U [r-2, r-1]。 steps = 2时, 高维度仅支持配置axes取值为[-r] U [-1, -2] U [r-2, r-1] U [0]。	
starts	attribute/ input	1-D 数据	表示切割的起始元素	[-r,r-1], r=rank(input)	
ends	attribute/ input	1-D 数据	表示切割的终结元素	[-r,r-1], r=rank(input)	



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
steps	input	1-D 数据	表示切割的步长	缺省为1。 仅opset>=10时存在steps属性。opset<10时steps恒为1。 - Hi3516CV610: 当steps不为1, 且axes=-1时, 不支持axes对应的轴超过4095。 - Hi3519DV500: 当steps不为1, 且axes=-1时, 不支持axes对应的轴超过65535。	

5.2.1.86 Softplus

opset version: 1

功能描述: 计算 $\ln(\exp(x) + 1)$ 。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
input	input	float	数据	支持	是

5.2.1.87 Softsign

opset version: 1

功能描述: 计算 $x/(1+|x|)$ 。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
input	input	float	数据	支持	是

5.2.1.88 SpaceToDepth

opset version: 11

功能描述: 重新排列空间数据块,将space数据转移到进入depth。

注意: 输出Channel最大仅支持4096。



参数名	参数/输入	数据类型	参数含义	规格		是否支持离线data输入
				Hi3519 DV500	Hi3516CV6 10	
input	input	float	数据	H/W必须是blocksize的整数倍。		是
blocksize	attribute	int	取空间的大小	支持[2, 255]	支持[2, 16]	

5.2.1.89 Split

opset version: 13

功能描述：在指定数据轴对数据进行拆分。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
axis	attribute	int64	指定拆分轴	支持，高维度场景下axis约束与 Slice 相同。	否
input	input	float	数据	支持	
split	input	int64	拆分的长度	支持	

5.2.1.90 Squeeze

功能描述：删除指定下标轴的1。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是
axes	input	int64	删除轴的下标	支持	

5.2.1.91 Sub

opset version: 13

功能描述：tensor对应轴作减法。支持高维度输入。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
A	input	float	数据	broadcast支持与Add一致。	是
B	input	float	数据		

5.2.1.92 Sum

opset version: 13

功能描述：对所有的tensor对应值求和。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data_0	input	variadic	数据	broadcast支持与Add一致。	是

5.2.1.93 Softmax

功能描述：

- Opset version 11：计算指定轴往后所有轴的softmax。
- Opset version 13：计算指定轴的softmax。
- Hi3516CV610需满足：运算轴为axisC时， $5*16*1024*8 \geq \text{input_c} * \text{dataBit} / 2$ ；运算轴为axisH/axisW时， $5*16*1024*8 \geq 4 * \text{input_axis} * \text{dataBit}$

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
axis	attribute	int32	指定softmax的轴	[-r,r-1], r=rank(input), 若r为4, axis不为-4和0 若r为5, axis不为-5, -4, 0和1	是
input	input	float	数据	支持	

5.2.1.94 Sort

功能描述：RPN硬化层，对检测框进行排序



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
0	input	float	数据	支持	否
topK	attribute	uint32_t	最大输出框个数	支持，值域 [1,10000]	否
multi_sort	attribute	bool	是否使用多类sort	支持	
class_num	attribute	uint32_t	分类个数	支持，值域 [1,1000]	

5.2.1.95 Tanh

opset version: 13

功能描述：求tanh。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
input	input	float	数据	支持	是

5.2.1.96 ThresholdedRelu

opset version: 10

功能描述：作为激活函数实现数据变换： $y=x$ for $x > \alpha$, $y=0$ otherwise。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
alpha	attribute	float	数据分段阈值	支持，默认为1.0	不涉及
X	input	float	数据	支持	是

5.2.1.97 Tile

功能描述：对每一个轴的数据进行重复叠加，支持高维度输入（shape>4）。

opset version: 13

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
input	input	float	数据	支持	是



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
repeats	input	int64	指定轴重复几遍	必须为离线，size为InputDimNum的一维数组，且元素大于0。最高轴到C轴只允许有一个轴的重复次数不为1,且最高轴到该轴之前的轴的值必须为1，HW轴不受限制。	

5.2.1.98 Transpose

功能描述：数据转置。支持高维度输入，输入数据是4维或高维度场景下，高维度轴长度乘积大于等于1024时，走cpu模式。例如输入4维数据NCHW，当N大于等于1024时走cpu模式；输入数据5维shape[n1, n0, c, h, w]，当n1*n0大于等于1024时走cpu模式。

opset version: 21

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是
perm	attribute	int32	整型数组，转置后轴的排列值	支持，shape大小与输入shape一致	否

5.2.1.99 Upsample

功能描述：上采样。

参数名	参数/输入	数据类型	参数含义	规格	其他约束
data	input	float	数据	仅支持NCHW	不支持离线data输入
mode	attribute	string	默认为nearest，表示插值模式	仅支持mode为nearest	scale等同于stride
scale	input	uint32	缩放倍数，默认为2	仅支持NCHW，且要求N和C轴必须为1，H和W轴仅支持设置为2，不支持单轴上采样。	



5.2.1.100 Unsqueeze

功能描述：在指定下标轴插入1。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是
axes	input	int32	插入轴的下标	支持	

5.2.1.101 WinPartition

功能描述：WinPartition主要用来对张量划分窗口，通过指定窗口大小，将原本的张量从NCHW, 划分成 num_windows,C,1>window_size*window_size,其中 num_windows=H*W/ (window_size*window_size)，即窗口的个数。

规格约束：输入C在Hi3516CV610上必须为8的整数倍，在Hi3519DV500中必须为4或8的整数倍；WinPartition和WinPartitionReverse配对出现时不支持batch。

参数名	参数/输入	数据类型	参数含义	公共规格	是否支持离线data输入
data	input	float	数据	仅支持shape结构为4维，仅支持输入N维度为1	否
windowSize	input	int	窗口的大小	windowSize不能为0，必须能被输入W维度和输入H维度整除	是

5.2.1.102 WinPartitionReverse

功能描述：WinPartitionReverse为WinPartition的逆过程，将shape还原成WinPartition输入shape。

规格约束：输入C在Hi3516CV610上必须为8的整数倍，在Hi3519DV500中必须为4或8的整数倍；WinPartition和WinPartitionReverse配对出现时不支持batch，WinPartitionReverse单独出现支持batch。

参数名	参数/输入	数据类型	参数含义	公共规格	是否支持离线输入
data	input	float	数据	仅支持shape结构为4维,仅支持inputWidth等于window_size * window_size	否



参数名	参数/输入	数据类型	参数含义	公共规格	是否支持离线输入
windowSize	input	int	窗口的大小	windowSize不能为0,必须能被origHSize和origWSize整除	是
origHSize	input	int	原始Height大小	须大于0	是
origWSize	input	int	原始Width大小	须大于0	是

5.2.1.103 TopK

opset version: 11

功能描述：沿指定轴检索最大或最小的K个元素。

参数名	参数/输入	数据类型	参数含义	规格		是否支持离线data输入
axis	attribute	int	排序的维度。	支持。范围为[-r,r-1], r=rank(input)	Hi3516CV610使用CPU实现，Hi3519DV500的支持如下： largest为false或者sorted为false的场景使用CPU实现，其他场景如果满足下面任一条使用图像引擎实现： 1. 输入4维以下 2. 输入4维且最高维为1，axis的值不为0或者-4 3. 其他维度数，axis为最后两个轴的其中之一 不满足的场景使用CPU实现	是
largest	attribute	int	决定是否返回最大或最小的元素	支持		
sorted	attribute	int	无论sorted为true或false输出都是排序后的	支持		
X	input	float	数据	支持		
K	input	int64	最大或最小的元素个数。	支持。须大于0且小于等于数据输入X的axis轴对应的数据量		



5.2.1.104 SortVector

说明

Hi3519DV500不支持。

功能描述：对输入向量进行排序操作。

规格约束：输入shape只支持1*1*1*w格式。当后接算子的类型为SortVector或FilterVector时，不支持is_output_idx配1。输入shapeW取值范围为[1,4095]。

参数名	数据类型	参数含义	规格
top_k	uint32	默认为inputW，表示输出的值最大个数，配置后 outputW=min(top_k, inputW)。	支持配置
is_output_idx	bool	默认为false，值为false时表示输出为向量值，为true时表示输出为向量索引。	支持配置
is_report_vector_num	bool	默认为true，值为true时表示当算子为最后一层时，会后接两个report层，同时输出结果向量以及向量长度；值为false时后接一个report层，只输出结果向量。	支持配置

5.2.1.105 FilterVector

说明

Hi3519DV500不支持。

功能描述：对输入向量进行过滤操作。大于等于过滤阈值的数据会被保留，其余被过滤，过滤后的输出紧凑排布。

规格约束：输入shape只支持1*1*1*w格式。当后接算子的类型为SortVector或FilterVector时，不支持is_output_idx配1。



参数名	数据类型	参数含义	规格
top_k	uint32	默认为inputW，表示输出的值最大个数，配置后 outputW=min(top_k, inputW)。当top_k配置值小于实际框数量时，只会保留前top_k个符合阈值要求的框。	支持配置
filter_thresh	float	默认为0.5，过滤阈值。	支持配置
is_output_idx	bool	默认为false，值为false时表示输出为向量值，为true时表示输出为向量索引。	支持配置
is_report_vector_num	bool	默认为true，值为true时表示当算子为最后一层时，会后接两个report层，同时输出结果向量以及向量长度；值为false时后接一个report层，只输出结果向量。	支持配置

5.2.1.106 GroupNorm

功能描述：计算 $y = \text{scale} * (x - \text{mean}) / \sqrt{\text{variance} + \text{epsilon}} + \text{bias}$ 。其中，mean和variance 是根据每个通道组的实例计算的，并且应为每组通道指定比例(scale)和偏差(B)。

规格约束：scale和B不支持在线输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
epsilon	attribute	float	避免除零	支持	是
num_groups	attribute	uint32	分组数	支持（大于0）	
input	input	float	数据	支持	
scale	input	float	缩放比例	支持	
bias	input	float	偏差	支持	

5.2.2 CPU



5.2.2.1 Acosh

opset version: 9

功能描述：逐点求hyperbolic arccosine。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是

5.2.2.2 And

功能描述：对输入A、B进行elementwise逻辑与计算得到输出C。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
A	input	bool	数据	输入A、B皆支持 Numpy-style广播	是
B	input	bool	数据		

说明：当And算子作为首层，使用--input_type设置数据类型时，需要设置成FP32。

5.2.2.3 Asinh

opset version: 9

功能描述：逐点求hyperbolic arcsine。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是

5.2.2.4 Atanh

opset version: 9

功能描述：逐点求hyperbolic arctangent。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是



5.2.2.5 BitShift

功能描述：对输入的元素二进制表示进行移位操作。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
direction	attribute	string	决定移位的方向	支持	是
X	input	int	数据		
y	input	int	移动的数量		

5.2.2.6 Cosh

功能描述：逐点求hyperbolic cosine。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是

5.2.2.7 CumSum

功能描述：计算输入元素沿给定轴的累加和。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
exclusive	attribute	int	指示是否包含顶部元素的独占和	支持	是 当x为离线输入时，axis同样必须是离线输入
reverse	attribute	int	指示求和的元素方向		
x	input	float	数据		
axis	input	int32, int64	指示求和的维度		

5.2.2.8 Cmp

函数功能：

配置比较类型，目前支持"COND_GT"、"COND_EQ"、"COND_LT"、"COND_NE"、"COND_GE"、"COND_LE"六种。

参数说明：



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
compType	input	float	数据	比较类型： COND_GT 大于； COND_EQ 等于； COND_LT 小于； COND_NE 不相等； COND_GE 大于等于； COND_LE 小于等于。 默认 COND_GT 大于	是

5.2.2.9 Equal

功能描述：逐点计算A中元素是否等于B中元素。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
A	input	float	数据	支持Numpy-style广播	是
B	input	float	数据	支持Numpy-style广播	

5.2.2.10 Det

功能描述：求行列式。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	需2D或以上	是

5.2.2.11 Div

功能描述：对输入A、B进行除法运算得到输出C。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
A	input	float	数据	输入A、B皆支持 Numpy-style广播	是
B	input	float	数据		



5.2.2.12 Expand

功能描述：将输入tensor广播成输出tensor。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
input	input	float	数据	支持	是
shape	input	int64	指示输出的形状	必须为离线	

5.2.2.13 GatherElements

功能描述：是一种索引操作，通过在由indices的元素确定的索引位置处对输入数据张量进行索引来生成其输出。它的输出形状与索引的形状相同。

opset version: 13

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是
indices	input	int32/int64	需要提取的indices	$[-s, s-1]$, $s = \text{shape}(\text{axis})$	
axis	attribute	int32	gather的轴	$[-r, r-1]$, $r = \text{rank}(\text{input})$	

5.2.2.14 GlobalLpPool

功能描述：实现对同一channel的所有元素Lp norm。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入	其他约束
p	attribute	int	Lp norm的p值	支持	是	-
X	input	float	数据			

5.2.2.15 Greater

功能描述：逐点计算A中元素是否大于B中元素。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
A	input	float	数据	支持Numpy-style广播	是



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
B	input	float	数据	支持Numpy-style广播	

5.2.2.16 GreaterOrEqual

功能描述：逐点计算A中元素是否大于等于B中元素。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
A	input	float	数据	支持Numpy-style广播	是
B	input	float	数据	支持Numpy-style广播	

5.2.2.17 GridSample

功能描述：基于网格坐标位置的插值，对输入x进行采样。该算子仅支持Hi3519DV500芯片。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
x	input	float	数据	仅支持4D	否
grid	input	float	坐标	shape为[N,H,W,2]，数值范围[-1,1]	否
align_corners	attribute	int32	角点像素是否中心对齐	取值0或1，默认为0。	是
mode	attribute	string	插值模式	取值'linear'、'nearest'或'cubic'，分别表示线性插值、临近插值、三次插值，默认为'linear'。	是
padding_mode	attribute	string	补边填充方式	取值'zeros'、'border'或'reflection'，分别表示0值模式、边缘模式、镜像模式，默认为'zeros'。	是

5.2.2.18 HardMax

功能描述：如果沿着axis，输入的点是最大的则为1，否则为0。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是
axis	attribute	int32	轴	$[-r, r-1]$, $r=\text{rank}(\text{input})$	

5.2.2.19 Less

功能描述：逐点计算A中元素是否小于B中元素。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
A	input	float	数据	支持Numpy-style广播	是
B	input	float	数据	支持Numpy-style广播	

5.2.2.20 LessOrEqual

功能描述：逐点计算A中元素是否小于等于B中元素。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
A	input	float	数据	支持Numpy-style广播	是
B	input	float	数据	支持Numpy-style广播	

5.2.2.21 LpNormalization

功能描述：对指定轴进行lp_norm计算。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是
axis	attribute	int32	指定进行正则化的轴	$[-r, r-1]$, $r=\text{rank}(\text{input})$	
p	attribute	float	归一化的顺序	支持	

5.2.2.22 MaxUnPool

功能描述：MaxPool的部分逆操作。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
kernel_shape	attribute	int	沿着每轴的kernel大小	支持	是
pads	attribute	int	每个轴的开始和结束位置	支持	
strides	attribute	int	每个轴的stride	支持	
X	input	float	数据	支持	
l	input	int64	对应X中元素的索引	支持	
output_shape	input(optional)	int64	输出形状	必须为离线，可不配置	

5.2.2.23 Mod

功能描述：对输入数据的元素进行取余。

opset version: 13

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
fmod	attribute	bool	指示进行fmod还是integer mod	支持 输入A、B皆支持 Numpy-style广播	是
A	input	float	数据		
B	input	float	数据		

5.2.2.24 NonMaxSuppression

功能描述：过滤掉与其它框有高的IOU的框。其输出shape 随在线数据变化，模型转换时按最大shape分配内存和推理。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
center_point_box	attribute	int	框数据的格式	支持	是
boxes	input	float	数据	支持	
scores	input	float	数据	支持	
max_output_boxes_per_class	input	float	每类每batch的最大框数	optional	



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
iou_threshold	input	float	框与框的IOU(intersection-over-union)阈值	optional	
score_threshold	input	float	决定是否基于分数去除框	optional	

5.2.2.25 NonZero

功能描述：返回非零元素的索引。其输出shape 随在线数据变化，模型转换时按最大shape分配内存和推理。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	是

5.2.2.26 Not

功能描述：对输入X进行逻辑非运算得到输出Y。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	bool	数据	支持	是

说明：当Not算子作为首层，使用--input_type设置数据类型时，需要设置成Fp32。

5.2.2.27 OneHot

功能描述：求onehot编码。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
indices	input	float	indices指示哪些位置为on_value，输入必须为整数坐标对应的浮点表示，如0.0, 1.0等。	[-depth, depth-1]	是。depth必须为离线输入
depth	input	float	onehot编码的类数	支持	



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
values	input	float	共有两个值，一个on_value，另一个为off_value	[off_value, on_value]	
axis	attribute	int32	指定onehot编码的轴	[-r-1, r], r=rank(input)	

5.2.2.28 Or

功能描述：对输入A、B进行elementwise逻辑或计算得到输出C。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
A	input	bool	数据	输入A、B皆支持Numpy-style广播	是
B	input	bool	数据		

说明：当Or算子作为首层，使用--input_type设置数据类型时，需要设置成Fp32。

5.2.2.29 Range

功能描述：根据起始值，结束值，步长信息计算输出数列。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
start	input	float	数列起始值	支持	是。仅支持所有输入为离线数据。
limit	input	float	数列结束值	支持	
delta	input	float	数列步长	支持	

5.2.2.30 Resize

功能描述：将输入按指定mode进行缩放。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
coordinate_transformation_mode	attribute	string	坐标轴转换的方式	除tf_crop_and_resize外支持配置	是
cubic_coeff_a	attribute	float	cube模式下缩放参数	不支持配置	



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
exclude_outside	attribute	int	是否包含张量之外的采样点	不支持配置	
extrapolation_value	attribute	float	coordinate_transformation_mode为"tf_crop_and_resize", 输入数据超出范围时使用的值。	支持配置	
mode	attribute	string	插值模式	支持nearest,linear	
nearest_mode	attribute	string	插值模式配置为nearest时的取值方式	支持	
X	input	float	数据	仅支持4D	
roi	input	float	roi区域	不支持配置	
scales	input	float	沿各个轴的缩放倍数	必须且只能配置scales或者sizes中的一个	
sizes	input	int64	输出的shape	支持	

5.2.2.31 ReduceL2

opset version: 13

功能描述：对指定的轴计算l2_norm。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是
axes	attribute	list of ints	reduce的轴	list中的每个axis[-r,r-1], r=rank(input)	
keepdims	attribute	bool	是否保留reduce的轴	支持	

5.2.2.32 ReduceLogSum

opset version: 13

功能描述：对指定的轴计算log_sum。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是
axes	attribute	list of ints	reduce的轴	list中的每个axis[-r,r-1], r=rank(input)	
keepdims	attribute	bool	是否保留reduce的轴	支持	

5.2.2.33 ReduceLogSumExp

opset version: 13

功能描述：对指定的轴计算log_sum_exp。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是
axes	attribute	list of ints	reduce的轴	list中的每个axis[-r,r-1], r=rank(input)	
keepdims	attribute	bool	是否保留reduce的轴	支持	

5.2.2.34 ReduceProd

opset version: 13

功能描述：对指定的轴计算乘积。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是
axes	attribute	list of ints	reduce的轴	list中的每个axis[-r,r-1], r=rank(input)	
keepdims	attribute	bool	是否保留reduce的轴	支持	

5.2.2.35 Scatter

功能描述：替换输入数据指定位置的值。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
axis	attribute	int32	替换的轴面	支持	是
data	input	float	数据	支持	
indices	input	int32/int64/ float	要替换数据下标	支持，onnx原生仅支持int32/64,ATC兼容float，由于indices必须为整型，float数据以round()方式近似为整型。	
updates	input	float	要替换的值	支持	

5.2.2.36 ScatterND

功能描述：替换输入数据指定位置的值。

opset version: 13

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是
indices	input	int64	要替换的数据切片在输出中的坐标值	支持	
updates	input	float	要替换的值	支持	

5.2.2.37 Selu

opset version: 13

功能描述：Selu激活函数。非默认参数下进CPU模式，即 $\alpha \neq 1.67326$ || $\gamma \neq 1.0507$ 。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
alpha	attribute	float	系数	支持	是
gamma	attribute	float	系数	支持	
X	input	float	数据	支持	



5.2.2.38 Shrink

功能描述：Shrink激活函数。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
bias	attribute	float	给输出数据的偏转值	支持	是
lambd	attribute	float	Shrink公式的lambd值	支持	
input	input	float	数据	支持	

5.2.2.39 Sinh

功能描述：逐点求hyperbolic sine。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
data	input	float	数据	支持	是

5.2.2.40 Sqrt

opset version: 13

功能描述：对输入数据求平方根。支持高维度输入。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
X	input	float	数据	支持	是

5.2.2.41 Transpose

功能描述：和numpy的transpose一样转置输入tensor。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
perm	attribute	int	permute轴	支持	是
data	input	float	数据		

5.2.2.42 Xor

功能描述：对输入A、B进行elementwise逻辑异或计算得到输出C。



参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
A	input	bool	数据	输入A、B皆支持Numpy-style广播	是
B	input	bool	数据		

5.2.2.43 Where

功能描述：根据condition确定输出是X还是Y对应的元素。

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线data输入
condition	input	bool	指示是输出元素是到X还是Y对应的元素	condition、X、Y都支持广播	是
X	input	float	condition为True时选定的值		
Y	input	float	condition为False时选定的值		

5.2.2.44 Gather

功能描述：将指定轴方向指定indices的数据聚合在一起。

opset version: 13

参数名	参数/输入	数据类型	参数含义	规格	是否支持离线输入
data	input	float	数据	支持tensor输入。	是
indices	input	int32/ int64	需要提取的indices	支持scalar/tensor输入。 - indices为在线输入时：[0,s-1], s=shape(axis) - indices为离线输入时：[-s,s-1], s=shape(axis)	是
axis	attribute	int32	gather的轴	[-r,r-1], r=rank(input)	不涉及

5.3 Roi/Psroi Pooling 算子输入格式

标准Caffe/Onnx的Roi/Psroi Pooling算子都有2个输入，其中第1个输入是维度为N×C×H×W的输入数据，第2个输入是维度为num_rois×5的ROI区域。本小节描述当Roi/Psroi Pooling算子作为网络首层时，ATC工具和板端需要的第2个输入（板端还需要第3个输入）的数据格式。

5.3.1 ATC 工具的输入格式

ATC工具支持两种ROI输入格式。


- 与标准Caffe/Onnx的输入格式保持一致；
- 与硬化DecBBBox层的输出格式保持一致，维度为 $1 \times 1 \times H \times \text{num_rois}$ ， $H \geq 4$ 。Prototxt的写法如图5-1所示。

图 5-1 两种输入格式的 prototxt 写法



对应两种不同的prototxt写法，相应的量化数据输入格式如图5-2所示。对于格式1)，N维度为num_rois，所以每个ROI区域是一行。对于格式2)，N维度为1，所以H×W个点在同一行；需要注意：当H > 4时，需保证表示ROI区域的坐标排在H0-H3，并且顺序为x0 -> y0 -> x1 -> y1。

图 5-2 两种输入格式的量化数据排布




5.3.2 板端的输入格式

当Roi/Psroi Pooling算子作为网络首层时，最终生成的网络结构如图5-3所示。

- 第1个data层对应feature_map输入，
- 第2个data层对应ROI区域输入，
- 第3个data层的输入是实际有效ROI的个数，即ActualRoiNum。

图 5-3 首层 Roi/Psroi Pooling 网络结构图



板端只支持1种ROI区域（第2个data层）输入格式，类似ATC工具的第2种输入格式。ATC工具的输入配置为格式1）或2），不影响最终生成的om支持的输入格式。板端需要的ROI输入维度为 $1 \times 1 \times H \times \text{MaxRoiFrameCnt}$ ，其中H等于prototxt中配置的H，MaxRoiFrameCnt等于cfg文件中指定的max_roi_frame_cnt。当ActualRoiNum < MaxRoiFrameCnt，每一行需要补齐到MaxRoiFrameCnt个点。Roi/Psroi Pooling算子会按照 $\min(\text{MaxRoiFrameCnt}, \text{ActualRoiNum})$ 计算。

5.4 Recurrent（LSTM/GRU/RNN）算子板端输入输出格式


标准Caffe的Recurrent（LSTM/GRU/RNN）算子都有至少2个输入，其中第1个输入是维度为 $t \times n \times d$ 的输入数据，第2个输入是维度为 $t \times n$ 的continuous数据。本小节描述当Recurrent网络包含诸如Conv等4D规格的算子且batch_num配置为大于1的值时，板端的输入输出数据格式。



5.4.1 板端的输入格式

假设Recurrent网络片段结构如图5-4所示，Reshape层和Permute层负责将Conv输出的4D数据转换为3D数据并作为LSTM层的第一个输入，Data（Preprocess）层对应LSTM层的第二个continuous输入。当Prototxt首层N轴为1，即维度为 $1 \times C \times H \times W$ 时，LSTM层的帧数轴t为18，句子轴n为1。

图 5-4 Recurrent 网络片段结构图



若batch_num配置为大于1的值，针对LSTM层的continuous输入（Data层），板端需准备指定图片张数对应的数据量，并且数据排布等同于标准Caffe下，Prototxt首层N轴为batch_num时continuous的数据排布。以图5-4为例，板端准备的continuous数据应符合标准Caffe下continuous的shape为[18, batch_num]所对应的数据排布。



5.4.2 板端的输出格式

当batch_num配置为大于1的值时，板端的输出数据将按照图片顺序依次排列，即先排完第一张图片对应的全量数据，再依次排列后续各图片对应的全量数据。该排布可能和Caffe标准框架下Prototxt首层N轴为batch_num所产生的数据排布不一致。

仍以图5-4为例，LSTM层第一个输出shape为[18, 1, 128]，板端在该层得到的输出符合shape为[batch_num, 18, 1, 128]对应的数据排布，即依次排列每张图片对应的计算数据。在标准Caffe下，若Prototxt首层N轴为batch_num，LSTM层第一个输出符合shape为[18, batch_num, 128]对应的数据排布，即不同图片对应的数据间存在交叉排列。

6 性能优化推荐设置

6.1 网络连接


6.1.1 兄弟节点的数据类型

当多个兄弟节点的输入数据类型(DDR)与计算数据类型(NPU)完全一致时，性能最好。

如果使用ATC生成的量化参数，兄弟节点的上述几个数据类型大部分情况是一致的；如果需要通过AMCT调整数据类型，则需自行保证一致性。

如图6-1所示，net1、net2是推荐设置，net3不推荐；图中的S8_FP16_S8，分别表示：输入数据类型(DDR)_ 计算数据类型(NPU)_ 输出数据类型(DDR)。

图 6-1 兄弟节点的数据类型设置



6.1.2 兄弟节点的补边

当兄弟节点的kernel_h相等，建议上补边也相等；如图6-2所示，左图是推荐设置。

图 6-2 兄弟节点的补边设置




只有上补边有影响，左、右、下补边没有影响。

当兄弟节点的kernel_h不相等，则上补边是否相等没有影响。

6.1.3 Conv 级联 Pool

当Conv是单输出节点，并且Pool同时满足kernel=2*2，stride=2*2，pad=0时，性能最好。

图 6-3 Conv 级联 Pool 推荐设置



6.2 算子属性



6.2.1 Conv/Pool/DepthwiseConv

属性名称	推荐设置
output_w	output_w % 16 = 0
output_h	> 1
output_c	output_c % 16 = 0
input_c	input_c % (64 / data_bit_num) = 0 input_c <= 8192
kernel	1*1; 2*2; 3*3 针对Convolution, 当 (input_c < 32) 时, 不推荐设置kernel为1*1
dilation	1*1
stride	Hi3519DV500: 1*1, 2*2 Hi3516CV610: 1*1, 不推荐2*2
pad	pad_up < kernel_h pad_down < kernel_h 在可以选择上补边或者下补边时, 推荐设置上补边
group	针对Convolution, 每个group都可以视作一个Convolution层, 则当每个group的参数都满足上述推荐设置时, 性能最好。
weight_param_size	< 1MB

说明

- data_bit_num 表示计算数据位宽, 当计算数据类型为U4/S4时, data_bit_num = 4; 当计算数据类型为U8/S8时, data_bit_num = 8; 当计算数据类型为U16/S16时, data_bit_num = 16。
- weight_bit_num表示权重位宽, 当权重类型为S4时, weight_bit_num=4; 当权重类型为S8时, weight_bit_num=8。
- output_w / output_c / input_c 不满足对齐要求时, 会浪费补齐到对应倍数的计算量。
- weight_param_size 表示量化后权重的总大小, 以 group=1 的Convolution为例, $\text{weight_param_size} = \text{output_c} * \text{input_c} * \text{kernel_h} * \text{kernel_w} * \text{weight_bit_num} / 8$ 。

6.2.2 Deconv

属性名称	推荐设置
output_w	output_w % 16 = 0
output_h	> 1
output_c	output_c % 16 = 0



属性名称	推荐设置
input_c	input_c % (64 / data_bit_num) = 0 32 <= input_c <= 8192
kernel	1*1; 2*2; 3*3 针对Deconvolution, 当 (input_c < 32) 时, 不推荐设置kernel为1*1
dilation	1*1
stride	1*1; 2*2 stride_w <= kernel_w stride_h <= kernel_h
pad	pad_up > (kernel_h - stride_h - 1) pad_down > (kernel_h - stride_h - 1) 在可以选择上补边或者下补边时, 推荐设置上补边
weight_param_size	< 1MB

6.2.3 输入输出 shape

建议使用NCHW格式来描述算子的输入输出数据排布。

6.2.4 变形类算子

算子	推荐设置
Concat Slice	输入输出均为NCHW格式, 并且在C轴拼接或者分割时, 效率最高
Reshape	output_w = input_w时, 效率最高

6.2.5 双目运算类算子

包括: Caffe框架中的Eltwise算子, Pytorch框架中的Add / Sub / Mul 等算子。

建议使用加、减、乘、取Max 的算子。